ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Комплект программной документации ЕСПД

Версия комплекса 0.0.1, коммит 16122fc, дата составления 30.10.2026. Черновик: не согласован, подписи и организация не заполнены.

Авторы: Верховых Егор, Стрижевский Андрей, Парамонов Даниил, Приц Артём.

Единый PDF: названия документов в таблице – ссылки на их первые страницы; панель закладок содержит оглавление каждого документа; пути к файлам репозитория в тексте (`docs/...`, `src/...`) – ссылки на GitHub на коммите 16122fc. Нумерация страниц внутри документов своя.

Таблица 1 – Документы комплекта

№	Документ	Сокр.	ГОСТ	Стр.	Файл DOCX
1	Техническое задание	ТЗ	ГОСТ 19.201-78	2	01-tehnicheskoe-zadanie.docx
2	Пояснительная записка	ПЗ	ГОСТ 19.404-79	16	02-poyasnitelnaya-zapiska.docx
3	Описание программы	ОП	ГОСТ 19.402-78	31	03-opisanie-programmy.docx
4	Руководство оператора	РО	ГОСТ 19.505-79	49	04-rukovodstvo-operatora.docx
5	Руководство системного программиста	РСП	ГОСТ 19.503-79	58	05-rukovodstvo-sistemnogo-programmista.docx
6	Программа и методика испытаний	ПМИ	ГОСТ 19.301-79	71	06-programma-i-metodika-ispytanij.docx
7	Описание применения	ОПр	ГОСТ 19.502-78	86	07-opisanie-primeneniya.docx
8	Формуляр	ФО	ГОСТ 19.501-78	94	08-formulyar.docx

Дополнительно в каталоге `docs/gost/`: `docs/gost/README.md` (перечень), `docs/gost/CHECKLIST.md` (соответствие ГОСТ, пробелы, неизмеренное).

_____

(наименование организации – заполнить)

УТВЕРЖДАЮ
Должность
_____
_____ / _____
«____» _____ 2026 г.
(поля подписи оставлены пустыми)

ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Локальный офлайн нейро-символический следователь по рассказам о Шерлоке Холмсе

ТЕХНИЧЕСКОЕ ЗАДАНИЕ

на разработку программного комплекса
ГОСТ 19.201-78

Обозначение документа: _____ (присваивается организацией)

Авторы:
Верховых Егор
Стрижевский Андрей
Парамонов Даниил
Приц Артём

Комплект программной документации ЕСПД, документ 1 из 8
Версия комплекса: 0.0.1 (pyproject.toml); состояние репозитория: main, коммит 16122fc
Дата составления: 30.10.2026. Статус: черновик, не согласован

2026

ЛИСТ СОГЛАСОВАНИЯ

Подписи, фамилии и даты не заполнены: документ составлен по состоянию репозитория и не согласован ни с кем.

Роль	Должность	Фамилия И. О.	Подпись	Дата
Разработал				
Проверил				
Нормоконтроль				
Утвердил				

СОДЕРЖАНИЕ

1 ВВЕДЕНИЕ.....4
1.1 Наименование программы.....4
1.2 Краткая характеристика области применения.....4
1.3 Статус настоящего задания.....4
2 ОСНОВАНИЕ ДЛЯ РАЗРАБОТКИ.....5
3 НАЗНАЧЕНИЕ РАЗРАБОТКИ.....5
3.1 Функциональное назначение.....5
3.2 Эксплуатационное назначение.....5
4 ТРЕБОВАНИЯ К ПРОГРАММЕ.....6
4.1 Требования к функциональным характеристикам.....6
4.2 Требования к надёжности.....7
4.3 Условия эксплуатации.....8
4.4 Требования к составу и параметрам технических средств.....8
4.5 Требования к информационной и программной совместимости.....8
4.6 Требования к маркировке и упаковке.....9
4.7 Требования к транспортированию и хранению.....9
4.8 Специальные требования.....9
5 ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ.....10
6 ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ.....10
7 СТАДИИ И ЭТАПЫ РАЗРАБОТКИ.....11
8 ПОРЯДОК КОНТРОЛЯ И ПРИЁМКИ.....11
ПРИЛОЖЕНИЕ А.....12
ПРИЛОЖЕНИЕ Б.....13
ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ.....14

Документ – черновик: составлен по материалам репозитория и измерениям, лежащим в `docs/spike/results/` и `docs/perf/`; человеком не проверен и никем не согласован. Подписи, должности, даты согласования и обозначение документа оставлены пустыми намеренно.

Условные обозначения статуса сведений в комплекте. [Измерено] – число взято из файла отчёта, путь указан рядом. **[Не измерено]** – измерения нет. **[План]** – описано в проектных документах, в коде отсутствует или выключено. **[Заполнить]** – поле оставлено пустым для человека.

1 ВВЕДЕНИЕ

1.1 Наименование программы

Полное наименование: «Детективная доска» (Detective Board) – локальный офлайн нейро-символический следователь по 20 рассказам о Шерлоке Холмсе. Условное обозначение в комплекте документации – «система», «комплекс». Версия в `pyproject.toml`: 0.0.1.

1.2 Краткая характеристика области применения

Система предназначена для работы с фиксированным текстовым корпусом (20 рассказов о Шерлоке Холмсе, общественное достояние, Проект Гутенберг): отвечает на вопросы только по тексту корпуса с дословными цитатами, проверяет противоречия и алиби детерминированными правилами, показывает ход расследования (граф фактов и трассу шагов агента) и честно отказывается отвечать, когда корпус ответа не поддерживает. Область применения – учебный проект и демонстрация на конкурсе (показ 30.10.2026, слот 7 минут); промышленная эксплуатация не предполагается.

1.3 Статус настоящего задания

Задание составлено **ретроспективно**, по состоянию репозитория на коммит `16122fc`: подписанного заказчиком технического задания в репозитории нет. Источниками требований служат `docs/PRD.md` (draft 2 от 23.10.2026), решения заказчика от 22.10.2026, зафиксированные в

docs/design/demo-script.md, и принятые ADR (docs/adr/). Для каждого требования указан статус выполнения на дату составления.

2 ОСНОВАНИЕ ДЛЯ РАЗРАБОТКИ

– Документ-основание: docs/PRD.md (положение о продукте, цели, не-цели, ограничения). Приказ, договор или задание на проект: **[Заполнить]** (в репозитории не найдено).
– Организация-заказчик и организация-исполнитель: **[Заполнить]**. Исполнитель – команда проекта; руководитель проекта – владелец репозитория (GitHub `AndrewStrizhevskiy`).
– Наименование темы разработки: «Local GraphRAG investigator agent over Sherlock Holmes stories» (pyproject.toml).

3 НАЗНАЧЕНИЕ РАЗРАБОТКИ

3.1 Функциональное назначение

Ответы на вопросы пользователя по корпусу с цитатами и ссылкой на рассказ и фрагмент; поиск противоречий, проверка алиби и построение хронологии правилами R1–R3 над графом фактов; отказ при отсутствии опоры в тексте; показ графа и трассы работы агента; предоставление возможностей через MCP-инструменты.

3.2 Эксплуатационное назначение

Работа на одном ноутбуке без сети и без облачных моделей: ЦП, Ollama, модели не более 8 млрд параметров. Основная нагрузка (извлечение фактов из 596 фрагментов) вынесена в предварительные вычисления на другом оборудовании, результат поставляется готовыми файлами.

4 ТРЕБОВАНИЯ К ПРОГРАММЕ

4.1 Требования к функциональным характеристикам

Таблица 1 сводит требования. Столбец «Статус» отражает только то, что есть в репозитории и что измерено; ссылки на отчёты даны в пути относительно корня репозитория.

Таблица 1 – Функциональные требования и их статус на коммите 16122fc

№	Требование	Статус на дату составления
ФТ-1	Ответ по корпусу с дословной цитатой и ссылкой на рассказ/фрагмент (PRD, цель 1)	Реализовано: основной режим – извлекающий (модель выбирает номера предложений, ответ – дословный текст; ADR-0009). **[Измерено]** на test-срезе (n=30): «поведение корректно» у агента 13/30, у векторного поиска 11/30, у «голой» модели 3/30 (`docs/spike/results/eval-2026-10-28-test-7b7b197-7857839ed9be-175321.md`). Метки разметки размечены автоматически, человеком не проверены.
ФТ-2	Поиск противоречий и проверка алиби правилами R1–R3 с объяснением (PRD, цель 2)	Реализовано в `src/detective_board/symbolic/`. **[Измерено]**: на автоматически построенном графе правила не нашли противоречий в 19 из 20 рассказов; единственная находка – курируемый случай Wisteria Lodge (`docs/spike/results/graph-sanity-20261028.md`). Полнота на test-срезе 0/12, ложных срабатываний 0/8 (файл test-среза).
ФТ-3	Честный отказ при отсутствии опоры в корпусе (цель 3)	Реализовано (шлюз поиска и правила маршрутизатора, ответ без вызова модели). **[Измерено]** на test-срезе: полнота отказов 6/6, точность отказов 6/12, доля ложных отказов 6/24.
ФТ-4	Показ расследования: граф фактов и трасса шагов в реальном времени (цель 4)	Реализовано: веб-интерфейс `web/`, поток событий SSE. Частота кадров доски улучшена в PR #30 (влит 29.10.2026, коммит `9541df9`). Измерение из описания PR (суммарное время растеризации в headless Chromium при скриптовых сдвиге и масштабировании, мс до → после): 14 карточек – сдвиг 2400 → 225, масштаб 2100 → 315; 120 узлов – 2040 → 363 и 3700 → 1170; 200 узлов – 2060 → 384 и 13 900 → 2780. Разброс на масштабировании большой; на целевом ноутбуке не измерялось; в покое картинка совпадает с прежней (среднее отличие 1,5 из 255 после сдвига); видимое изменение – резкие тени во время жеста масштабирования.
ФТ-5	Возможности как MCP-инструменты (цель 5)	Реализован собственный сервер `timeline-alibi` (6 инструментов, stdio). Готовые серверы filesystem и fetch **[План]**, в системе не подключены (`docs/security.md`, раздел 2.5).

№	Требование	Статус на дату составления
ФТ-6	Метки происхождения каждого утверждения: extracted / derived / conditional (+ source_text, curated)	Реализовано в графе (`provenance`, `confidence`), результатах правил и ответах API.
ФТ-7	Измерение качества: сравнение конфигураций и отдельная оценка правил (цель 6)	Реализован `eval/run_eval.py` (конфигурации bare, vector, hybrid+graph; vector+rerank – «не запускалось», реранкера нет). Золотые наборы размечены автоматически, проверка человеком (issue #9) **не выполнена**.
ФТ-8	Единый источник истины: MCP и агент вызывают одни и те же правила (цель 7)	Реализовано (`mcp/server.py` и агент используют `symbolic/`); тесты `tests/mcp/`, `tests/symbolic/`.
ФТ-9	Запуск одной командой без сети после установки	`just run` (в режиме `--fake` без Ollama). Офлайн-архив собран и проверен **на одной машине** (`docs/perf/clean-install-20261029.md`); проверка на двух разных ноутбуках (issue #8) **не выполнена**.
ФТ-10	Вопрос на русском языке	Кириллический вопрос переводится на английский локальной моделью (`translate_questions`, по умолчанию включено). Отдельная метрика качества для русских вопросов **[Не измерено]**.
ФТ-11	Хронология, таблица присутствия, доска исключения по алиби	Реализованы дополнительные MCP-инструменты `build_timeline`, `presence_table`, `scene_board`; доска опирается на курируемую сцену (одна сцена – Wisteria Lodge).

4.2 Требования к надёжности

– Результат правил R1–R3 должен быть детерминированным и воспроизводимым (PRD, раздел 7: цель – 100 % зелёных тестов правил). **[Измерено]**: `uv run pytest -m "not live and not e2e"` на коммите 16122fc – 986 passed.

– При недоступности Ollama или превышении лимита 600 с запуск завершается событием `run_error` (`internal`, `unavailable`, `timeout`); трасса, выданная ранее, остаётся действительной (`docs/api.md`).

– Одновременно выполняется один запрос; второй получает `429 busy`.

– MCP-сервер открывает граф только на чтение, ограничение времени вызова инструмента – 4 с по умолчанию (`DETECTIVE_BOARD_TOOL_DEADLINE_S`).

– Ответ не должен выдавать пустой результат правил за доказательство согласованности (охрана честности, ADR-0010).

4.3 Условия эксплуатации

Целевое устройство: ноутбук ThinkPad X1 Carbon 7-го поколения (i7-8665U, 4 ядра, 15 ГиБ ОЗУ, без GPU), Linux x86_64, сеть отключена. Среда разработки: macOS. Устройство работает на сетевом питании; для долгого показа нужен отвод тепла: температура корпуса процессора в измерениях 98–100 °C (`docs/perf/laptop-20261029.md`).

4.4 Требования к составу и параметрам технических средств

– Процессор x86_64, 4 ядра; GPU не требуется (на GPU-сервере кафедры RTX 4070 12 ГБ использовалась только для предварительных вычислений).
– ОЗУ: 16 ГБ рекомендуется (пик по процессам llama-server 6289 МБ **[Измерено]**, `docs/perf/laptop-20261029.md`); профиль 8 ГБ **[Не измерено]**.
– Диск: около 2,5 размера офлайн-архива; архив rc4 – 6,2 ГБ (`docs/perf/clean-install-20261029.md`).
– Время ответа: рабочий бюджет не более 40 с (PRD, раздел 7, предварительный). **[Измерено]**: медиана 28,4 с по 16 отвеченным вопросам, диапазон 18,6–44,1 с (холодный старт 44,1 с) – не на «чистом» окне (`docs/perf/laptop-20261029.md`).

4.5 Требования к информационной и программной совместимости

Таблица 2 – Программная среда

Компонент	Требование	Источник
Python	>= 3.12	`pyproject.toml`
Менеджер окружения / запуск задач	uv, just	`justfile`, ADR-0001
Хранилище	SQLite с FTS5, расширение sqlite-vec 0.1.9	ADR-0002, `pyproject.toml`
Веб-сервер	Starlette 1.9.0, uvicorn 0.54.0	ADR-0005

Компонент	Требование	Источник
MCP	пакет `mcp` >= 2.3, < 3 (stdio)	ADR-0003, `pyproject.toml`
Валидация данных	pydantic >= 2.9, < 3	`pyproject.toml`
LLM-среда	Ollama (в офлайн-архиве – 0.35.0)	`docs/perf/clean-install-20261029.md`
Модели	bge-m3 (эмбеддинги), qwen3:4b-instruct (ответы), qwen3:4b (извлечение)	`docs/team/models.md`, ADR-0006..0008
Браузер	современный браузер с ES-модулями; Node.js нужен только для тестов интерфейса (`just test-web`)	`web/`, `justfile`

Данные корпуса: `data/clean/*.txt`, `data/chunks.jsonl` (596 фрагментов). Бинарные файлы индексов и графа в git не хранятся (`data/index/`, `data/graph/`, `data/cache/`) и поставляются в офлайн-архиве.

4.6 Требования к маркировке и упаковке

Поставка – один архив `detective-board-offline-<ref>.tar` с файлами `MANIFEST` (коммит, версии, идентификаторы моделей) и `SHA256SUMS`, рядом лежит `.tar.sha256` (`scripts/pack_offline.sh`). Отдельная упаковка не предусмотрена.

4.7 Требования к транспортированию и хранению

Перенос на USB-носителе; перед распаковкой обязательна проверка `sha256sum -c`. Условия хранения носителя не регламентируются **[Заполнить]**.

4.8 Специальные требования

– Текст корпуса – данные, а не инструкции: фрагменты передаются модели только внутри ограждённых блоков (`docs/security.md`, раздел 1).
– Использование без сети и без облачных моделей во время показа (`docs/DISCLOSURE.md`).
– Раскрытие того, что вычислено на другом оборудовании, какие модели использованы, какие факты курируются людьми (`docs/DISCLOSURE.md`).

– Лицензии корпуса и сторонних компонентов: data/LICENSES.md, THIRD_PARTY_NOTICES.md.
– Система не делает утверждений о виновности; вывод правил следует из извлечённых фактов, а не обязательно из рассказа (ограничение PRD, раздел 6).

5 ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ

Состав комплекта – по ЕСПД (ГОСТ 19.101-77), оформление – по ГОСТ 19.106-78, ГОСТ 2.105-95 и ГОСТ 7.32-2017 (поля 30/15/20/20 мм, Times New Roman 14 пт, интервал 1,5).

Таблица 3 – Комплект программной документации

№	Документ	Сокр.	Стандарт
1	Техническое задание	ТЗ	ГОСТ 19.201-78
2	Пояснительная записка	ПЗ	ГОСТ 19.404-79
3	Описание программы	ОП	ГОСТ 19.402-78
4	Руководство оператора	РО	ГОСТ 19.505-79
5	Руководство системного программиста	РСП	ГОСТ 19.503-79
6	Программа и методика испытаний	ПМИ	ГОСТ 19.301-79
7	Описание применения	ОПр	ГОСТ 19.502-78
8	Формуляр	ФО	ГОСТ 19.501-78

Дополнительно в комплект входят README.md (перечень документов) и CHECKLIST.md (соответствие разделов пунктам ГОСТ; что оставлено пустым или не измерено). Исходные материалы – docs/ репозитория; при расхождении приоритет у кода и у отчётов в docs/spike/results/.

6 ТЕХНИКО-ЭКОНОМИЧЕСКИЕ ПОКАЗАТЕЛИ

Экономическая эффективность и затраты на разработку **[Не измерено]**, не оценивались. Эффективность определяется измеримыми показателями качества, приведёнными в Пояснительной записке и в ПМИ. Предполагаемая потребность: один ноутбук с ЦП и офлайн-архив 6,2 ГБ.

7 СТАДИИ И ЭТАПЫ РАЗРАБОТКИ

Таблица 4 – Стадии (по датам из документов репозитория)

Этап	Содержание	Дата / источник
Фаза 0 (спайк)	Замеры скорости LLM, эмбеддингов, поиска; пилот извлечения на 12 фрагментах	22–23.10.2026, docs/spike/REPORT.md
Фаза 1	Поиск, извлечение, граф, правила, MCP, агент, API, веб-интерфейс	до 27.10.2026, docs/STATUS.md
Вычисления на GPU-сервере	Извлечение 596 фрагментов; проход «присутствия» на демонстрационных рассказах	27.10 и 29.10.2026, docs/spike/results/graph-sanity-20261028.md, presence-pass-server-20261029.md
Заморозка и оценка	Оценка dev- и test-срезов; кандидаты rc1–rc4	28–29.10.2026, docs/STATUS.md
Показ	Демонстрация 7 минут	30.10.2026, docs/PRD.md
Открытые задачи	Issues #8–#28 (в т.ч. чистая установка на двух ноутбуках #8, замеры #14, проверка золотых наборов #9, репетиции #15)	GitHub

8 ПОРЯДОК КОНТРОЛЯ И ПРИЁМКИ

Виды испытаний, методы и перечень проверяемых требований – в документе «Программа и методика испытаний» (ПМИ). Критерии приёмки проекта – docs/acceptance/acceptance.md. Приёмку проводит комиссия, состав которой **[Заполнить]**; акт приёмки в комплекте не составлен. Подписанный акт отсутствует и не подразумевается.

ПРИЛОЖЕНИЕ А

(справочное)

Термины и сокращения

Термин	Значение
Чанк (фрагмент)	Абзацно-выровненный фрагмент рассказа с позициями начала и конца в очищенном тексте; всего 596
Якорь (anchor)	Ссылка на дословную цитату: рассказ, чанк, смещения символов, текст
R1	Один человек не может одновременно находиться в двух разных местах
R2	Порядок событий транзитивен и не содержит циклов
R3	Утверждение свидетеля, несовместимое с установленным фактом, – противоречие
extracted / derived / conditional	Метки происхождения: извлечено моделью / выведено правилом / выведено правилом из сомнительного извлечённого факта
curated	Факт, введённый вручную и перепроверенный человеком 29.10.2026 для демонстрационных случаев (`data/curated/`, `docs/spike/results/curated-review-2026-10-29.md`)
MCP	Model Context Protocol – протокол вызова инструментов
SSE	Server-Sent Events – односторонний поток событий сервера
RRF	Reciprocal Rank Fusion – слияние ранжирований
ЕСПД	Единая система программной документации

ПРИЛОЖЕНИЕ Б

(справочное)

Перечень документов репозитория, использованных как источники

- README.md, docs/PRD.md, docs/STATUS.md, docs/HANDOFF.md, docs/DISCLOSURE.md
- docs/architecture/c4.md, docs/adr/0001..0012, docs/symbolic-layer.md, docs/data-schema.md, docs/api.md, docs/mcp-contracts.md
- docs/security.md, docs/test-plan.md, docs/spike/REPORT.md, docs/spike/results/*, docs/perf/*, docs/team/*
- исходный код src/detective_board/, web/, eval/, scripts/, tests/

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

Изм.	**Номера листов (страниц)**			**Всего листов**	**№ докум.**	**Подп.**	**Дата**
	изменённых	замененных	новых				

_____

(наименование организации – заполнить)

УТВЕРЖДАЮ
Должность
_____
_____ / _____
«____» _____ 2026 г.
(поля подписи оставлены пустыми)

ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Локальный офлайн нейро-символический следователь по рассказам о Шерлоке Холмсе

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

к программному комплексу
ГОСТ 19.404-79

Обозначение документа: _____ (присваивается организацией)

Авторы:
Верховых Егор
Стрижевский Андрей
Парамонов Даниил
Приц Артём

Комплект программной документации ЕСПД, документ 2 из 8
Версия комплекса: 0.0.1 (pyproject.toml); состояние репозитория: main, коммит 16122fc
Дата составления: 30.10.2026. Статус: черновик, не согласован

2026

ЛИСТ СОГЛАСОВАНИЯ

Подписи, фамилии и даты не заполнены: документ составлен по состоянию репозитория и не согласован ни с кем.

Роль	Должность	Фамилия И. О.	Подпись	Дата
Разработал				
Проверил				
Нормоконтроль				
Утвердил				

СОДЕРЖАНИЕ

1 ВВЕДЕНИЕ....4
2 НАЗНАЧЕНИЕ И ОБЛАСТЬ ПРИМЕНЕНИЯ....4
3 ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ....5
3.1 Постановка задачи....5
3.2 Описание алгоритма и функционирования....5
3.3 Правила символического слоя....6
3.4 Структура программы....7
3.5 Методы и средства разработки....7
4 ИЗМЕРЕННЫЕ ХАРАКТЕРИСТИКИ....7
4.1 Модели на целевом ноутбуке (спайк)....7
4.2 Поиск....7
4.3 Граф по полному корпусу....8
4.4 Оценка качества агента (eval/run_eval.py)....8
4.5 Правила на автоматическом графе....9
4.6 Проход «присутствия» (кто где когда)....9
4.7 Время и память на целевом ноутбуке....9
4.8 Экспериментальные режимы, не включённые в основной путь....10
5 ОБОСНОВАНИЕ ПРИНЯТЫХ РЕШЕНИЙ....11
6 МЕТКИ ПРОИСХОЖДЕНИЯ И ПРЕДЕЛЫ ЧЕСТНОСТИ....12
7 БЕЗОПАСНОСТЬ....13
8 ЧТО НЕ СДЕЛАНО....14
ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ....15

Документ – черновик: составлен по материалам репозитория и измерениям, лежащим в `docs/spike/results/` и `docs/perf/`; человеком не проверен и никем не согласован. Подписи, должности, даты согласования и обозначение документа оставлены пустыми намеренно.

Условные обозначения статуса сведений в комплекте. [Измерено] – число взято из файла отчёта, путь указан рядом. **[Не измерено]** – измерения нет. **[План]** – описано в проектных документах, в коде отсутствует или выключено. **[Заполнить]** – поле оставлено пустым для человека.

1 ВВЕДЕНИЕ

Пояснительная записка описывает назначение и область применения программного комплекса «Детективная доска» (Detective Board), поставленную задачу, принятые решения и их обоснование, измеренные характеристики и ограничения. Устройство программы подробно изложено в документе «Описание программы» (ОП), порядок работы – в «Руководстве оператора» (РО) и «Руководстве системного программиста» (РСП), проверки – в «Программе и методике испытаний» (ПМИ).

Основание: см. «Техническое задание» (ТЗ), раздел 2. Все числа привязаны к файлам репозитория; числа без указанного файла в документе не приводятся.

2 НАЗНАЧЕНИЕ И ОБЛАСТЬ ПРИМЕНЕНИЯ

Комплекс отвечает на вопросы о 20 рассказах о Шерлоке Холмсе, опираясь только на текст корпуса: каждый ответ содержит дословную цитату, результаты логических проверок получаются детерминированными правилами и сопровождаются объяснением, а при отсутствии опоры в тексте система отказывается отвечать. Применение: учебный проект, демонстрация, исследование границ нейро-символического подхода на небольшом локальном оборудовании.

Не предназначен для: других корпусов, загрузки пользовательских текстов, многопользовательской работы, обучения моделей, вопросов об общих знаниях о Холмсе вне текста (раздел «Не-цели» PRD).

3 ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ

3.1 Постановка задачи

Длинная художественная проза трудно поддаётся опросу: чтобы выяснить, кто не мог находиться на месте происшествия, нужно перечитать десятки рассказов, а обычный чат с языковой моделью выдумывает факты и цитаты (PRD, раздел 1). Требуется агент, который исследует фиксированный корпус, показывает свои доказательства и умеет сказать «в корпусе этого нет».

Ограничения среды: ноутбук без GPU (i7-8665U, 4 ядра, 15 ГиБ), модели не более 8 млрд параметров, работа без сети. Измеренная скорость генерации на этом ноутбуке 4,3–7,7 ток./с в зависимости от модели, время до первого токена 15–30 с для запроса в 300 слов (`docs/spike/REPORT.md`, раздел 3). Следствие: мало вызовов модели на вопрос, короткие запросы, предвычисление графа.

3.2 Описание алгоритма и функционирования

Работа делится на подготовку данных (выполняется заранее) и ответ на вопрос (выполняется при показе).

Подготовка. Рассказы очищаются от служебного текста Проекта Гутенберг и делятся на 596 абзацно-выровненных фрагментов. Языковая модель извлекает из каждого фрагмента сущности (персонаж, место, предмет), события, высказывания и отношения в JSON-схеме, каждое с дословной цитатой; цитата, не найденная в тексте фрагмента как подстрока, отбрасывается. Нормализатор добавляет время и структуру высказываний; результат пишется в граф SQLite. Строятся индекс фрагментов (BM25 + векторы bge-m3) и индекс предложений.

Ответ. Маршрутизатор на правилах определяет тип вопроса. Текстовые вопросы идут через гибридный поиск (BM25 и вектор, слияние RRF) и индекс предложений: модель выбирает номера предложений, а ответ – их дословный текст (извлекающий режим, ADR-0009). Вопросы о противоречиях, алиби и хронологии решаются инструментом MCP `timeline-alibi`, который вызывает правила R1–R3; ответ строится по шаблону без вызова модели (ADR-0010). Перед выдачей проверяется, что каждая цитата – дословная подстрока цитируемого фрагмента; иначе выдаётся отказ с причиной. Все шаги отправляются клиенту потоком событий SSE.

Диаграммы потоков данных приведены в ОП (раздел «Описание логической структуры»), правила R1–R3 – в разделе 3.3 настоящей записки.

3.3 Правила символического слоя

Таблица 1 – Правила R1–R3 (`docs/symbolic-layer.md`, раздел 4)

Правило	Условие нарушения	Что не моделируется
R1 – одно место в одно время	Человек участвует в двух событиях, времена которых определённо пересекаются, а места определённо различны	Время в пути; различие «присутствие / передвижение» в схеме извлечения; нет данных – вердикт «неизвестно», а не «согласовано»
R2 – порядок событий	В отношении «раньше» (из относительных меток и абсолютных времён) возникает цикл (компонента сильной связности > 1 узла или петля)	Рассказ «задом наперёд» (позиция в тексте не является доказательством); дубликаты событий могут давать ложные циклы
R3 – высказывание против факта	Структурированное утверждение свидетеля несовместимо с установленным фактом (событие в голосе рассказчика с высокой уверенностью)	Конфликт двух высказываний (нет авторитета выбора); ненадёжный рассказчик

Результат правила – один из трёх вердиктов: `violated`, `consistent`, `unknown` (с кодом причины и перечнем недостающего); отсутствие факта никогда не даёт `consistent` или `violated`. Метка `conditional` ставится, если хотя бы один из извлечённых входов имеет уверенность `low`. Уверенность вычисляется детерминированно по сигналам конвейера (неоднозначный якорь, приблизительное время, неточное сопоставление имён), а не сообщается моделью.

3.4 Структура программы

Модули и их взаимодействие приведены в ОП (рисунки «Контейнеры» и «Потоки»). Кратко: `extract/` – извлечение и нормализация; `index/` и `retrieval/` – индексы и поиск; `graph/` – хранилище графа; `symbolic/` – правила; `mcp/` – клиент и сервер инструментов; `agent/` – маршрутизатор, режимы ответа, проверки; `api/` – сервер Starlette; `web/` – интерфейс без сборки.

3.5 Методы и средства разработки

Python 3.12, SQLite (FTS5, sqlite-vec 0.1.9), Starlette 1.9.0 и uvicorn 0.54.0, pydantic 2, пакет `mcp` 2.x, Ollama; интерфейс – ES-модули и векторная графика без сборочного этапа (ADR-0005). Инструменты: uv, just, ruff 0.17.1, pyright 1.1.414, pytest 9.1.1 (`pyproject.toml`). Сквозное тестирование с Playwright описано в группе зависимостей `e2e` и по умолчанию не ставится.

4 ИЗМЕРЕННЫЕ ХАРАКТЕРИСТИКИ

Ниже собраны числа из отчётов репозитория. «Золотые» наборы вопросов и случаев размечены автоматически и **не проверены человеком** (issue #9), поэтому все показатели качества – показатели относительно автоматических меток.

4.1 Модели на целевом ноутбуке (спайк)

Таблица 2 – Скорость моделей, 300 слов запроса, до 200 токенов ответа, среднее из 3 прогонов (`docs/spike/REPORT.md`, раздел 3)

Модель	ток./с	TTFT, с	ОЗУ пик, МиБ
qwen3:4b-instruct	7,04	19,46	3195
qwen3:4b	7,07	17,19	3526
gemma3:4b	7,73	15,30	4127
qwen3:8b	4,34	29,49	6033

4.2 Поиск

Гибридный поиск (k=30, веса BM25:вектор 0,5:1) дал hit@5 = 0,97 при 35 вопросах, векторный – 0,89; параметры подобраны на тех же 35 вопросах, оценка завышена, доверительных интервалов нет (`docs/spike/REPORT.md`, раздел 5).

4.3 Граф по полному корпусу

Извлечение выполнено на GPU-сервере кафедры (RTX 4070, Ollama 0.40.11, qwen3:4b, промпт extract-2.1, схема v2, temperature 0, seed 42): 596 из 596 фрагментов, 20 из 20 рассказов, около 3,2 с на фрагмент при 4 потоках (на ноутбуке 180–250 с). Сохранено элементов 8663, отброшено 125 (дубликаты 14, цитата не найдена 111). Граф: 2157 высказываний, 1698 событий, 743 персонажа, 631 место, 49 предметов (`docs/spike/results/graph-sanity-20261028.md`).

Доля событий с текстом времени 19,3 %, с нормализованным временем 52,5 %, с днём рассказа 4,5 %; доля высказываний со структурированным утверждением о присутствии 0,7 % (там же). Это главная причина, по которой правила почти ничего не находят на автоматическом графе.

4.4 Оценка качества агента (eval/run_eval.py)

Таблица 3 – Доля «поведение корректно» (ответ на отвечаемый вопрос с покрытием ключевых фактов ≥ 0,5; отказ на внекорпусный вопрос); механический критерий без LLM-судьи

Срез	Голая модель	Только вектор	Агент (hybrid+graph)	Файл
dev (n=34)	4/34	15/34	12/34	`docs/spike/results/eval-2026-10-28-dev-ab945e8-78b3bbb3f2a6-145202-rescored.md`
test (n=30), один прогон на `7b7b197`	3/30	11/30	13/30 (43 %, ДИ 27–61 %)	`docs/spike/results/eval-2026-10-28-test-7b7b197-7857839ed9be-175321.md`

На dev-срезе агент не лучше векторного поиска (12/34 против 15/34); его преимущество – полнота извлечения фрагмента recall@4 (21/27 против 18/27) и отказы. На test-срезе агент лучше голой модели (точный критерий Макнемара p = 0,006) и статистически не отличим от векторного поиска (2 против 0, p = 0,5). Конфигурация vector+rerank не запускалась: локального реранкера нет.

Таблица 4 – Отказы и цитаты на test-срезе (`eval-2026-10-28-test-7b7b197-...-175321.md`)

Показатель	Векторный	Агент
Полнота отказов	6/6	6/6

Показатель	Векторный	Агент
Точность отказов	6/12	6/12
Доля ложных отказов	6/24	6/24
Ответ, все цитаты верны	6/18	7/18
Предложение-цитата попало в золотую цитату	7/18	11/18

4.5 Правила на автоматическом графе

Контрольный набор `eval/golden/contradictions.jsonl`: на test-срезе (20 случаев) найдено 0 из 12 положительных, ложных срабатываний 0 из 8 контрольных; на dev-срезе 0 из 14 и 0 из 9 (файлы `eval-2026-10-28-*`). На всех 20 рассказах правила нашли единственное противоречие – курируемый случай Wisteria Lodge (`docs/spike/results/graph-sanity-20261028.md`). Вывод: правила детерминированы, но подходящих фактов в автоматическом графе практически нет.

4.6 Проход «присутствия» (кто где когда)

Таблица 5 – Воронка прохода на 159 фрагментах демонстрационных рассказов (`docs/spike/results/presence-pass-server-20261029.md`)

Этап	qwen3:8b	qwen3:4b-instruct
Факты от модели	537	587
После проверки цитат и полей	101	122
После голосования (2 из 3)	103	103
После верификатора (оставлено)	16	7
Фрагментов с хотя бы одним фактом	14 из 159	6 из 159

Эталон прохода содержит лишь 4 строгих факта (20 в широком наборе), поэтому оценки точности (4b-instruct: 1,0 по 3 оценённым предсказаниям; 8b: ни один из 16 не совпал с эталоном) не поддерживают никаких выводов о качестве. Извлечение присутствия слабое: оставлено 16 и 7 фактов на 159 фрагментах; ни один оставленный факт не несёт дня рассказа.

4.7 Время и память на целевом ноутбуке

18 различных отвечаемых вопросов dev-среза, три серии по 6: медиана 28,4 с по 16 отвеченным (диапазон 18,6–44,1 с; 90-й процентиль 33,8 с), холодный старт 44,1 с, пик памяти всех процессов llama-server 6289 МБ, температура до 100 °C. Замер выполнен **не в чистом окне** (параллельно

работали VPN, Docker, рабочий стол), оценка – верхняя; профиль 8 ГБ не проверялся (docs/perf/laptop-20261029.md).

4.8 Экспериментальные режимы, не включённые в основной путь

– Угадывание виновного (матрица подозреваемых, экспериментальный код src/detective_board/suspects/, eval/suspects/; отчёты docs/spike/results/suspects-20261030.md и suspects-prereg-heldout-20261030.md). Тестовый срез основного корпуса (8 рассказов, замороженный протокол, один прогон): ни один метод не превзошёл простые базовые приёмы. Dev (8 рассказов) – исследовательский: лучший из примерно 35 вариантов, парный турнир на qwen3:14b, назвал виновного первым в 4 случаях из 8; цифра завышена, так как метод отбирался на этих же рассказах. На 6 новых рассказах (Честертон, «Father Brown», протокол заморожен до прогона, один запуск) тот же метод назвал виновного первым в 2 случаях из 6 – как и базовая «самый упоминаемый» (2 из 6); интервал Уилсона 0,10–0,70; один оправданный назван первым. Метки (виновный, оправданные, место обрезки текста) расставлены автоматически, нужна проверка человеком. Вывод: система не угадывает развязку надёжно; «не обвиняет невиновного» выполняется лишь ценой отказов отвечать.

– Тест «до раскрытия» (eval/pre_reveal.py, 16 вопросов, 8 рассказов): виновник назван 2/16 при полном корпусе, 0/16 при корпусе, обрезанном перед раскрытием, 1/16 у голой модели; различия статистически не значимы (docs/spike/results/pre-reveal-2026-10-28-rescored.md).

– Семантический R3 (модельная проверка пар высказываний, `AgentConfig.semantic_r3`, по умолчанию выключен): на dev строгая полнота 1/14, ложных срабатываний на контролях 8/9

(docs/spike/results/r3-semantic-dev-judge-r3j2.md). В демонстрации не показывается.

– Более ранний вариант `exp/entity-answer` (выбор сущности) признан небезопасным (docs/spike/results/entity-answer-2026-10-29.md); он не слит.

5 ОБОСНОВАНИЕ ПРИНЯТЫХ РЕШЕНИЙ

Решения зафиксированы в ADR (docs/adr/). Таблица приводит статус «как записано в документе»; часть записей предшествует реализации и могла устареть.

Таблица 6 – Архитектурные решения

ADR	Решение	Статус в ADR
0001	Монорепозиторий, Python 3.12, uv, just, ruff, проверка типов	Принято (монорепо, Python, uv, just, ruff); проверка типов – предложено
0002	Хранилище: SQLite FTS5 + sqlite-vec; граф – SQLite, Ladybug отложен	Принято
0003	MCP-серверы и SDK `mcp` 2.x	Предложено (дизайн); реализация есть
0004	Символический слой: обычные функции Python над представлением фактов, без Datalog/ASP	Предложено; реализовано в `symbolic/`
0005	Starlette + uvicorn, поток SSE, статический UI	Принято
0006	Модель эмбеддингов bge-m3	Принято
0007	Модель извлечения	Предложено
0008	Модель ответов qwen3:4b-instruct (n=12, средняя-низкая уверенность)	Принято 23.10.2026
0009	Извлекающие ответы: модель выбирает предложения	Принято 27.10.2026 (пилот n=12, один прогон)
0010	Ответы «правила сначала» и охрана честности	Принято 27.10.2026
0011	Целевой проход присутствия и курируемые факты	Курируемые факты – принято; автоматический проход – предложено (точность не измерена)
0012	Универсальный промпт extract-2.1 + детерминированный ремонт	Принято 26.10.2026

Почему правила написаны на обычном Python (ADR-0004): детерминизм, объяснимость (код правила сам строит объект `Explanation` с цитатами), тестируемость на мини-графах, ноль зависимостей. Почему извлекающие ответы (ADR-0009): генерация на ноутбуке давала 45–140 с на вопрос, а 4B-модель отказывалась отвечать даже при наличии ответа в

запросе; выбор номеров предложений даёт 8–20 с в пилоте и дословный текст ответа.

6 МЕТКИ ПРОИСХОЖДЕНИЯ И ПРЕДЕЛЫ ЧЕСТНОСТИ

Таблица 7 – Метки происхождения

Метка	Кем создана	Свойство
extracted	модель (и детерминированная постобработка)	вероятностная; несёт уверенность high/low и якорь с цитатой
derived	правило R1–R3	детерминированная; несёт объяснение: правило, факты, рёбра, цитаты
conditional	правило	выведено из сомнительного (low) извлечённого факта; в ответе формулируется как «если факт F верен, то…»
source_text	извлекающий ответ	дословные предложения корпуса, выбранные моделью
curated	человек (пометка к факту)	введён вручную и перепроверен человеком 29.10.2026 для демонстрационных случаев; в экране, панели «Почему» и ответе назван «curated»

Главное ограничение. Ошибки извлечения проходят в символический слой без изменений: правила точны на графе, который им дан, но не обязательно на рассказе. Неверно извлечённое время, место или говорящий дадут ошибочный, но хорошо объяснённый вывод. Поэтому каждая цитата входа показана, а выводы на сомнительных входах помечены `conditional`. Система утверждает только, что вывод следует из названных фактов.

– Пустой результат правил не означает «противоречий нет»: ответ говорит о покрытии и цитирует текст (охрана честности, ADR-0010).

– Демонстрационные находки (Wisteria Lodge, Abbey Grange R1; контроль Boscombe Valley) построены на восьми **курируемых** фактах (`data/curated/presence_demo.jsonl`), введённых вручную и перепроверенных человеком 29.10.2026 (`docs/spike/results/curated-review-2026-10-29.md`); для Abbey Grange время относительное, поэтому вывод всегда

`conditional`. Показывают, что делают правила на верных фактах, а не что находит модель (`docs/DISCLOSURE.md`).

– Цитата проверяется на дословное вхождение в цитируемый фрагмент, но не на то, что она поддерживает утверждение (`docs/security.md`, 1.5); добавлена проверка пересечения содержательных слов (порог 0,3, предварительный).
– Золотые наборы (64 вопроса, 43 случая противоречий, 12 фрагментов извлечения) размечены автоматически; проверка человеком не выполнена.
– Вычисления на GPU-сервере: извлечение графа, проход присутствия, часть оценок; на показе их нет. Разрешение организаторов – по сообщению руководителя команды от 26.10.2026; письменный ответ к раскрытию не приложен (`docs/DISCLOSURE.md`).

7 БЕЗОПАСНОСТЬ

Обзор безопасности выполнен 23.10.2026 (`docs/security.md`), по коду без запуска моделей. Выводы по группам угроз: внедрение инструкций из корпуса – модель не выбирает маршрут и аргументы инструментов (код), корпус передаётся в ограждённых блоках; найдены проблемы средней важности – неограждённые поля в запросе и проверка цитат только на дословность. Песочница чтения файлов MCP – в порядке; серверы filesystem/fetch не подключены. API: привязка к loopback, проверка Host и Origin, заголовки CSP и X-Frame-Options. SQL-инъекции, pickle/eval – не выявлены. Таблица статусов в отчёте содержит пометки «исправлено, не закоммичено» на момент обзора; актуальное состояние исправлений нужно проверять по коду и тестам (`tests/api/test_hardening.py`, `tests/mcp/test_hardening.py`, `tests/agent/test_security.py`). Открытыми на момент отчёта остались: извлечение-время внедрение (не

изучено глубоко), неограниченная привязка к не-loopback адресам (только предупреждение), проверка контрольных сумм корпуса и vendor-файлов.

8 ЧТО НЕ СДЕЛАНО

– Чистая установка из офлайн-архива на двух разных ноутбуках (issue #8): проверена одна машина (`docs/perf/clean-install-20261029.md`).
– Замеры задержки в чистом окне с повторами и профиль 8 ГБ (issue #14).
– Проверка золотых наборов человеком (issue #9).
– Точность автоматического прохода присутствия не доказана; расширение числа курируемых случаев не планировалось в документах.
– Реранкер, фильтрация серверов filesystem/fetch, сервер заметок `evidence-notes`, не реализованы.
– Репетиции показа с финальным кодом (issue #15).

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

Изм.	**Номера листов (страниц)**			**Всего листов**	**№ докум.**	**Подп.**	**Дата**
	изменённых	замененных	новых				

_____

(наименование организации – заполнить)

УТВЕРЖДАЮ
Должность
_____
_____ / _____
«____» _____ 2026 г.
(поля подписи оставлены пустыми)

ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Локальный офлайн нейро-символический следователь по рассказам о Шерлоке Холмсе

ОПИСАНИЕ ПРОГРАММЫ

программного комплекса
ГОСТ 19.402-78

Обозначение документа: _____ (присваивается организацией)

Авторы:
Верховых Егор
Стрижевский Андрей
Парамонов Даниил
Приц Артём

Комплект программной документации ЕСПД, документ 3 из 8
Версия комплекса: 0.0.1 (pyproject.toml); состояние репозитория: main, коммит 16122fc
Дата составления: 30.10.2026. Статус: черновик, не согласован

2026

ЛИСТ СОГЛАСОВАНИЯ

Подписи, фамилии и даты не заполнены: документ составлен по состоянию репозитория и не согласован ни с кем.

Роль	Должность	Фамилия И. О.	Подпись	Дата
Разработал				
Проверил				
Нормоконтроль				
Утвердил				

СОДЕРЖАНИЕ

1 ОБЩИЕ СВЕДЕНИЯ....4
2 ФУНКЦИОНАЛЬНОЕ НАЗНАЧЕНИЕ....4
3 ОПИСАНИЕ ЛОГИЧЕСКОЙ СТРУКТУРЫ....5
3.1 Архитектура: контекст и контейнеры....5
3.2 Модули программы....7
3.3 Поток подготовки данных....8
3.4 Поток обработки вопроса....9
3.5 Модель данных....10
3.6 Символический слой: правила R1–R3 и метки....12
3.7 MCP-контракт....13
3.8 HTTP-интерфейс....15
3.9 Веб-интерфейс....15
4 ИСПОЛЬЗУЕМЫЕ ТЕХНИЧЕСКИЕ СРЕДСТВА....16
5 ВЫЗОВ И ЗАГРУЗКА....16
6 ВХОДНЫЕ ДАННЫЕ....17
7 ВЫХОДНЫЕ ДАННЫЕ....17
ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ....18

Документ – черновик: составлен по материалам репозитория и измерениям, лежащим в `docs/spike/results/` и `docs/perf/`; человеком не проверен и никем не согласован. Подписи, должности, даты согласования и обозначение документа оставлены пустыми намеренно.

Условные обозначения статуса сведений в комплекте. [Измерено] – число взято из файла отчёта, путь указан рядом. **[Не измерено]** – измерения нет. **[План]** – описано в проектных документах, в коде отсутствует или выключено. **[Заполнить]** – поле оставлено пустым для человека.

1 ОБЩИЕ СВЕДЕНИЯ

Таблица 1 – Сведения о программе

Параметр	Значение
Обозначение	Detective Board, версия 0.0.1 (`pyproject.toml`); репозиторий `AndrewStrizhevskiy/detective-board`
Языки реализации	Python 3.12 (ядро, сервер, правила, конвейер), JavaScript ES-модули (интерфейс `web/`), shell (скрипты `scripts/`)
Необходимое программное обеспечение	uv, just, Ollama с моделями bge-m3, qwen3:4b-instruct, qwen3:4b; SQLite с FTS5; современный браузер
Библиотеки (`pyproject.toml`)	pydantic >=2.9,<3; sqlite-vec 0.1.9; mcp >=2.3,<3; starlette 1.9.0; uvicorn 0.54.0
Состав	8 подпакетов `src/detective_board/` (agent, api, extract, graph, index, mcp, retrieval, symbolic); тесты: 67 файлов `test_*.py` в `tests/` и тесты интерфейса в `tests/web_js/`

2 ФУНКЦИОНАЛЬНОЕ НАЗНАЧЕНИЕ

Программа отвечает на вопросы по корпусу из 20 рассказов о Шерлоке Холмсе дословными цитатами, находит противоречия и проверяет алиби детерминированными правилами R1–R3, отказывается отвечать при отсутствии опоры в тексте и показывает ход расследования (граф фактов, трассу шагов, объяснения выводов). Классы решаемых задач: поиск по тексту (факт, цитата, кто сказал); вопросы о связях сущностей; хронология; алиби и таблица присутствия; противоречия; доска исключения по алиби для сцены преступления.

3 ОПИСАНИЕ ЛОГИЧЕСКОЙ СТРУКТУРЫ

3.1 Архитектура: контекст и контейнеры

Исходные описания – `docs/architecture/c4.md` (диаграммы Mermaid, раздел «Статус: черновик, фаза 0»). Диаграммы перерисованы в Graphviz и приведены к реализованному состоянию: граф хранится в SQLite (Ladybug не используется, ADR-0002), фреймворк интерфейса – без сборки, API – Starlette, символический слой реализован. Исходники диаграмм – `docs/gost/diagrams/*.dot`.

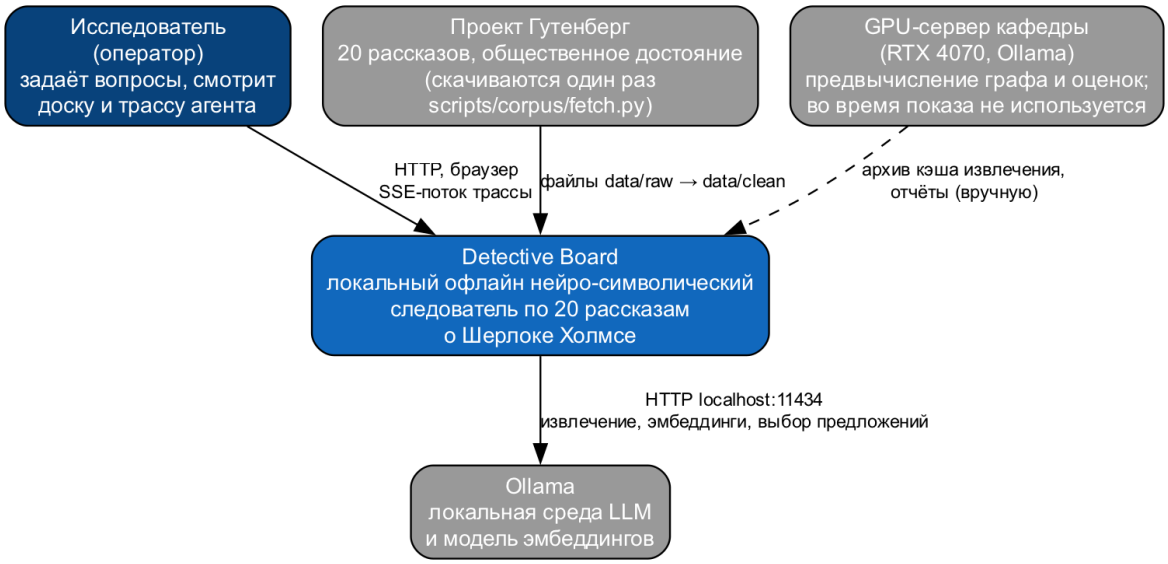


Рисунок 1 – Системный контекст (C4, уровень 1)

Система работает на одной машине. Внешние участники: исследователь (оператор) работает в браузере; Ollama предоставляет локальные модели; корпус загружается с Проекта Гутенберг один раз; GPU-сервер используется только для предварительных вычислений и во время работы системы не нужен.

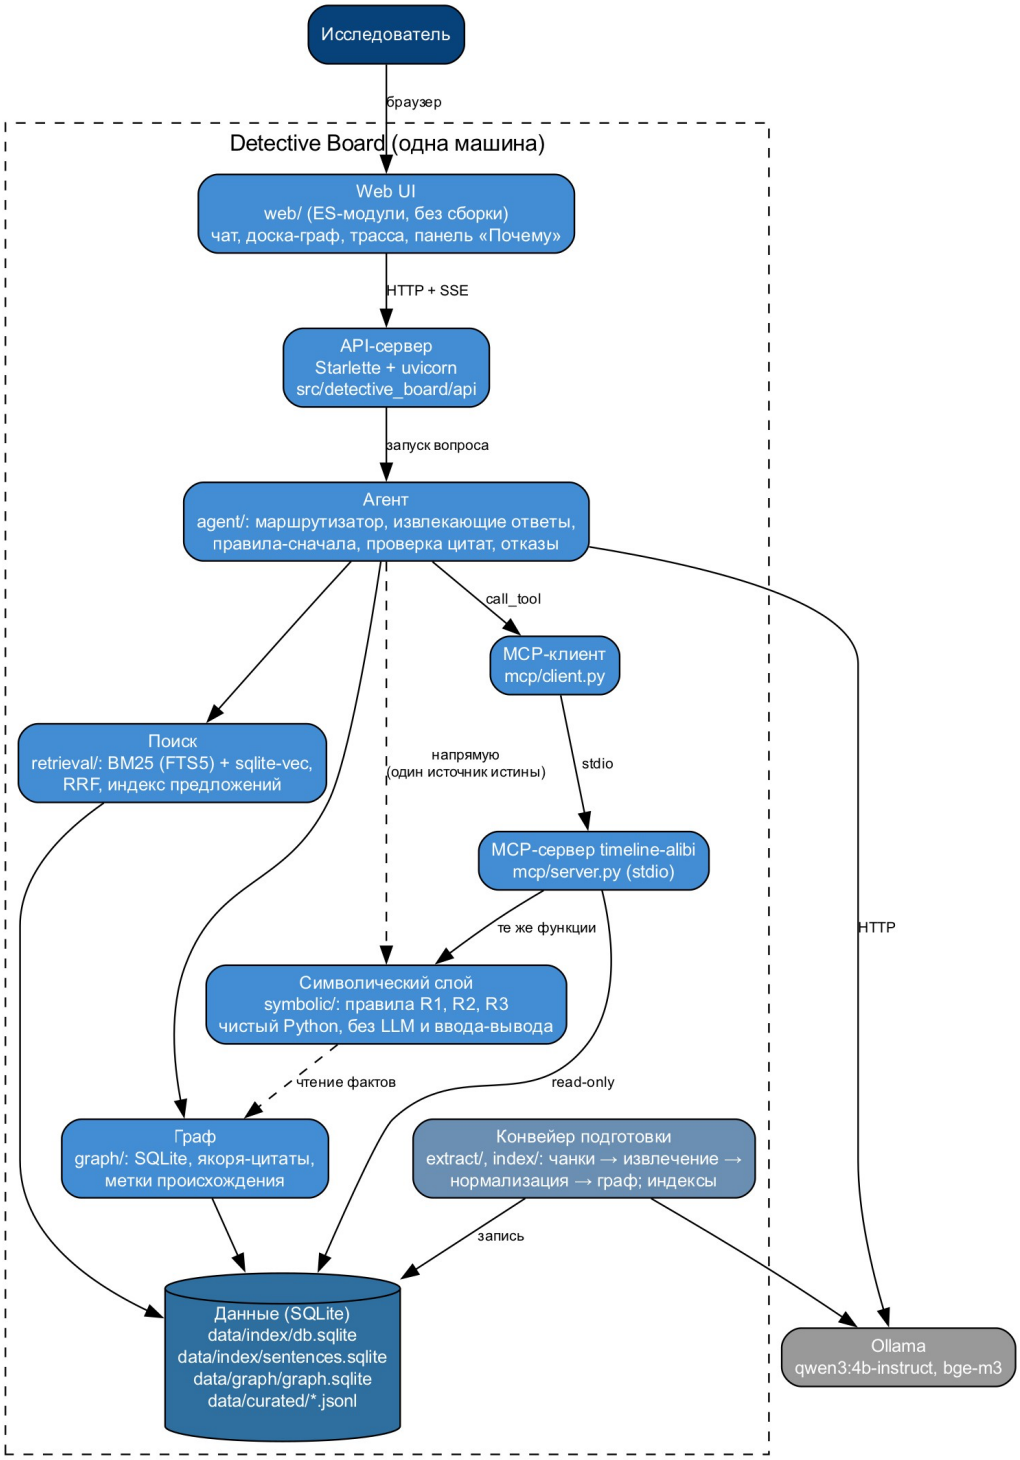


Рисунок 2 – Контейнеры и модули (C4, уровень 2)

Агент и MCP-сервер `timeline-alibi` вызывают одни и те же функции модуля `symbolic/` – результат правила не зависит от пути вызова. MCP-сервер открывает граф только на чтение.

3.2 Модули программы

Таблица 2 – Каталоги `src/detective_board/`

Модуль	Назначение	Ключевые файлы
`extract/`	Схема извлечения, привязка цитат (`ground.py`), ремонт полей (`repair.py`), нормализация времени и высказываний (`normalise.py`), проход присутствия (`presence*.py`), курируемые факты (`curated.py`), сцены (`scenes.py`), кэш (`cache.py`)	`pipeline.py`, `schema_v2.py`, `run.py`
`index/`	Сборка индекса фрагментов и индекса предложений	`build.py`, `sentences.py`
`retrieval/`	Эмбеддинги, поиск BM25 + вектор, слияние RRF, индекс предложений	`search.py`, `store.py`, `sentences.py`, `rerank.py` (заглушка)
`graph/`	Хранилище графа SQLite, якоря, нормализация, источник фактов для правил	`schema.py`, `store.py`, `facts_source.py`, `timenorm.py`
`symbolic/`	Правила R1–R3, модель фактов и результатов, время, места, объяснения	`rules/ r1_presence.py`, `r2_order.py`, `r3_claims.py`, `api.py`
`mcp/`	Клиент и сервер MCP, песочница файлов, ошибки	`server.py`, `client.py`, `tools.py`, `sandbox.py`
`agent/`	Маршрутизатор, контекст запроса, извлекающие ответы, ответы «правила сначала», охрана честности, перевод вопроса, память, события	`router.py`, `agent.py`, `extractive.py`, `rule_first.py`, `honesty.py`, `events.py`
`api/`	HTTP-сервер: SSE-ответ, граф, источники, состояние; конфигурация; прогрев	`app.py`, `config.py`, `services.py`, `sse.py`

3.3 Поток подготовки данных

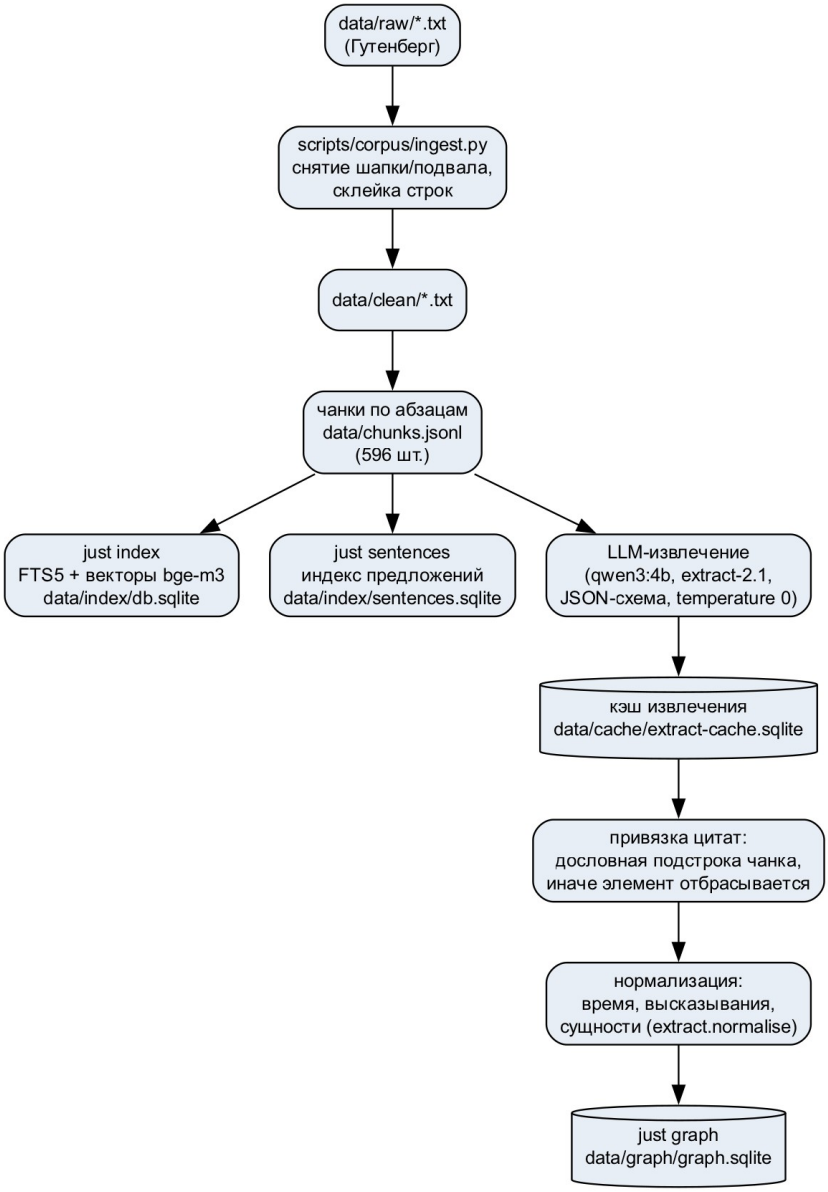


Рисунок 3 – Подготовка данных (выполняется заранее)

Идемпотентность: результат извлечения кэшируется по ключу, в который входят текст фрагмента, тег модели, версия промпта, версия схемы и параметры (`docs/team/models.md`); повторный запуск не вызывает модель. Элемент извлечения, чья цитата не является точной подстрокой фрагмента, отбрасывается и учитывается в таблице `g_dropped`.

3.4 Поток обработки вопроса

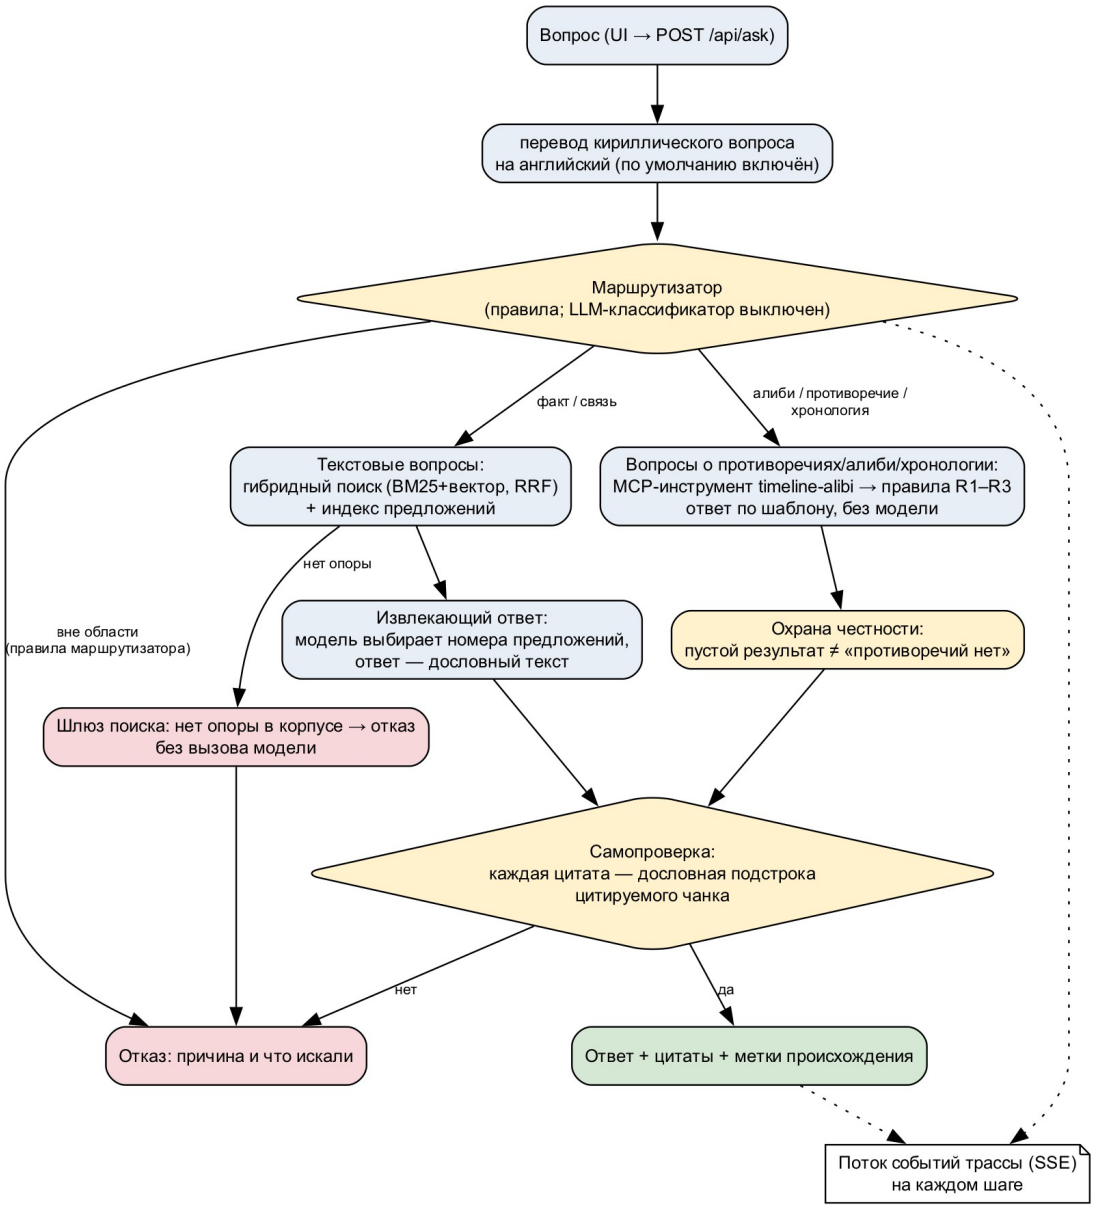


Рисунок 4 – Обработка вопроса агентом

Маршрутизатор – детерминированные регулярные выражения (внекорпусные темы, алиби, противоречия, связи, хронология, таблица присутствия, вопросы о сцене); LLM-классификатор по умолчанию выключен (`use_llm_router = false`) и в любом случае не выбирает инструмент и аргументы. Модель влияет только на формулировку и на выбор номеров предложений.

Таблица 3 – Режимы ответа (`AgentConfig`, `docs/api.md`)

Режим	Когда	Что делает модель
Извлекающий (`answer_mode = extractive`, по умолчанию)	Текстовые вопросы: факт, связь, текстовая часть вопросов об алиби/противоречиях	Выбирает 1–2 номера предложений (JSON с ограничением); ответ – их дословный текст, метка `source_text`; при выборе NONE – отказ
Правила сначала (`rule_first = true`)	Противоречия, алиби, хронология, таблица присутствия, доска сцены	Не вызывается: ответ – шаблон над результатом инструмента; пустой результат даёт честную фразу о покрытии
Генеративный (`answer_mode = generate`)	Только для сравнения (A/B)	Пишет текст ответа с цитатами; самопроверка цитат
Отказ	Нет опоры (шлюз: `min_score` 0,018, `min_support` 0,25), внекорпусная тема, не пройдена проверка цитат	Не вызывается при отказе шлюза

3.5 Модель данных

Граф хранится в одном файле SQLite (`data/graph/graph.sqlite`, схема в `src/detective_board/graph/schema.py`, версия построения 3). Узлы: персонаж, место, предмет, событие, высказывание. Каждое ребро и каждый узел события или высказывания несёт якорь – фрагмент, смещения и дословную цитату; сущности привязаны к тексту через таблицу упоминаний.

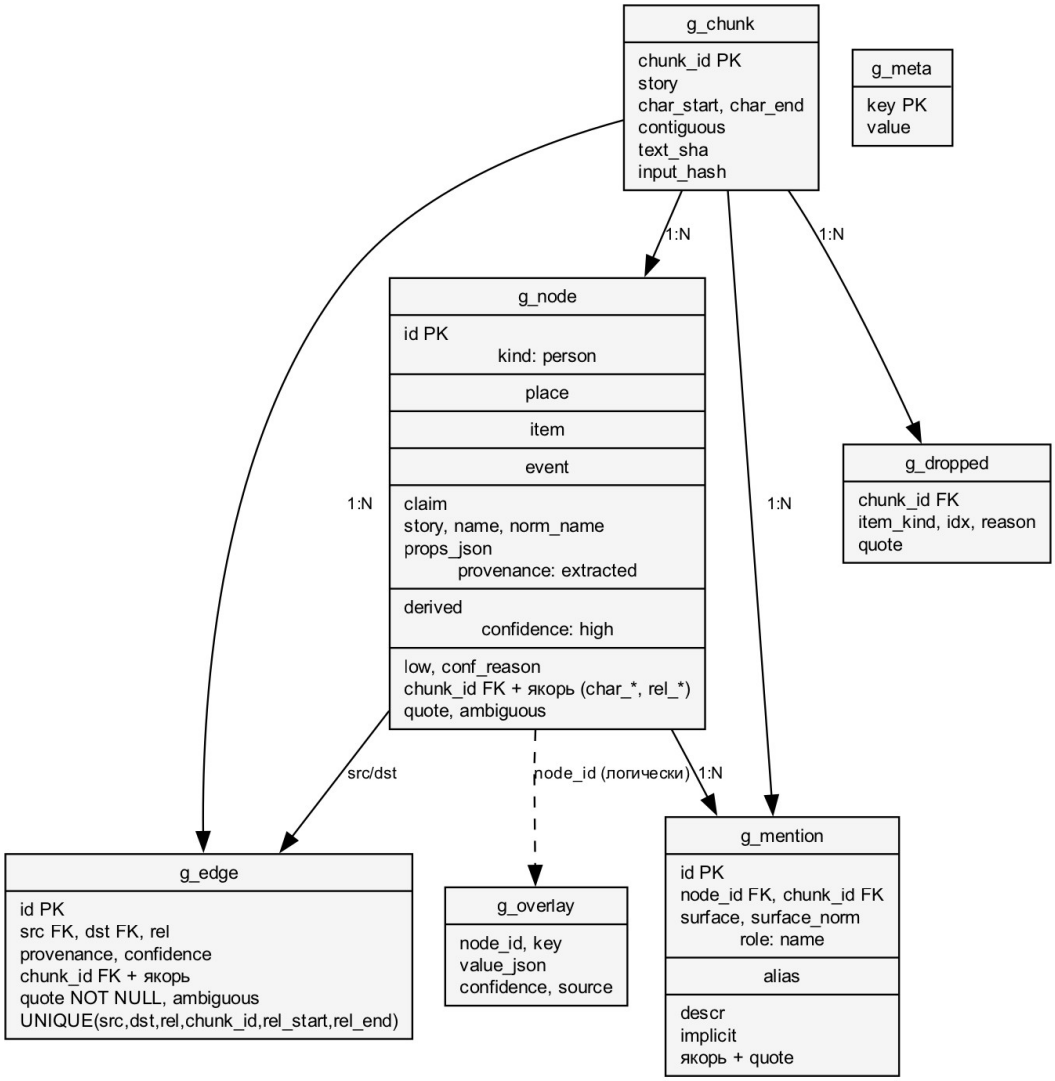


Рисунок 5 – Схема данных графа (SQLite)

Таблица 4 – Таблицы графа

Таблица	Поля и ограничения
`g_chunk`	`chunk_id` PK, `story`, `char_start`, `char_end`, `contiguous`, `text_sha`, `input_hash` (хэш текста, извлечения и версий построения)
`g_node`	`id` PK; `kind` ∈ {person, place, item, event, claim}; `story`, `name`, `norm_name`, `unnamed`; `props_json`; `provenance` ∈ {extracted, derived}; `confidence` ∈ {high, low}, `conf_reason`; якорь (`chunk_id`, `char_*`, `rel_*`, `quote`, `ambiguous`) для событий и высказываний
`g_edge`	`src`, `dst` → `g_node`; `rel`; `props_json`; `provenance`, `confidence`; якорь и `quote` NOT NULL; уникальность (`src, dst, rel, chunk_id, rel_start, rel_end`)
`g_mention`	поверхностные формы сущности во фрагменте: `surface`, `surface_norm`, `role` ∈ {name, alias, descr}, `implicit`, якорь
`g_dropped`	аудит отброшенных элементов: `item_kind`, `idx`, `reason`, `quote`
`g_overlay`	результаты нормализатора и ручные уточнения, переживающие пересборку: день рассказа, структура высказывания; `confidence`, `source`
`g_meta`	служебные пары ключ–значение

Таблица 5 – Индексы поиска

Файл	Таблицы
`data/index/db.sqlite`	`chunks` (текст и позиции), `chunks_fts` (FTS5, токенайзер porter unicode61), `chunk_vec` (vec0, 1024 измерения, bge-m3), `index_manifest`
`data/index/sentences.sqlite`	`sent` (предложения, смещения внутри фрагмента), `sent_fts`, `sent_vec` (vec0 float[1024], косинус), `sent_manifest`; в рассматриваемом графе 11 018 предложений
`data/cache/extract-cache.sqlite`	кэш извлечения (ключ → ответ модели)
`data/curated/presence_demo.jsonl`, `scenes.jsonl`	курируемые факты присутствия (8 записей) и сцены преступлений (1 сцена)

Примечание: в `docs/data-schema.md` часть описаний помечена «[P]» (предварительно) и описывает проект; фактической схемой считается код `schema.py`, `retrieval/store.py`, `retrieval/sentences.py`.

3.6 Символический слой: правила R1–R3 и метки

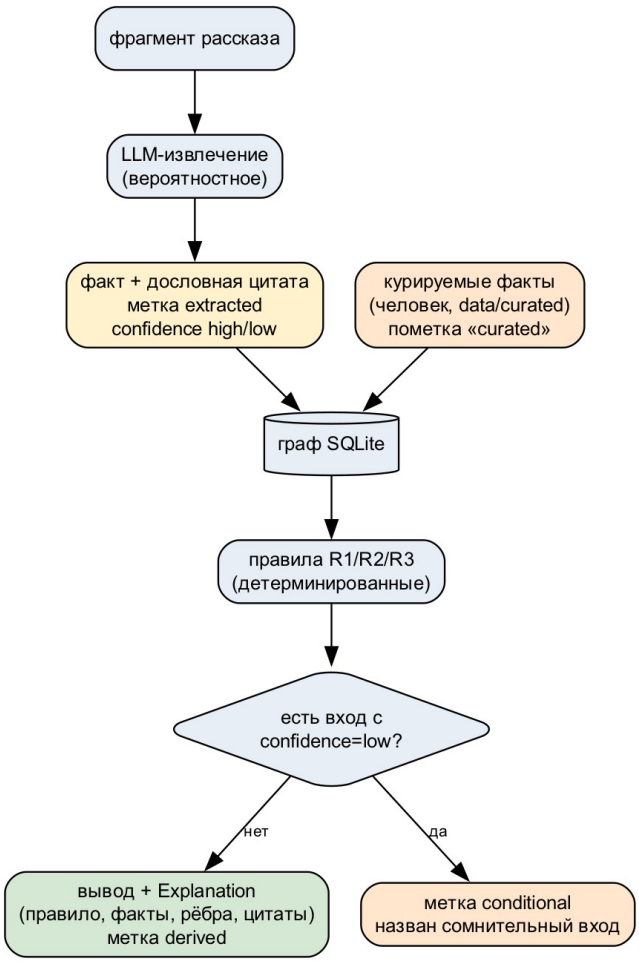


Рисунок 6 – Происхождение утверждений и метки

Таблица 6 – Правила

Правило	Определение	Файл
R1	Для человека p события e1 ≠ e2 с различными местами и определённо пересекающимися интервалами – `violated`; определённо непересекающиеся интервалы или совместимые места – `consistent`; иначе `unknown` с причиной (`PLACE_UNRESOLVED`, `TIME_UNDECIDED`, …). Режимы: `scan_presence_conflicts`, `check_presence` (алиби)	`symbolic/rules/r1_presence.py`
R2	Граф «раньше» из относительных меток (`after`/`before`) и абсолютных времён; транзитивное замыкание; цикл (компонента сильной связности) – `violated`; пара без пути – `unknown` (`NO_PATH`). Функции: `find_order_cycles`, `order_of`, `timeline`	`symbolic/rules/r2_order.py`
R3	Структурированное утверждение (о присутствии или порядке) против установленного факта: событие в голосе рассказчика, уверенность high. Несовместимость – `violated` (`claim_incompatible_with_fact`), без обвинения свидетеля во лжи; неструктурированное утверждение – `unknown`	`symbolic/rules/r3_claims.py`

Перекрытие интервалов: для непрерывных – полуоткрытые (касание не перекрытие), если один из интервалов – момент, то замкнутые. Определённое перекрытие требует точного времени и известного дня; относительное время («на следующее утро») может доказать непересечение разных дней, но не определённое перекрытие. Время в пути между местами не моделируется. Совместимость мест определяется таблицей алиасов и отношением «содержит», а не сходством строк (`docs/symbolic-layer.md`, разделы 4–5).

Объект объяснения (`Explanation`) содержит: идентификатор и версию правила, вердикт, признак `conditional`, код причины, субъект, использованные факты и рёбра (каждый с якорем и цитатой), шаги вывода, множество зависимых извлечённых фактов, слабые факты (`weak`), недостающее (`missing`) и примечания. Нарушение без якоря – ошибка (инвариант документа `docs/symbolic-layer.md`, раздел 3.1).

3.7 MCP-контракт

Собственный сервер `timeline-alibi` (stdio, `src/detective_board/mcp/server.py`) строится на SDK `mcp` и содержит

шесть инструментов; контракт – docs/mcp-contracts.md. Агент вызывает их через mcp/client.py (белый список, тайм-ауты, отображение ошибок).

Таблица 7 – Инструменты сервера timeline-alibi

Инструмент	Вход (основное)	Выход (основное)
build_timeline	story, person_id?, place_id?, include_undated, limit ≤ 200	status ok / insufficient_evidence; события с интервалом, местом, участниками, якорями; undated_count, total_events, curated
check_alibi	story, person_id, window, claimed_place_id?	status supported / contradicted / unknown / insufficient_evidence; свидетельства; provenance derived / conditional; explanation (R1)
find_overlaps	story, person_ids ≤ 10, same_place_only, window?, limit ≤ 100	пары пересекающихся событий с якорями, provenance, explanation (R1)
find_contradictions	story, person_id?, rules? (R1/R2/R3), limit	findings (правило, provenance, explanation, якоря); пустой список с ok ≠ «согласовано»
presence_table	story, person_id, names?, limit ≤ 100	строки «где, по чьим словам, цитата», утверждение или отрицание; конфликты R1
scene_board	story, place, window, person_ids?, victim_ids?, limit ≤ 50	статусы persons: excluded / placed / not_excluded; счётчики; без суждения о виновности

Модель ошибок: домены возвращают обычный результат со статусом; сбои протокола и проверки – объект {error: {code, message, retriable, details}}, коды invalid_input, not_found, ambiguous, insufficient_evidence, timeout, store_unavailable, internal (docs/mcp-contracts.md, раздел 5). Серверный предел времени вызова – 4 с (DeadlineRunner; DETECTIVE_BOARD_TOOL_DEADLINE_S); значения лимитов в контракте помечены как предварительные. Пути чтения файлов ограничены песочницей mcp/sandbox.py.

Планировавшийся сервер заметок evidence-notes и готовые серверы filesystem/fetch в реализации отсутствуют.

3.8 HTTP-интерфейс

Таблица 8 – Маршруты (src/detective_board/api/app.py, docs/api.md)

Маршрут	Назначение
`POST /api/ask`	Запуск вопроса; ответ `text/event-stream`, по одному событию на шаг; тело JSON ≤ 16 КиБ, вопрос 1–1000 символов, история ≤ 6 пар; второй одновременный запуск – `429 busy`
`GET /api/graph/subgraph`	Окрестность сущности (0–3 шага, ≤ 200 узлов) с якорями и объяснениями производных рёбер
`GET /api/graph/entities`	Поиск сущностей для подсказок
`GET /api/source/{chunk_id}`	Текст фрагмента с подсветкой цитаты (идентификатор проверяется по шаблону, путь к файлу не используется)
`GET /api/health`	Состояние: Ollama, модели, индекс, граф, MCP, прогрев
`GET /api/config`	Эффективные несекретные настройки и перечень событий
`/` (статика)	Интерфейс из `web/`

События SSE (`agent/events.py`): `query_translated`, `route_decided`, `retrieval_started`, `retrieval_results`, `graph_query`, `graph_results`, `tool_call`, `tool_result`, `enriched_query`, `answer_token`, `citation_check`, `refusal`, `final`; при сбое вместо `final` приходит `run_error` с кодом `internal`, `unavailable` или `timeout`. Итоговое событие содержит статус (`answered`, `partial`, `refused`), признак `verified`, ответ, цитаты с якорями и метки происхождения.

3.9 Веб-интерфейс

Статические файлы `web/` (ES-модули `app.js`, `graph.js`, `trace.js`, `replay.js`, `demo.js` и др., библиотеки в web/vendor/): строка вопроса и подсказки, панель трассы шагов, доска-граф с карточками сущностей и нитями, панель ответа с цитатами и меткой происхождения, панель «Почему» с объяснением правила, режимы «Записи» и демонстрационные подсказки. Записи прогонов (`web/replay/*.json`) в интерфейсе помечены как записи, а не живой прогон. Горячие клавиши: `/` – фокус на вопрос, `g` – список вместо графа, `c` – сохранённый прогон, `t` – последнее событие трассы, `Esc` – сброс. Подробно – в «Руководстве оператора» (РО).

4 ИСПОЛЬЗУЕМЫЕ ТЕХНИЧЕСКИЕ СРЕДСТВА

Целевое: ноутбук ThinkPad X1 Carbon 7 поколения (i7-8665U, 4 ядра, 15 ГиБ ОЗУ, без GPU), Linux x86_64. Для предварительных вычислений использовался сервер кафедры (i7-12700K, 96 ГБ, RTX 4070 12 ГБ). Развёртывание показано на рисунке «Схема развёртывания».

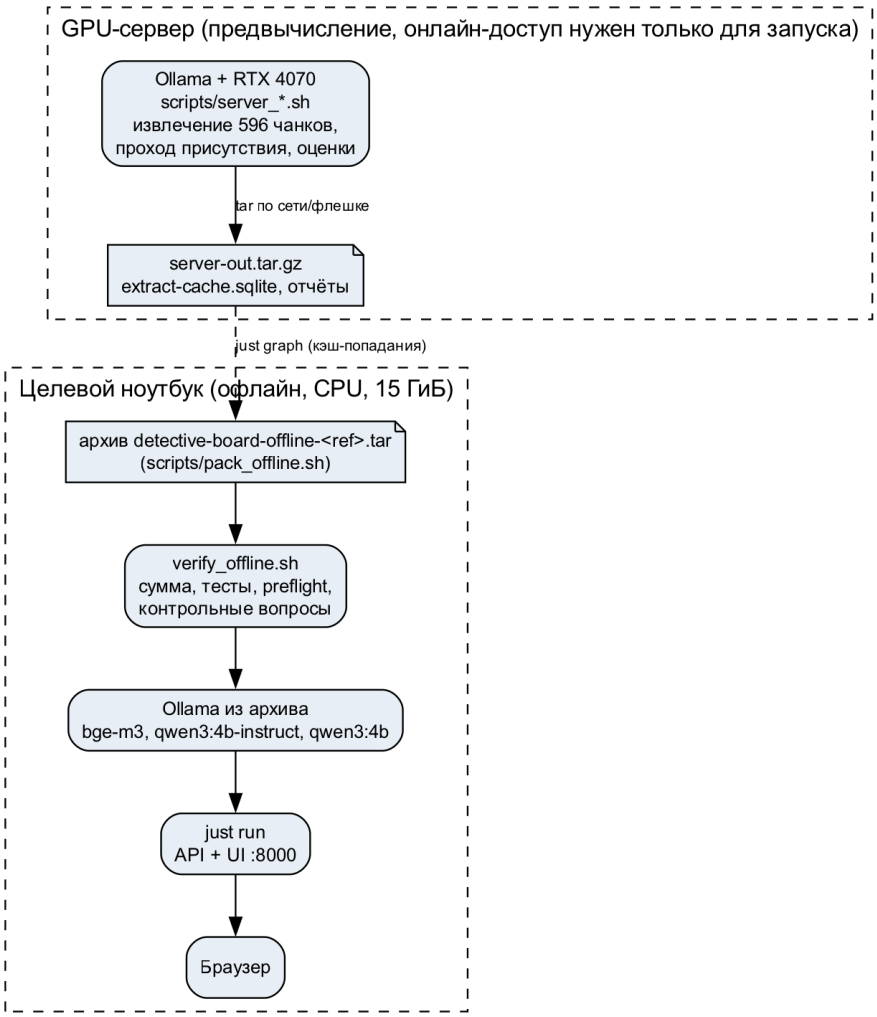


Рисунок 7 – Схема развёртывания: GPU-сервер и целевой ноутбук

5 ВЫЗОВ И ЗАГРУЗКА

Запуск: `just run` (предварительно проверяет доступность Ollama и моделей скриптом `scripts/preflight.py`, затем выполняет `python -m detective_board.api`, адрес http://127.0.0.1:8000). `just run --fake` запускает интерфейс с фиктивной моделью и тремя заготовленными фрагментами без Ollama и без файлов данных. Загрузка индекса, графа и MCP-сервера происходит при старте; прогрев моделей – `api/warmup.py`.

6 ВХОДНЫЕ ДАННЫЕ

– Вопрос пользователя (до 1000 символов) и история до 6 пар «вопрос –ответ» (`POST /api/ask`).
– Корпус: `data/clean/*.txt`, `data/chunks.jsonl`; индексы `data/index/db.sqlite`, `data/index/sentences.sqlite`; граф `data/graph/graph.sqlite`; курируемые файлы `data/curated/*.jsonl`.
– Конфигурация: значения по умолчанию < TOML-файл (`--config` или `DETECTIVE_BOARD_CONFIG`) < переменные `DETECTIVE_BOARD_<ПОЛЕ>` < параметры командной строки.

7 ВЫХОДНЫЕ ДАННЫЕ

– Поток событий SSE и итоговое событие `final` (ответ, цитаты с якорями, метки происхождения, статус).
– Объекты `Explanation` для выводов правил; подграф и текст фрагментов для интерфейса.
– Отчёты оценки: `docs/spike/results/eval-<дата>-<срез>-<sha7>-<хэш конфигурации>-<время>.{md,json,svg}` (ни один результат не перезаписывается).

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

Изм.	**Номера листов (страниц)**			**Всего листов**	**№ докум.**	**Подп.**	**Дата**
	изменённых	замененных	новых				

_____

(наименование организации – заполнить)

УТВЕРЖДАЮ
Должность
_____
_____ / _____
«____» _____ 2026 г.
(поля подписи оставлены пустыми)

ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Локальный офлайн нейро-символический следователь по рассказам о Шерлоке Холмсе

РУКОВОДСТВО ОПЕРАТОРА

программного комплекса
ГОСТ 19.505-79

Обозначение документа: _____ (присваивается организацией)

Авторы:
Верховых Егор
Стрижевский Андрей
Парамонов Даниил
Приц Артём

Комплект программной документации ЕСПД, документ 4 из 8
Версия комплекса: 0.0.1 (pyproject.toml); состояние репозитория: main, коммит 16122fc
Дата составления: 30.10.2026. Статус: черновик, не согласован

2026

ЛИСТ СОГЛАСОВАНИЯ

Подписи, фамилии и даты не заполнены: документ составлен по состоянию репозитория и не согласован ни с кем.

Роль	Должность	Фамилия И. О.	Подпись	Дата
Разработал				
Проверил				
Нормоконтроль				
Утвердил				

СОДЕРЖАНИЕ

1 НАЗНАЧЕНИЕ ПРОГРАММЫ.....4
1.1 Функциональное назначение.....4
1.2 Эксплуатационное назначение.....4
1.3 Состав функций.....4
2 УСЛОВИЯ ВЫПОЛНЕНИЯ ПРОГРАММЫ.....5
3 ВЫПОЛНЕНИЕ ПРОГРАММЫ.....5
3.1 Запуск и проверка состояния.....5
3.2 Окно программы.....5
3.3 Как задать вопрос.....6
3.4 Как читать ответ.....7
3.5 Отказы.....7
3.6 Записи и повторное воспроизведение.....8
4 СООБЩЕНИЯ ОПЕРАТОРУ.....8
ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ.....9

Документ – черновик: составлен по материалам репозитория и измерениям, лежащим в `docs/spike/results/` и `docs/perf/`; человеком не проверен и никем не согласован. Подписи, должности, даты согласования и обозначение документа оставлены пустыми намеренно.

Условные обозначения статуса сведений в комплекте. [Измерено] – число взято из файла отчёта, путь указан рядом. **[Не измерено]** – измерения нет. **[План]** – описано в проектных документах, в коде отсутствует или выключено. **[Заполнить]** – поле оставлено пустым для человека.

1 НАЗНАЧЕНИЕ ПРОГРАММЫ

1.1 Функциональное назначение

Оператор (исследователь) задаёт вопросы по 20 рассказам о Шерлоке Холмсе и получает ответы с дословными цитатами, проверки алиби и противоречий с объяснением, а также видит, как агент к ним пришёл: граф фактов и пошаговую трассу. Если корпус не поддерживает ответ, программа отказывается отвечать и говорит, что искала.

1.2 Эксплуатационное назначение

Интерфейс открывается в браузере по адресу http://127.0.0.1:8000 на той же машине, где запущена программа. Сеть не требуется. Язык интерфейса – английский; вопросы можно задавать по-русски (раздел 3.3).

1.3 Состав функций

– ответы на вопросы о фактах, цитатах, связях персонажей;
– проверка алиби («где был X в такое-то время»), поиск противоречий, хронология, таблица «кто где был по чьим словам», доска исключения по алиби для сцены преступления;
– показ ответа, цитат с подсветкой в тексте, метки происхождения и панели «Почему» с объяснением правила;
– воспроизведение сохранённых прогонов (записей) и сохранение собственного прогона в JSON.

2 УСЛОВИЯ ВЫПОЛНЕНИЯ ПРОГРАММЫ

Программа должна быть установлена и запущена системным программистом (см. «Руководство системного программиста», РСП). Требования к рабочему месту оператора: современный браузер, экран не менее 1280×720 (для показа использовалось 1920×1080), сетевое подключение не нужно. Ноутбук должен работать от сети; при длительной работе процессор нагревается до 98–100 °C (`docs/perf/laptop-20261029.md`), поэтому нужна твёрдая поверхность или подставка.

Ожидаемое время ответа на текстовый вопрос на целевом ноутбуке – около 18–44 с (медиана 28,4 с, холодный старт 44 с; замер не в чистом окне, `docs/perf/laptop-20261029.md`). Вопросы на алиби и противоречия обрабатываются правилами без модели и занимают секунды (в проверке офлайн-архива – 4,6 с; `docs/perf/clean-install-20261029.md`); отказ шлюза – около 1,5 с.

3 ВЫПОЛНЕНИЕ ПРОГРАММЫ

3.1 Запуск и проверка состояния

1) Запустите Ollama и программу (команды – РСП, раздел «Запуск»). Откройте http://127.0.0.1:8000.
2) Нажмите индикатор состояния в верхней строке: он показывает, достижима ли Ollama, загружены ли модели, есть ли индекс, граф и MCP-сервер, идёт ли прогрев. Состояние `degraded` означает, что что-то из перечисленного недоступно.
3) Подождите окончания прогрева: первый вопрос иначе включает холодную загрузку модели.

3.2 Окно программы

Таблица 1 – Элементы интерфейса

Элемент	Назначение
Строка вопроса и кнопки Ask / Stop	Отправка вопроса; Stop прерывает запуск (модель останавливается на ближайшем токене, подготовка запроса не прерывается)

Элемент	Назначение
Метки маршрута, бейдж IDLE / RUNNING / RECORDING, часы	Выбранный маршрут (какой путь выбрал маршрутизатор), состояние запуска, время
Индикатор состояния (health)	Ollama, модели, индекс, граф, MCP, прогрев
Theme / Motion	Тема оформления и отключение анимации
Подсказки Try	Готовые вопросы для демонстрации
History	История вопросов; флажок «Send answered questions as context» передаёт до 6 пар как контекст для уточняющих вопросов
Recordings	Сохранённые прогоны; воспроизводятся из записанных событий, всегда с бейджем RECORDING и никогда не выдаются за живые
Save run as JSON, Keep previous graph	Сохранение собственного прогона; не очищать граф между вопросами
Панель Trace	Шаги агента по порядку: перевод вопроса, маршрут, поиск, запрос к графу, вызов инструмента, проверка цитат, ответ
Панель доски (граф)	Карточки сущностей и событий, нити-связи, пунктирное ребро – конфликт; масштаб «+» и «−»; поиск сущности по имени
Панель ответа	Текст ответа, цитаты, метки происхождения, панель «Почему»

Клавиши: `/` – перейти в поле вопроса; `g` – переключить граф и список (для экранов без графики); `c` – показать сохранённый прогон для текущего вопроса, во время записи – вернуться к живому; `t` – к последнему событию трассы; `Esc` – сбросить выбор. Граф доступен с клавиатуры: стрелки – между узлами, Enter – выбрать, Escape – снять выбор, плюс/минус – масштаб.

3.3 Как задать вопрос

1) Введите вопрос на английском или русском языке (до 1000 символов) и нажмите Ask.
2) Следите за трассой: каждый шаг появляется по мере выполнения; для текстовых вопросов основное время уходит на подготовку запроса к модели (около 21 токена в секунду, `docs/perf/ttft-levers-2026-10-26.md`), а не на выбор предложений.
3) Прочитайте ответ и проверьте цитату: нажмите на цитату – фрагмент откроется с подсветкой места в тексте рассказа.

Примеры вопросов, на которых система проверялась (`docs/team/CLEAN_INSTALL.md`, шаг 5):

Таблица 2 – Контрольные вопросы

Вопрос	Ожидаемое поведение
What kind of snake killed Dr. Grimesby Roylott?	Ответ с цитатой: «It is a swamp adder!»
Is there a conflict about where Aloysius Garcia was at about one o'clock on the night he died?	Пунктирное ребро-конфликт (правило R1), метка conditional, помечено «curated» (вход – курируемые факты); открывается панель «Почему»
What was the creature that haunted the Baskerville family on the Devonshire moor?	Отказ без вызова модели: рассказа «Собака Баскервилей» нет в корпусе

3.4 Как читать ответ

Таблица 3 – Метки в ответе

Метка	Как понимать
`source_text`	Дословные предложения из корпуса, выбранные моделью; модель текст не писала
`extracted`	Факт извлечён моделью; вероятностный, может содержать ошибку; показан с цитатой
`derived`	Вывод правила R1–R3; следует из названных фактов детерминированно; объяснение – в панели «Почему»
`conditional`	Вывод правила, опирающийся на сомнительный (low) извлечённый факт; читать как «если факт F верен, то…»; сомнительный вход назван
curated	Факт введён вручную и перепроверен человеком 29.10.2026 для демонстрационных случаев; в ответе есть строка «Curated»
RECORDING	Это записанный, а не живой прогон

Важно. Вывод правила говорит о том, что следует из извлечённых фактов, а не о том, что истинно в рассказе. Слово «исключён» в доске исключения не означает невиновности, «не исключён» – подозрения; программа не делает утверждений о виновности. Если правила ничего не нашли, ответ говорит о покрытии (сколько пар событий вообще можно сравнить) и показывает текст, но не утверждает, что рассказы согласованы.

3.5 Отказы

Отказ – штатный результат, а не ошибка. Отказ с причиной выдаётся, если: вопрос вне корпуса (по теме или по отсутствию опоры в поиске); модель не нашла подходящего предложения (выбор `NONE`); не прошла проверка цитат. Ответ «partial» содержит ближайшие фрагменты текста без утверждения, что они отвечают на вопрос. Вопрос на русском языке, переведённый неточно, может быть отклонён шлюзом – переформулируйте или задайте по-английски.

3.6 Записи и повторное воспроизведение

Меню Recordings воспроизводит сохранённые прогоны без модели; в каталоге `web/replay/` лежат записи реальных прогонов (`real-*.json`; пять из них записаны 27.10.2026 и перезаписаны на полном графе 28.10.2026, `docs/STATUS.md`) и «fake»-записи на фиктивной модели. Запись воспроизводится как поток событий, помечена RECORDING. Собственный прогон сохраняется кнопкой Save run as JSON (кнопка появляется во время захвата, бейдж CAPTURING).

4 СООБЩЕНИЯ ОПЕРАТОРУ

Таблица 4 – Сообщения интерфейса и действия

Сообщение / ситуация	Причина	Действие оператора
«Cannot reach the agent. Is the server running?»	Сервер API не запущен или недоступен по адресу страницы	Сообщить системному программисту; запустить `just run`
«The agent is busy with another run. Try again in a few seconds.» (HTTP 429)	Одновременно выполняется один запрос	Подождать или нажать Stop на предыдущем
«The question or history is too long.» (HTTP 413) / сообщение invalid_input	Вопрос длиннее 1000 символов или тело запроса больше 16 КиБ	Сократить вопрос; очистить историю
Событие run_error: unavailable	Недоступна Ollama или модель	Проверить индикатор состояния; запустить Ollama
Событие run_error: timeout	Запуск превысил 600 с	Повторить; проверить загрузку процессора (другие программы, перегрев)
Событие run_error: internal	Внутренняя ошибка (без трассы стека и путей)	Повторить; сообщить системному программисту
«The graph view could not start in this browser. Use the list view (g).»	Браузер не поддерживает графическую часть	Нажать `g`
«No stored run for …»	Для вопроса нет записи	Выбрать запись из меню Recordings
«Invalid ?replay= path…»	Неверный адрес записи	Использовать относительный путь вида `replay/run.json`
Состояние `degraded` в индикаторе	Недоступен один из компонентов	Открыть индикатор и прочитать, какой

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

Изм.	**Номера листов (страниц)**			**Всего листов**	**№ докум.**	**Подп.**	**Дата**
	изменённых	замененных	новых				

_____

(наименование организации – заполнить)

УТВЕРЖДАЮ
Должность
_____
_____ / _____
«____» _____ 2026 г.
(поля подписи оставлены пустыми)

ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Локальный офлайн нейро-символический следователь по рассказам о Шерлоке Холмсе

РУКОВОДСТВО СИСТЕМНОГО ПРОГРАММИСТА

программного комплекса
ГОСТ 19.503-79

Обозначение документа: _____ (присваивается организацией)

Авторы:
Верховых Егор
Стрижевский Андрей
Парамонов Даниил
Приц Артём

Комплект программной документации ЕСПД, документ 5 из 8
Версия комплекса: 0.0.1 (pyproject.toml); состояние репозитория: main, коммит 16122fc
Дата составления: 30.10.2026. Статус: черновик, не согласован

2026

ЛИСТ СОГЛАСОВАНИЯ

Подписи, фамилии и даты не заполнены: документ составлен по состоянию репозитория и не согласован ни с кем.

Роль	Должность	Фамилия И. О.	Подпись	Дата
Разработал				
Проверил				
Нормоконтроль				
Утвердил				

СОДЕРЖАНИЕ

1 ОБЩИЕ СВЕДЕНИЯ О ПРОГРАММЕ....4
2 СТРУКТУРА ПРОГРАММЫ....4
3 НАСТРОЙКА ПРОГРАММЫ....5
3.1 Установка из исходников (с сетью)....5
3.2 Запуск....6
3.3 Конфигурация....6
4 ПРОВЕРКА ПРОГРАММЫ....7
5 ДОПОЛНИТЕЛЬНЫЕ ВОЗМОЖНОСТИ....8
5.1 Офлайн-архив....8
5.2 Использование GPU-сервера....9
5.3 Оценка качества....10
6 СООБЩЕНИЯ СИСТЕМНОМУ ПРОГРАММИСТУ....11
ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ....13

Документ – черновик: составлен по материалам репозитория и измерениям, лежащим в docs/spike/results/ и docs/perf/; человеком не проверен и никем не согласован. Подписи, должности, даты согласования и обозначение документа оставлены пустыми намеренно.

Условные обозначения статуса сведений в комплекте. [Измерено] – число взято из файла отчёта, путь указан рядом. **[Не измерено]** – измерения нет. **[План]** – описано в проектных документах, в коде отсутствует или выключено. **[Заполнить]** – поле оставлено пустым для человека.

1 ОБЩИЕ СВЕДЕНИЯ О ПРОГРАММЕ

Руководство предназначено для системного программиста, который устанавливает, настраивает, проверяет и обслуживает комплекс. Назначение, состав и логическая структура программы описаны в «Описании программы» (ОП); работа оператора – в «Руководстве оператора» (РО); перечень проверок и протоколов – в «Программе и методике испытаний» (ПМИ).

Таблица 1 – Что нужно для работы

Компонент	Версия / требование	Где проверить
ОС	целевая: Linux x86_64; разработка: macOS	docs/team/CLEAN_INSTALL.md
Python	>= 3.12 (в офлайн-архиве 3.12.15)	pyproject.toml
uv и just	uv создаёт окружение по uv.lock; just запускает рецепты justfile	ADR-0001
Ollama	локально, порт 11434 (в архиве – 0.35.0)	scripts/preflight.py
Модели Ollama	bge-m3, qwen3:4b-instruct, qwen3:4b; идентификаторы – в docs/team/models.md	ollama list
Данные	data/index/db.sqlite, data/index/sentences.sqlite, data/graph/graph.sqlite (в git не хранятся)	just run печатает состояние файлов
Node.js	только для just test-web	justfile

2 СТРУКТУРА ПРОГРАММЫ

Каталоги репозитория: src/detective_board/ (пакет), web/ (интерфейс), data/ (корпус, чанки, курируемые факты; бинарные индексы создаются или приходят из архива), eval/ (оценка), scripts/ (корпус, сервер,

упаковка, спайк), `tests/`, `docs/`, `prompts/` (промпты извлечения). Структура пакета и потоки данных – ОП, раздел «Описание логической структуры».

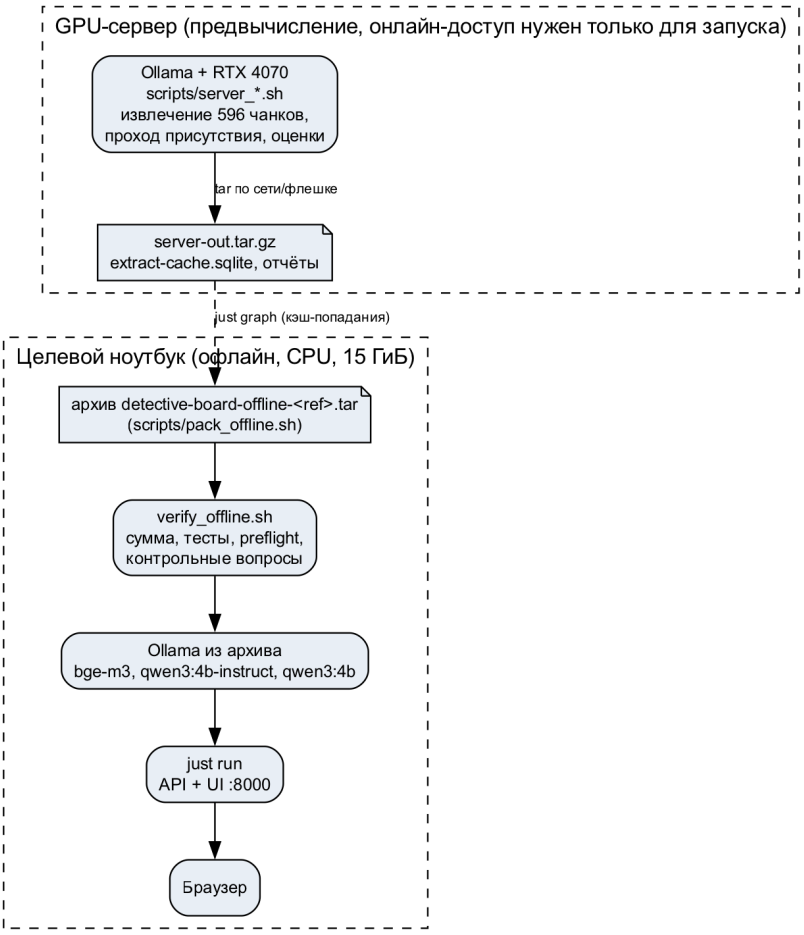


Рисунок 1 – Схема развёртывания: предвычисление на GPU-сервере и работа на ноутбуке

3 НАСТРОЙКА ПРОГРАММЫ

3.1 Установка из исходников (с сетью)

Первая установка требует сети (загрузка пакетов и моделей).

```
git clone https://github.com/AndrewStrizhevskiy/detective-board.git
cd detective-board
# uv sync --group dev
just setup
ollama pull bge-m3 && ollama pull qwen3:4b-instruct && ollama pull qwen3:4b
# сравнить столбец ID с docs/team/models.md
ollama list
```

Корпус и производные данные: `scripts/corpus/fetch.py` скачивает сборники Проекта Гутенберг (список `COLLECTIONS` в скрипте, источники – `data/LICENSES.md`) в `data/raw/`, `scripts/corpus/ingest.py` очищает их и режет на рассказы и 596 чанков (`data/clean/`, `data/chunks.jsonl`);

лицензионные сведения – data/LICENSES.md. Чанки и очищенные рассказы уже лежат в репозитории.

```
# только если нужны исходные тексты
uv run python scripts/corpus/fetch.py
uv run python scripts/corpus/ingest.py
# data/index/db.sqlite: чанки + FTS5 + векторы bge-m3
just index
# data/index/sentences.sqlite (индекс предложений)
just sentences
# data/graph/graph.sqlite из кэша извлечения + нормализация
just graph
```

`just index` без готового кэша эмбеддингов занимает около 22 минут на целевом ноутбуке (0,46 чанка/с, docs/spike/results/embed-20261022-180354.md); индекс предложений – около 20 минут на CPU и 5–10 минут на GPU (justfile, docs/team/SERVER_RUNBOOK.md). Извлечение 596 чанков на ноутбуке заняло бы около 30 часов (оценка docs/PRD.md), поэтому кэш извлечения приходит с GPU-сервера или из архива; `just graph` при полном кэше не вызывает модель (все обращения – попадания в кэш).

Курируемые демонстрационные факты загружаются в граф отдельной командой `python -m detective_board.extract.curated` (параметры – `--help`); без них вопрос о Garcia/Wisteria Lodge не даст находки (docs/team/CLEAN_INSTALL.md, «If something fails»).

3.2 Запуск

```
# проверка Ollama и моделей (scripts/preflight.py), затем API + UI на
http://127.0.0.1:8000
just run
# без Ollama и без файлов данных: фиктивная модель и три фрагмента
just run --fake
uv run python -m detective_board.api --host 127.0.0.1 \
    --port 8000 [--config FILE] [--fake]
```

scripts/preflight.py завершается кодом 2 и печатает, чего нет: недоступна Ollama (`ollama serve`) или не загружена модель (`ollama pull <модель>`). Привязка не к loopback-адресу допускается, но печатается предупреждение: API не аутентифицирует пользователей.

3.3 Конфигурация

Приоритет источников: значения по умолчанию < TOML-файл (`--config` или `DETECTIVE_BOARD_CONFIG`) < переменные окружения

DETECTIVE_BOARD_<ПОЛЕ> < аргументы командной строки. Неизвестные ключи – ошибка.

Таблица 2 – Основные поля (src/detective_board/api/config.py, docs/api.md)

Поле	По умолчанию	Назначение
host, port	127.0.0.1, 8000	адрес и порт API
index_path, graph_path	data/index/ db.sqlite, data/graph/graph.sqlite	файлы данных
facts_path, facts_allow	пусто	JSON FactBase для MCP-инструментов; при пустом значении используется граф
ollama_host	http://localhost:11434	адрес Ollama
llm_model, embed_model, embed_dim	qwen3:4b-instruct, bge-m3, 1024	модели; настройки эмбеддингов должны совпадать с построенным индексом (иначе хранилище откажется работать)
num_ctx, keep_alive	4096, 30m	контекст модели и время удержания в памяти
warmup	true	фоновый прогрев моделей при старте
[agent] (DETECTIVE_BOARD_AGENT_<ИМЯ>)	см. agent/config.py	пороги агента: top_k 4, min_score 0,018, min_support 0,25, answer_mode extractive, rule_first true, translate_questions true, use_llm_router false, tool_timeout_s 5, temperature 0, seed 42 и др.
DETECTIVE_BOARD_TOOL_DEADLINE_S	4	серверный предел времени вызова MCP-инструмента

Значения порогов агента (min_score, min_support, min_claim_overlap) предварительные; промпт выбора предложений заморожен: любое изменение требует повторного измерения (ADR-0009, docs/STATUS.md).

4 ПРОВЕРКА ПРОГРАММЫ

Таблица 3 – Команды проверки

Команда	Что проверяет	Условие
just test	быстрый детерминированный набор pytest (без live и e2e)	без Ollama; **[Измерено]** 986 passed за 9,6 с на коммите 16122fc

Команда	Что проверяет	Условие
`just test-cov`	то же с порогом покрытия 80 % на `src/detective_board`	CI
`just lint`, `just fmt`, `just typecheck`	ruff (проверка/формат) и pyright	—
`just test-web`	логика интерфейса (`tests/web_js/*.test.mjs`, встроенный раннер Node)	нужен Node.js; два живых теста пропускаются без `DB_URL`
`just test-live`	тесты `live`	нужна запущенная Ollama и модели; в CI не запускаются
`just eval --short`	8 вопросов dev, фиктивная модель, образцовый индекс, без сети (задание CI `eval-short`)	—
`./verify_offline.sh --require-offline`	проверка распакованного офлайн-архива (контрольные суммы, окружение, тесты, Ollama, API, контрольные вопросы)	на целевом ноутбуке без сети

Подробный перечень проверок, ожидаемые результаты и протоколы – в ПМИ.

5 ДОПОЛНИТЕЛЬНЫЕ ВОЗМОЖНОСТИ

5.1 Офлайн-архив

Архив содержит всё для работы без сети: репозиторий на теге, записи `web/replay`, индексы и граф, uv, сборку Python, кэш uv, бинарник Ollama и три модели, `MANIFEST` и `SHA256SUMS`. Собирается на Linux x86_64 (платформа цели):

```
scripts/pack_offline.sh --tag rc4 --out ~/dist [--with-8b] [--dry-run]
```

Скрипт отказывается собирать архив, если не хватает модели или файла данных, и сверяет идентификаторы моделей с `docs/team/models.md`. **[Измерено]** архив rc4 (коммит 76f45ad): 6,2 ГБ, sha256 `16854b3d…e2ca3` (полностью – `docs/perf/clean-install-20261029.md`).

Установка на целевой ноутбук (подробно – `docs/team/CLEAN_INSTALL.md`):

```
cp /media/$USER/<носитель>/detective-board-offline-<ref>.tar* ~/
cd ~ && sha256sum -c detective-board-offline-<ref>.tar.sha256
tar -xf detective-board-offline-<ref>.tar && cd detective-board-offline-<ref>
# ожидается RESULT: PASS
./verify_offline.sh --require-offline

# запуск (два терминала)
OLLAMA_MODELS="$PWD/ollama-models" OLLAMA_HOST=127.0.0.1:11434 \
    ollama/bin/ollama serve
export PATH="$PWD/bin:$PATH" UV_OFFLINE=1 UV_PYTHON_DOWNLOADS=never \
    UV_CACHE_DIR="$PWD/uv-cache" UV_LINK_MODE=copy
cd detective-board
uv run --no-sync python scripts/preflight.py
# http://127.0.0.1:8000
uv run --no-sync python -m detective_board.api
```

Перед установкой остановите системную Ollama (`sudo systemctl stop ollama`) и убедитесь, что порты 8765 и 11435 (проверка) и 8000 и 11434 (работа) свободны. Критерий готовности по `CLEAN_INSTALL.md` – успешное прохождение на двух разных ноутбуках с записью в `docs/perf/clean-install-<дата>.md`; **выполнено на одной машине**, на второй **[Не выполнено]** (issue #8).

5.2 Использование GPU-сервера

GPU-сервер используется только для предварительных вычислений: извлечение графа (qwen3:4b, промпт extract-2.1), проход присутствия, сравнения моделей на 12 размеченных фрагментах, индекс предложений, длинные оценки. Это пакетный вывод готовых открытых моделей; обучения и дообучения нет. Во время показа сервер не нужен. Доступ к серверу (SSH, Tailscale, диагностика сети) описан в отдельном репозитории `gpu-server-access`; в настоящий комплект учётные данные и адреса не включены.

Порядок работ (по `docs/team/SERVER_RUNBOOK.md`; на машине общего пользования не хранить учётные данные GitHub, не оставлять ключи и токены, по окончании остановить вручную запущенную Ollama и убрать рабочую копию, если администратор просит):

```
# на ноутбуке: detective-board.tar.gz из HEAD + COMMIT, проверка в чистой копии
scripts/make_server_archive.sh
# или через USB
scp detective-board.tar.gz USER@SERVER:~/
# на сервере, внутри tmux:
# проверки, uv, Ollama, настройки, модели, тесты, подтверждение GPU
scripts/server_bootstrap.sh --with-8b
# детерминизм -> проба параллельности -> gold12 -> полный прогон -> граф ->
отчёт
scripts/server_run_all.sh
# из второго окна: прогресс по шардам, ETA
scripts/server_progress.sh
uv run python -m detective_board.index.sentences
# проход присутствия на демонстрационных рассказах
scripts/server_presence.sh --verify --samples 3
```

Возврат результатов (в git не коммитятся): `data/cache/extract-cache.sqlite`, `data/graph/graph.sqlite`, `data/index/sentences.sqlite`, `data/cache/server/` (отчёт, журналы). Параллельная работа: `OLLAMA_NUM_PARALLEL` (по умолчанию в bootstrap 4) и `OLLAMA_KEEP_ALIVE`. Прогон возобновляем: повторный запуск той же команды продолжает с кэша. Шардирование: `scripts/extract_shards.py plan N`, `scripts/extract_shard.sh k N [модель]`, слияние кэшей `scripts/merge_extract_cache.py merge|verify|count`; `just graph qwen3:4b 20 "data/cache/extract-cache-qwen3_4b-shard*.sqlite"` объединяет шарды и строит граф.

[Измерено] по прогону 27.10.2026 (docs/spike/results/graph-sanity-20261028.md): 596 из 596 чанков, около 3,2 с на чанк при 4 потоках на RTX 4070. Выходы на разном оборудовании и версиях Ollama не побайтно совпадают (сравнено 3 чанка, ни один не идентичен), поэтому кэши ноутбука и сервера не смешивались; демонстрационный граф построен только по серверному прогону.

5.3 Оценка качества

```
# CI-подмножество, без сети
just eval --short
# реальный стек
just eval --split dev
# один раз на замороженную конфигурацию; отказ при незакоммиченных изменениях
just eval --split test
# тест «до раскрытия»; нужна Ollama
just pre-reveal
```

Протокол: результаты dev фиксируются коммитом до запуска test; пороги подбираются только на dev (eval/golden/split.json, проверка

scripts/eval/split_check.py); test-срез запускается один раз на замороженную конфигурацию, повторный запуск для того же коммита и конфигурации отказывает; к каждому числу прикладываются SHA и хэш конфигурации. Тяжёлые прогоны – на GPU-сервере; на целевом ноутбуке осмысленна только задержка.

6 СООБЩЕНИЯ СИСТЕМНОМУ ПРОГРАММИСТУ

Таблица 4 – Диагностика

Сообщение / симптом	Причина	Действие
`preflight: Ollama is not reachable at …`	Ollama не запущена или другой адрес	`ollama serve`; `DETECTIVE_BOARD_OLLAMA_HOST`
`preflight: model missing: <модель>`	модель не загружена	`ollama pull <модель>`
`just run` завершился кодом 2 без запуска сервера	нет файла индекса `data/index/db.sqlite`	`just index` или распаковать архив; состояние файлов печатается при старте
Хранилище отказывается открыть индекс	настройки эмбеддингов не совпадают с построенным индексом	привести `embed_model`, `embed_dim`, префиксы в соответствие
`/api/health`: `degraded`	недоступна Ollama, модель, индекс, граф или MCP-процесс	прочитать поля ответа; при падении подпроцесса MCP метка инструмента `timeline-alibi[in-process]`
`sha256sum -c` FAILED	копия архива повреждена	скопировать заново
`uv sync offline` FAIL (Network connectivity is disabled…)	в кэше нет колеса для платформы	архив собран на другой платформе: пересобрать на Linux x86_64
`ollama` FAIL «address already in use»	работает системная Ollama	`sudo systemctl stop ollama` или `--ollama-port N`
`ollama: model IDs differ`	упакованы другие сборки моделей	пересобрать архив
`api` FAIL на c001	в графе нет курируемых фактов Wisteria Lodge	использовать демонстрационный `graph.sqlite` или загрузить курируемые факты
`network: the internet is reachable`	сеть не отключена	отключить сеть
HTTP 429 `busy`	идёт другой запуск	дождаться или остановить
Коды ошибок API	`invalid_input` 400, `not_found` 404, `unsupported_media_type` 415, `too_large` 413, `busy` 429, `internal` 500	детали в журнале; тело ответа не содержит трассы стека и путей

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

Изм.	**Номера листов (страниц)**			**Всего листов**	**№ докум.**	**Подп.**	**Дата**
	изменённых	замененных	новых				

_____

(наименование организации – заполнить)

УТВЕРЖДАЮ
Должность
_____
_____ / _____
«____» _____ 2026 г.
(поля подписи оставлены пустыми)

ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Локальный офлайн нейро-символический следователь по рассказам о Шерлоке Холмсе

ПРОГРАММА И МЕТОДИКА ИСПЫТАНИЙ

программного комплекса
ГОСТ 19.301-79

Обозначение документа: _____ (присваивается организацией)

Авторы:
Верховых Егор
Стрижевский Андрей
Парамонов Даниил
Приц Артём

Комплект программной документации ЕСПД, документ 6 из 8
Версия комплекса: 0.0.1 (pyproject.toml); состояние репозитория: main, коммит 16122fc
Дата составления: 30.10.2026. Статус: черновик, не согласован

2026

ЛИСТ СОГЛАСОВАНИЯ

Подписи, фамилии и даты не заполнены: документ составлен по состоянию репозитория и не согласован ни с кем.

Роль	Должность	Фамилия И. О.	Подпись	Дата
Разработал				
Проверил				
Нормоконтроль				
Утвердил				

СОДЕРЖАНИЕ

1 ОБЪЕКТ ИСПЫТАНИЙ....4
2 ЦЕЛЬ ИСПЫТАНИЙ....4
3 ТРЕБОВАНИЯ К ПРОГРАММЕ....4
4 ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ....5
5 СРЕДСТВА И ПОРЯДОК ИСПЫТАНИЙ....5
5.1 Средства испытаний....5
5.2 Состав наборов автоматических тестов....5
5.3 Порядок испытаний....6
6 МЕТОДЫ ИСПЫТАНИЙ....7
6.1 Автоматические тесты и статические проверки....7
6.2 Демо-режим без Ollama....7
6.3 Проверка офлайн-архива....7
6.4 Функциональные испытания на реальном стеке....8
6.5 Оценка качества (eval)....8
6.6 Тест «до раскрытия» и исследовательские эксперименты....9
6.7 Замеры времени и памяти....9
ПРИЛОЖЕНИЕ А....11
А.1 Оценка агента, test-срез (однократный прогон)....11
А.2 Тест «до раскрытия» (n = 16)....11
А.3 Офлайн-архив rc4....11
А.4 Время и память на целевом ноутбуке....12
А.5 Другие замеры....12
ПРИЛОЖЕНИЕ Б....14
ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ....15

Документ – черновик: составлен по материалам репозитория и измерениям, лежащим в `docs/spike/results/` и `docs/perf/`; человеком не проверен и никем не согласован. Подписи, должности, даты согласования и обозначение документа оставлены пустыми намеренно.

Условные обозначения статуса сведений в комплекте. [Измерено] – число взято из файла отчёта, путь указан рядом. **[Не измерено]** – измерения нет. **[План]** – описано в проектных документах, в коде отсутствует или выключено. **[Заполнить]** – поле оставлено пустым для человека.

1 ОБЪЕКТ ИСПЫТАНИЙ

Объект – программный комплекс «Детективная доска» (Detective Board) версии 0.0.1 в составе, описанном в «Описании программы» (ОП), на коммите `16122fc` ветки `main` и в виде офлайн-архива (текущий кандидат – тег rc4, коммит 76f45ad; код после rc4 в нём отсутствует, `docs/perf/clean-install-20261029.md`). Испытания проводятся на целевом ноутбуке (ThinkPad X1 Carbon 7 поколения, i7-8665U, 15 ГиБ ОЗУ, Linux x86_64) и, для части проверок, на машине разработки без Ollama.

2 ЦЕЛЬ ИСПЫТАНИЙ

Проверить соответствие комплекса требованиям «Технического задания» (ТЗ), подтвердить воспроизводимость заявленных чисел и честно зафиксировать, что не измерялось. Испытания не доказывают корректность ответов относительно эталона, проверенного человеком: эталонные наборы размечены автоматически и не проверены (issue #9).

3 ТРЕБОВАНИЯ К ПРОГРАММЕ

Проверяются требования ТЗ, раздел 4 (ФТ-1…ФТ-11, надёжность, условия эксплуатации, совместимость). Соответствие требований методам испытаний – в таблице 4 раздела 6.7. Источник сценариев – критерии АС-01…АС-25 (`docs/acceptance/acceptance.md`); их пошаговая проверка при составлении документа не выполнялась **[Не измерено]**. Критериев приёмки по

числовым показателям качества заказчик не задавал: целевые значения в PRD – «TBD» кроме задержки (рабочий бюджет ≤ 40 с) и детерминизма правил (100 %).

4 ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ

Комплект документов (ТЗ, ПЗ, ОП, РО, РСП, ПМИ, ОПр, ФО) проверяется на полноту разделов по соответствующим ГОСТ и на согласованность перекрёстных ссылок; результат проверки – `CHECKLIST.md` комплекта. Оформление – ГОСТ 19.106-78, ГОСТ 2.105-95, ГОСТ 7.32-2017.

5 СРЕДСТВА И ПОРЯДОК ИСПЫТАНИЙ

5.1 Средства испытаний

Таблица 1 – Средства

Средство	Назначение	Где
pytest 9.1.1, pytest-cov 7.1.0	модульные и интеграционные тесты; маркеры `live`, `e2e`, `slow`; строгие маркеры	`tests/`, `pyproject.toml`
Node.js (встроенный раннер)	тесты логики интерфейса	`tests/web_js/*.test.mjs` (7 файлов)
ruff 0.17.1, pyright 1.1.414	стиль и типы	`just lint`, `just typecheck`
`eval/run_eval.py`	A/B-оценка конфигураций и правил по золотым наборам	`eval/`
`eval/pre_reveal.py`	тест «до раскрытия»	`eval/pre_reveal/cases.jsonl`
`scripts/preflight.py`, `verify_offline.sh`	готовность Ollama/моделей и проверка офлайн-архива	`scripts/`
FakeLLM и фиктивное окружение `--fake`	детерминированная замена модели в тестах и демо-режиме	`tests/`, `api/fixture.py`
Измерительные скрипты ноутбука	задержка по API и память процессов	`docs/perf/laptop-*.md`, `scripts/spike/`

5.2 Состав наборов автоматических тестов

Команда `uv run pytest -m "not live and not e2e"` собирает 986 тестов (**[Измерено]** на коммите 16122fc: «986 passed in 9.58s»; в архиве rc4: «976 passed, 2 skipped, 41.5 s», `docs/perf/clean-install-20261029.md`).

Таблица 2 – Тесты по каталогам (сбор тестов на коммите 16122fc)

Каталог	Тестов	Что покрывает
tests/agent/	264	агент: маршрутизатор, извлекающие ответы, правила-сначала, компакция контекста, связывание, таблица присутствия, доска сцены, безопасность, перевод, семантический R3
tests/extract/	158	привязка цитат, разбор, нормализация, ремонт, конвейер
tests/symbolic/	75	правила R1–R3 на мини-графах, детерминизм, готовность
tests/curated/	75	курируемые факты, их проверка и сцены
tests/presence/	79	проход присутствия и верификация
tests/graph/	66	хранилище графа, нормализация времени, якоря, реальные цитаты
tests/api/	64	эндпоинты, SSE, защита (Host, Origin, заголовки), пути, прогрев
tests/mcp/	59	инструменты, stdio-сервер, песочница, защита, паритет с модулем правил
tests/eval/	35	метрики, раннер, тест «до раскрытия»
tests/retrieval/	27	эмбеддер, поиск, хранилище, индекс предложений
tests/index/	11	сборка индексов
tests/*.py (корень)	73	приём корпуса, подсчёт извлечения, шарды, офлайн-скрипты, preflight, хэши vendor, сервер-отчёты

Порог покрытия в CI: 80 % ветвлений на src/detective_board (just test-cov); фактическое покрытие в документах репозитория не зафиксировано **[Не измерено]**.

5.3 Порядок испытаний

1) Автоматические тесты и статические проверки на машине без Ollama (раздел 6.1).
2) Проверка демо-режима just run --fake.
3) Проверка офлайн-архива на целевом ноутбуке без сети: verify_offline.sh --require-offline (раздел 6.3).
4) Функциональная проверка на реальном стеке по трём контрольным вопросам (раздел 6.4).
5) Оценка качества eval/run_eval.py по протоколу раздела 6.5 – на GPU-сервере или на целевом ноутбуке; на ноутбуке осмыслены только значения задержки.

6) Замеры времени и памяти (раздел 6.7) – в чистом окне: закрыть посторонние программы (VPN, Docker, медиа), питание от сети.

7) Заполнение протокола (приложение А) и подписание комиссией – **[Заполнить]**.

6 МЕТОДЫ ИСПЫТАНИЙ

6.1 Автоматические тесты и статические проверки

```
just setup
# ожидается: все тесты проходят (на 16122fc: 986 passed)
just test
# порог 80 %
just test-cov
just lint && just typecheck
# нужен Node.js
just test-web
```

Критерий: 100 % тестов зелёные; тест правил R1–R3 не пропускается и не перезапускается до зелёного. Правила покрыты мини-графами (3–8 узлов) с ручным ответом, повтор запуска даёт идентичный результат; MCP-инструмент и прямой вызов модуля правил дают равный результат (`tests/mcp/`, `tests/symbolic/`).

6.2 Демо-режим без Ollama

```
just run --fake
```

Вопрос «What was the speckled band?» даёт ответ с цитатой фрагмента `speckled-band-0001`; вопрос вне темы – отказ (`docs/api.md`). Критерий – соответствие ожидаемому поведению.

6.3 Проверка офлайн-архива

Шаги и критерии – `docs/team/CLEAN_INSTALL.md`. `verify_offline.sh --require-offline` проверяет: контрольные суммы всех файлов, отсутствие интернета, офлайн-установку окружения, быстрый набор тестов, соответствие идентификаторов моделей `MANIFEST`, `preflight`, контрольные вопросы API (g001 – ответ, c001 – нарушение R1, g047 – отказ, g056 – отказ). Критерий: каждая строка PASS, последняя `RESULT: PASS`. Приёмка заявлена на **двух** разных ноутбуках, один из них не принадлежит автору архива.

6.4 Функциональные испытания на реальном стеке

Таблица 3 – Контрольные вопросы

Идентификатор	Вопрос	Ожидание
g001	What kind of snake killed Dr. Grimesby Roylott?	ответ: «It is a swamp adder!», метка source_text
c001	Is there a conflict about where Aloysius Garcia was at about one o'clock on the night he died?	правило R1 нарушено; conditional; пометка curated; две цитаты
g047	What was the creature that haunted the Baskerville family on the Devonshire moor?	отказ шлюзом, без вызова модели
g056	(второй вопрос вне корпуса, `eval/golden/questions.jsonl`)	отказ

6.5 Оценка качества (eval)

Наборы. `eval/golden/questions.jsonl` – 64 вопроса (категории: факт, многошаговый, связь, хронология, противоречие свидетельств, алиби, межрассказный, вне корпуса, состязательный, русский язык); `eval/golden/contradictions.jsonl` – 43 случая; `eval/extraction_gold/` и 12 размеченных фрагментов; `eval/pre_reveal/cases.jsonl` – 16 вопросов в 8 рассказах. Разбиение dev/test детерминировано (`eval/golden/split.json`, хэш sha256 от seed и идентификатора, расслоено по категориям). Эталоны размечены автоматически.

Конфигурации (генератор везде `qwen3:4b-instruct`, thinking выключен): `bare` – вопрос модели без поиска; `vector` – только поиск bge-m3, топ-4 фрагмента в путь ответа агента (отдельный порог `--vector-min-score`, по умолчанию 0); `vector+rerank` – «не запускалось» (локального реранкера нет); `hybrid+graph` – реальный агент (гибридный поиск, индекс предложений, граф, правила, извлекающий ответ).

Метрики (механические прокси, LLM-судьи нет): «поведение корректно» – отвечаемый вопрос отвечен с покрытием ключевых фактов ≥ 0,5, вопрос вне корпуса отклонён; «цитата верна» – цитата дословна в процитированном фрагменте и фрагмент – из золотых; «предложение-цитата попало» – цитата пересекается с золотой; точность, полнота и доля ложных отказов; recall@1/4/6 фрагментов; recall предложений @1/5/20; обнаружение

противоречий (только правила). У каждой доли – доверительный интервал Уилсона 95 % и n; конфигурации сравниваются парами точным критерием Макнемара.

Протокол. (1) Результаты dev фиксируются коммитом до запуска test (неотслеживаемые файлы считаются изменениями). (2) Пороги, включая `--vector-min-score`, подбираются только на dev. (3) Test-срез запускается один раз на замороженную конфигурацию; запуск с незакоммиченными изменениями отклоняется; повторный запуск для той же пары «коммит, конфигурация» отклоняется. (4) К каждому числу прикладываются SHA коммита и хэш конфигурации. (5) Результат никогда не перезаписывается. Предрегистрация test-прогона: docs/spike/results/test-preregistration-20261028.md.

```
# 8 вопросов dev, FakeLLM, образцовый индекс, без сети
just eval --short
# реальный стек
just eval --split dev
# один раз на замороженную конфигурацию
just eval --split test
```

6.6 Тест «до раскрытия» и исследовательские эксперименты

`just pre-reveal` запускает агента на полном корпусе и на корпусе, обрезанном перед местом, где названа разгадка, плюс «голую» модель; основная метрика – назван ли виновник (имя или псевдоним) в ответе или цитатах. Это лексический прокси, а не чтение человеком. Результаты – раздел A.2. Угадывание виновного (src/detective_board/suspects/, eval/suspects/) и семантический R3 – исследовательские, выключены и в приёмочные испытания не входят.

6.7 Замеры времени и памяти

Метод: 18 различных отвечаемых вопросов dev-среза, три серии по 6 с паузой 20 с (как на сцене), разные вопросы, чтобы кэш префикса не превращал повторы в трёхсекундные ответы; модели выгружены перед первым вопросом; регистрируются полное время ответа, пик памяти процессов llama-server и температура корпуса процессора (docs/perf/laptop-20261029.md). Правила

измерения (RSS в дочернем процессе, выгрузка других моделей, учёт троттлинга, разделение холодной и тёплой загрузки) – `docs/test-plan.md`, раздел 8.

Таблица 4 – Соответствие требований ТЗ методам испытаний

Требование ТЗ	Метод	Последний результат
ФТ-1 ответ с цитатой	6.2, 6.4, 6.5	A.1: test 13/30 (на автоматических метках)
ФТ-2 правила R1–R3	6.1, 6.4, 6.5	986 passed; A.1: полнота 0/12 на автоматических фактах
ФТ-3 отказ	6.4, 6.5	A.1: полнота отказов 6/6, точность 6/12
ФТ-4 интерфейс	6.1 (`test-web`), осмотр	тесты интерфейса не запускались при составлении (нет Node.js); осмотр – **[Заполнить]**
ФТ-5 MCP	6.1 (`tests/mcp/`)	включено в 986
ФТ-6 метки	6.1, осмотр ответов	включено в 986
ФТ-7 оценка	6.5	A.1
ФТ-8 единый источник	6.1 (тест паритета)	включено в 986
ФТ-9 офлайн-запуск	6.3	A.3: одна машина; вторая – не выполнено
ФТ-10 русский вопрос	осмотр	**[Не измерено]**
Задержка ≤ 40 с	6.7	A.4: медиана 28,4 с; не в чистом окне

ПРИЛОЖЕНИЕ А

(справочное)

Результаты уже выполненных проверок (на дату составления)

Приложение сводит измерения, найденные в репозитории. Это не протокол приёмочных испытаний данной редакции.

А.1 Оценка агента, test-срез (однократный прогон)

Таблица А.1 – `docs/spike/results/eval-2026-10-28-test-7b7b197-7857839ed9be-175321.md`; коммит 7b7b197, хэш конфигурации 7857839ed9be, n=30

Показатель	bare	vector	hybrid+graph
Поведение корректно	3/30 (10 %)	11/30 (37 %)	13/30 (43 %), ДИ 27–61 %
Все цитаты верны (из отвеченных)	н/п	6/18	7/18
Полнота отказов	2/6	6/6	6/6
Точность отказов	2/20	6/12	6/12
recall@4 фрагмента	н/п	16/24	16/24
Медиана полного времени, с	35,1	30,4	29,3
Обнаружение противоречий (правила)	—	—	полнота 0/12; ложных 0/8

Парные сравнения (точный критерий Макнемара): bare–hybrid+graph p = 0,0063; vector–hybrid+graph p = 0,5.

А.2 Тест «до раскрытия» (n = 16)

Файл: `docs/spike/results/pre-reveal-2026-10-28-rescored.md`.

Условие	Виновник назван	Отказ
A. полный корпус	2/16 (12 %)	5/16
B. корпус обрезан перед раскрытием	0/16	5/16
C. голая модель	1/16	13/16

Различия не значимы (A против B p = 0,5; A против C p = 1). Прогон выполнен на «грязном» дереве (коммит 0e00f58), оценка пересчитана без повторного запуска модели.

А.3 Офлайн-архив rc4

Файл: `docs/perf/clean-install-20261029.md`.

Шаг	Результат
Контрольные суммы	PASS, 11 291 файл

Шаг	Результат
Без сети	PASS
Офлайн-установка окружения	PASS, Python 3.12.15
Тесты	PASS, 976 passed, 2 skipped, 41,5 с
Ollama из архива	PASS, 3 модели совпадают с MANIFEST
preflight	PASS
g001 / c001 / g047 / g056	ответ 148,3 с / R1 нарушено 4,6 с / отказ 1,5 с / отказ 95,8 с

Ограничения: одна машина (ноутбук автора архива), модели уже были на диске; медленные ответы (148 с, 96 с) – не измерение скорости (параллельно шёл другой эксперимент и включалась холодная загрузка). Проверка на двух разных ноутбуках не выполнена. Заявление «установка менее 15 минут» не измерено.

A.4 Время и память на целевом ноутбуке

Файл: `docs/perf/laptop-20261029.md`.

Серия	Медиана, с	Диапазон, с	Пик ОЗУ, МБ	Макс. температура, °C
1 (холодный старт первым)	33,3	29,2–44,1	4991	98
2	26,1	18,6–28,4	5659	99
3	28,3	23,9–29,4	6289	98

Все 18 вопросов: медиана 28,4 с по 16 отвеченным, 90-й процентиль 33,8 с, 2 из 18 отказ (модель выбрала NONE). Условия: не чистое окно, один день, одна машина; профиль 8 ГБ не проверялся.

A.5 Другие замеры

Что	Результат	Файл
Граф полного корпуса	596/596 чанков, 5278 узлов до курируемых фактов	`docs/spike/results/graph-sanity-20261028.md`
Проход присутствия	оставлено 16 (qwen3:8b) и 7 (qwen3:4b-instruct) фактов на 159 чанках	`docs/spike/results/presence-pass-server-20261029.md`
Вопросы dev, рескоринг	bare 4/34, vector 15/34, agent 12/34	`docs/spike/results/eval-2026-10-28-dev-ab945e8-78b3bbb3f2a6-145202-rescored.md`
Семантический R3, dev	строгая полнота 1/14, ложных на контролях 8/9	`docs/spike/results/r3-semantic-dev-judge-r3j2.md`

Что	Результат	Файл
Угадывание виновного, 6 новых рассказов	виновный первым 2 из 6, как «самый упоминаемый» (2 из 6); интервал Уилсона 0,10–0,70; один оправданный назван первым	`docs/spike/results/suspects-20261030.md`
Скорость доски, PR #30 (headless Chromium, мс до → после)	14 карточек: сдвиг 2400 → 225, масштаб 2100 → 315; 200 узлов: 2060 → 384 и 13 900 → 2780; не на ноутбуке, разброс на масштабе большой	описание PR #30 на GitHub
12 вопросов через API	извлекающий режим 8–20 с против 45–140 с	`docs/spike/results/api12-20261027-extractive.md`, `api12-20261027-generative.md`

ПРИЛОЖЕНИЕ Б

(рекомендуемое)

Форма протокола приёмочных испытаний

Форма не заполнена: подписи, даты, фамилии и результаты вносятся комиссией.

№	Проверка (раздел ПМИ)	Результат	Замечания
1	Автоматические тесты (6.1)		
2	Демо-режим (6.2)		
3	Офлайн-архив на ноутбуке 1 (6.3)		
4	Офлайн-архив на ноутбуке 2 (6.3)		
5	Контрольные вопросы g001, c001, g047, g056 (6.4)		
6	Оценка dev и test (6.5)		
7	Замеры времени и памяти (6.7)		
8	Проверка документации (раздел 4)		

Роль	Фамилия И. О.	Подпись	Дата
Председатель комиссии			
Член комиссии			
Исполнитель			

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

Изм.	**Номера листов (страниц)**			**Всего листов**	**№ докум.**	**Подп.**	**Дата**
	изменённых	замененных	новых				

_____

(наименование организации – заполнить)

УТВЕРЖДАЮ
Должность
_____
_____ / _____
«____» _____ 2026 г.
(поля подписи оставлены пустыми)

ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Локальный офлайн нейро-символический следователь по рассказам о Шерлоке Холмсе

ОПИСАНИЕ ПРИМЕНЕНИЯ

программного комплекса
ГОСТ 19.502-78

Обозначение документа: _____ (присваивается организацией)

Авторы:
Верховых Егор
Стрижевский Андрей
Парамонов Даниил
Приц Артём

Комплект программной документации ЕСПД, документ 7 из 8
Версия комплекса: 0.0.1 (pyproject.toml); состояние репозитория: main, коммит 16122fc
Дата составления: 30.10.2026. Статус: черновик, не согласован

2026

ЛИСТ СОГЛАСОВАНИЯ

Подписи, фамилии и даты не заполнены: документ составлен по состоянию репозитория и не согласован ни с кем.

Роль	Должность	Фамилия И. О.	Подпись	Дата
Разработал				
Проверил				
Нормоконтроль				
Утвердил				

СОДЕРЖАНИЕ

1 НАЗНАЧЕНИЕ ПРОГРАММЫ.....4
1.1 Возможности программы.....4
1.2 Ограничения области применения.....4
2 УСЛОВИЯ ПРИМЕНЕНИЯ.....5
3 ОПИСАНИЕ ЗАДАЧИ.....5
4 ВХОДНЫЕ И ВЫХОДНЫЕ ДАННЫЕ.....6
4.1 Входные данные.....6
4.2 Выходные данные.....6
5 СЦЕНАРИИ ПРИМЕНЕНИЯ.....6
ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ.....8

Документ – черновик: составлен по материалам репозитория и измерениям, лежащим в docs/spike/results/ и docs/perf/; человеком не проверен и никем не согласован. Подписи, должности, даты согласования и обозначение документа оставлены пустыми намеренно.

Условные обозначения статуса сведений в комплекте. [Измерено] – число взято из файла отчёта, путь указан рядом. **[Не измерено]** – измерения нет. **[План]** – описано в проектных документах, в коде отсутствует или выключено. **[Заполнить]** – поле оставлено пустым для человека.

1 НАЗНАЧЕНИЕ ПРОГРАММЫ

1.1 Возможности программы

Программа позволяет исследователю задавать вопросы к 20 рассказам о Шерлоке Холмсе и получать ответы, опирающиеся только на текст корпуса, с дословными цитатами; проверять алиби и противоречия детерминированными правилами; видеть ход рассуждения агента и объяснение каждого логического вывода.

1.2 Ограничения области применения

– Корпус фиксирован: 20 рассказов на английском языке; загрузка других текстов не поддерживается (PRD, «Не-цели»).

– Программа не делает выводов о виновности и не заменяет чтение рассказа: вывод правила следует из извлечённых фактов, а извлечение ошибается.

– Автоматически построенный граф содержит очень мало фактов, пригодных для правил (структурированные утверждения о присутствии – 0,7 % высказываний, docs/spike/results/graph-sanity-20261028.md), поэтому проверка алиби и противоречий на произвольном рассказе чаще вернёт «неизвестно» или пустой результат; уверенные находки есть только для курируемых демонстрационных случаев.

– Угадывание виновного не реализовано в основном коде и ненадёжно: на 6 новых рассказах лучший экспериментальный метод назвал виновного первым 2 раза из 6, как простая базовая «самый упоминаемый»; не обвинять невиновного получается лишь отказами отвечать (`docs/spike/results/suspects-20261030.md`).

2 УСЛОВИЯ ПРИМЕНЕНИЯ

Технические и программные требования – ТЗ, раздел 4; установка – «Руководство системного программиста» (РСП); работа оператора – «Руководство оператора» (РО). Программа применяется на одном компьютере; сеть не нужна; время ответа на целевом ноутбуке без GPU – десятки секунд (медиана 28,4 с, `docs/perf/laptop-20261029.md`). Рекомендуется перед показом прогреть модель одним вопросом и подключить питание.

3 ОПИСАНИЕ ЗАДАЧИ

Задача: по вопросу пользователя найти в корпусе подтверждающий текст, при необходимости выполнить логическую проверку над графом фактов, сформировать ответ с цитатами и метками происхождения либо отказать с указанием причины. Алгоритм – «Описание программы» (ОП), раздел «Поток обработки вопроса»; правила R1–R3 – там же и в «Пояснительной записке» (ПЗ).

Таблица 1 – Типы вопросов и маршруты

Тип вопроса	Пример	Как обрабатывается
Факт, цитата	What kind of snake killed Dr. Grimesby Roylott?	гибридный поиск + выбор предложений; ответ – дословный текст
Связь сущностей	How is X connected to Y?	запрос к графу + текст
Алиби	Where was X at nine o'clock?	MCP-инструмент `check_alibi` (R1), ответ по шаблону

Тип вопроса	Пример	Как обрабатывается
Противоречия	Is there a conflict about where X was…?	MCP-инструмент `find_contradictions`, ответ по шаблону; пустой результат ≠ «согласовано»
Хронология	What happened in order…?	`build_timeline`
Таблица присутствия	Who says where X was?	`presence_table`
Сцена преступления	Who could have been at …?	`scene_board` (только курируемая сцена)
Вне корпуса	What was the creature that haunted the Baskerville family…?	отказ без вызова модели

4 ВХОДНЫЕ И ВЫХОДНЫЕ ДАННЫЕ

4.1 Входные данные

Вопрос (1–1000 символов, английский или русский; русский переводится на английский локальной моделью). Необязательно – история до 6 пар для уточняющих вопросов. Файлы данных – ОП, раздел «Входные данные».

4.2 Выходные данные

Ответ: статус (`answered`, `partial`, `refused`), текст, цитаты с якорями (рассказ, фрагмент, смещения), метки происхождения (`source_text`, `extracted`, `derived`, `conditional`, пометка curated), для правил – объяснение (правило, факты, рёбра, цитаты). Трасса шагов и граф показываются в интерфейсе.

5 СЦЕНАРИИ ПРИМЕНЕНИЯ

Таблица 2 – Контрольный сценарий показа (`docs/design/demo-script.md`, `docs/team/CLEAN_INSTALL.md`)

Шаг	Действие	Что должно произойти
1	Вопрос g001 о змее	Ответ с цитатой «It is a swamp adder!»; граф и трасса растут по мере работы
2	Вопрос c001 о Garcia	Конфликт R1 (пунктирное ребро), conditional, «curated»; панель «Почему» с двумя цитатами; без вызова модели
3	Вопрос g047 о «собаке Баскервилей»	Отказ шлюзом, в трассе нет вызова модели
4	Меню Recordings	Воспроизведение записанного прогона с бейджем RECORDING

Все записи показа, выполненные не вживую, объявляются записями; находки на курируемых фактах называются курируемыми (`docs/DISCLOSURE.md`).

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

Изм.	**Номера листов (страниц)**			**Всего листов**	**№ докум.**	**Подп.**	**Дата**
	изменённых	замененных	новых				

_____

(наименование организации – заполнить)

УТВЕРЖДАЮ
Должность
_____
_____ / _____
«____» _____ 2026 г.
(поля подписи оставлены пустыми)

ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Локальный офлайн нейро-символический следователь по рассказам о Шерлоке Холмсе

ФОРМУЛЯР

программного комплекса
ГОСТ 19.501-78

Обозначение документа: _____ (присваивается организацией)

Авторы:
Верховых Егор
Стрижевский Андрей
Парамонов Даниил
Приц Артём

Комплект программной документации ЕСПД, документ 8 из 8
Версия комплекса: 0.0.1 (pyproject.toml); состояние репозитория: main, коммит 16122fc
Дата составления: 30.10.2026. Статус: черновик, не согласован

2026

ЛИСТ СОГЛАСОВАНИЯ

Подписи, фамилии и даты не заполнены: документ составлен по состоянию репозитория и не согласован ни с кем.

Роль	Должность	Фамилия И. О.	Подпись	Дата
Разработал				
Проверил				
Нормоконтроль				
Утвердил				

СОДЕРЖАНИЕ

1 ОБЩИЕ СВЕДЕНИЯ.....4
2 ОСНОВНЫЕ ХАРАКТЕРИСТИКИ.....4
3 КОМПЛЕКТНОСТЬ.....5
4 СВИДЕТЕЛЬСТВО О ПРИЁМКЕ.....6
5 ГАРАНТИИ.....6
6 СВЕДЕНИЯ О ХРАНЕНИИ И КОНСЕРВАЦИИ.....6
7 УЧЁТ ЭКСПЛУАТАЦИИ.....6
ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ.....7

Документ – черновик: составлен по материалам репозитория и измерениям, лежащим в docs/spike/results/ и docs/perf/; человеком не проверен и никем не согласован. Подписи, должности, даты согласования и обозначение документа оставлены пустыми намеренно.

Условные обозначения статуса сведений в комплекте. [Измерено] – число взято из файла отчёта, путь указан рядом. **[Не измерено]** – измерения нет. **[План]** – описано в проектных документах, в коде отсутствует или выключено. **[Заполнить]** – поле оставлено пустым для человека.

1 ОБЩИЕ СВЕДЕНИЯ

Таблица 1 – Основные сведения

Параметр	Значение
Наименование	«Детективная доска» (Detective Board)
Обозначение (регистрационный номер)	**[Заполнить]** (присваивается организацией)
Версия	0.0.1 (pyproject.toml); состояние репозитория main, коммит 16122fc
Кандидат поставки	тег rc4, коммит 76f45ad, архив detective-board-offline-rc4.tar (6,2 ГБ)
Правообладатель, разработчик	**[Заполнить]**; репозиторий AndrewStrizhevskiy/detective-board
Лицензия программы	**[Заполнить]**: файл лицензии на проект в корне репозитория не найден; лицензии корпуса и сторонних компонентов – data/LICENSES.md, THIRD_PARTY_NOTICES.md
Дата изготовления экземпляра	**[Заполнить]**

2 ОСНОВНЫЕ ХАРАКТЕРИСТИКИ

Таблица 2 – Характеристики (все числа – с источником)

Характеристика	Значение	Источник
Корпус	20 рассказов, 596 фрагментов; 11 018 предложений	docs/PRD.md, docs/spike/results/graph-sanity-20261028.md
Граф (до курируемых фактов)	5278 узлов: 2157 высказываний, 1698 событий, 743 персонажа, 631 место, 49 предметов	graph-sanity-20261028.md
Курируемые факты демонстрации	8 фактов присутствия, 1 сцена; введены вручную и перепроверены человеком 29.10.2026; вывод остаётся conditional	docs/DISCLOSURE.md

Характеристика	Значение	Источник
Модели	bge-m3, qwen3:4b-instruct, qwen3:4b (идентификаторы – docs/team/models.md)	docs/team/models.md
Правила	R1, R2, R3 (чистый Python)	src/detective_board/symbolic/
MCP-инструменты	6 (сервер `timeline-alibi`)	src/detective_board/mcp/server.py
Тестов (без live и e2e)	986, все проходят на коммите 16122fc	`uv run pytest -m "not live and not e2e"`
Время ответа на целевом ноутбуке	медиана 28,4 с, диапазон 18,6–44,1 с (не чистое окно)	docs/perf/laptop-20261029.md
Пик памяти	6289 МБ (все процессы llama-server)	там же
Качество на test-срезе (автоматические метки)	поведение корректно 13/30; отказы: полнота 6/6, точность 6/12	`docs/spike/results/eval-2026-10-28-test-7b7b197-…-175321.md`

3 КОМПЛЕКТНОСТЬ

Таблица 3 – Состав поставки

№	Наименование	Количество	Примечание
1	Программный комплекс (исходный код репозитория)	1	git, коммит 16122fc
2	Офлайн-архив `detective-board-offline-<ref>.tar` с `MANIFEST`, `SHA256SUMS`, `.tar.sha256`	1	сборка scripts/pack_offline.sh; rc4: sha256 `16854b3d5fe2a8e80ba925bfdda8fcb0fb7a43bb379ae699bf92da694e5e2ca3`
3	Данные: индекс фрагментов, индекс предложений, граф, курируемые файлы	в архиве	в git не хранятся
4	Записи прогонов `web/replay/*.json`	в репозитории	помечены как записи
5	Комплект программной документации ЕСПД (ТЗ, ПЗ, ОП, РО, РСП, ПМИ, ОПр, ФО)	8	`docs/gost/`
6	Перечень документов и лист соответствия ГОСТ	2	README.md, `CHECKLIST.md` комплекта

Фактическая комплектность конкретного экземпляра подтверждается проверкой контрольных сумм (`sha256sum -c`) и `MANIFEST` архива.

4 СВИДЕТЕЛЬСТВО О ПРИЁМКЕ

Программный комплекс версии _____ соответствует техническому заданию и признан годным к эксплуатации. Приёмка не проводилась; поля не заполнены.

Должность	Фамилия И. О.	Подпись	Дата

5 ГАРАНТИИ

Гарантийные обязательства не установлены: проект учебный, поставляется «как есть». Условия поддержки **[Заполнить]**.

6 СВЕДЕНИЯ О ХРАНЕНИИ И КОНСЕРВАЦИИ

Хранение носителя с архивом – любое сухое помещение при комнатной температуре; перед каждым использованием проверяется контрольная сумма. Консервация не требуется. Параметры хранения **[Заполнить]** (в проекте не регламентированы).

7 УЧЁТ ЭКСПЛУАТАЦИИ

Таблица 4 – Журнал использования

Дата	Место	Версия / архив	Цель	Результат	Подпись

Таблица 5 – Учёт рекламаций и ремонта

Дата	Описание дефекта	Принятые меры	Подпись

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

Изм.	**Номера листов (страниц)**			**Всего листов**	**№ докум.**	**Подп.**	**Дата**
	изменённых	замененных	новых				