_____

(наименование организации – заполнить)

УТВЕРЖДАЮ
Должность
_____
_____ / _____
«____» _____ 2026 г.
(поля подписи оставлены пустыми)

ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Локальный офлайн нейро-символический следователь по рассказам о Шерлоке Холмсе

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

к программному комплексу
ГОСТ 19.404-79

Обозначение документа: _____ (присваивается организацией)

Авторы:
Верховых Егор
Стрижевский Андрей
Парамонов Даниил
Приц Артём

Комплект программной документации ЕСПД, документ 2 из 8
Версия комплекса: 0.0.1 (pyproject.toml); состояние репозитория: main, коммит 16122fc
Дата составления: 30.10.2026. Статус: черновик, не согласован

2026

ЛИСТ СОГЛАСОВАНИЯ

Подписи, фамилии и даты не заполнены: документ составлен по состоянию репозитория и не согласован ни с кем.

Роль	Должность	Фамилия И. О.	Подпись	Дата
Разработал				
Проверил				
Нормоконтроль				
Утвердил				

СОДЕРЖАНИЕ

1 ВВЕДЕНИЕ....4
2 НАЗНАЧЕНИЕ И ОБЛАСТЬ ПРИМЕНЕНИЯ....4
3 ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ....5
3.1 Постановка задачи....5
3.2 Описание алгоритма и функционирования....5
3.3 Правила символического слоя....6
3.4 Структура программы....7
3.5 Методы и средства разработки....7
4 ИЗМЕРЕННЫЕ ХАРАКТЕРИСТИКИ....7
4.1 Модели на целевом ноутбуке (спайк)....7
4.2 Поиск....7
4.3 Граф по полному корпусу....8
4.4 Оценка качества агента (eval/run_eval.py)....8
4.5 Правила на автоматическом графе....9
4.6 Проход «присутствия» (кто где когда)....9
4.7 Время и память на целевом ноутбуке....9
4.8 Экспериментальные режимы, не включённые в основной путь....10
5 ОБОСНОВАНИЕ ПРИНЯТЫХ РЕШЕНИЙ....11
6 МЕТКИ ПРОИСХОЖДЕНИЯ И ПРЕДЕЛЫ ЧЕСТНОСТИ....12
7 БЕЗОПАСНОСТЬ....13
8 ЧТО НЕ СДЕЛАНО....14
ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ....15

Документ – черновик: составлен по материалам репозитория и измерениям, лежащим в `docs/spike/results/` и `docs/perf/`; человеком не проверен и никем не согласован. Подписи, должности, даты согласования и обозначение документа оставлены пустыми намеренно.

Условные обозначения статуса сведений в комплекте. [Измерено] – число взято из файла отчёта, путь указан рядом. **[Не измерено]** – измерения нет. **[План]** – описано в проектных документах, в коде отсутствует или выключено. **[Заполнить]** – поле оставлено пустым для человека.

1 ВВЕДЕНИЕ

Пояснительная записка описывает назначение и область применения программного комплекса «Детективная доска» (Detective Board), поставленную задачу, принятые решения и их обоснование, измеренные характеристики и ограничения. Устройство программы подробно изложено в документе «Описание программы» (ОП), порядок работы – в «Руководстве оператора» (РО) и «Руководстве системного программиста» (РСП), проверки – в «Программе и методике испытаний» (ПМИ).

Основание: см. «Техническое задание» (ТЗ), раздел 2. Все числа привязаны к файлам репозитория; числа без указанного файла в документе не приводятся.

2 НАЗНАЧЕНИЕ И ОБЛАСТЬ ПРИМЕНЕНИЯ

Комплекс отвечает на вопросы о 20 рассказах о Шерлоке Холмсе, опираясь только на текст корпуса: каждый ответ содержит дословную цитату, результаты логических проверок получаются детерминированными правилами и сопровождаются объяснением, а при отсутствии опоры в тексте система отказывается отвечать. Применение: учебный проект, демонстрация, исследование границ нейро-символического подхода на небольшом локальном оборудовании.

Не предназначен для: других корпусов, загрузки пользовательских текстов, многопользовательской работы, обучения моделей, вопросов об общих знаниях о Холмсе вне текста (раздел «Не-цели» PRD).

3 ТЕХНИЧЕСКИЕ ХАРАКТЕРИСТИКИ

3.1 Постановка задачи

Длинная художественная проза трудно поддаётся опросу: чтобы выяснить, кто не мог находиться на месте происшествия, нужно перечитать десятки рассказов, а обычный чат с языковой моделью выдумывает факты и цитаты (PRD, раздел 1). Требуется агент, который исследует фиксированный корпус, показывает свои доказательства и умеет сказать «в корпусе этого нет».

Ограничения среды: ноутбук без GPU (i7-8665U, 4 ядра, 15 ГиБ), модели не более 8 млрд параметров, работа без сети. Измеренная скорость генерации на этом ноутбуке 4,3–7,7 ток./с в зависимости от модели, время до первого токена 15–30 с для запроса в 300 слов (`docs/spike/REPORT.md`, раздел 3). Следствие: мало вызовов модели на вопрос, короткие запросы, предвычисление графа.

3.2 Описание алгоритма и функционирования

Работа делится на подготовку данных (выполняется заранее) и ответ на вопрос (выполняется при показе).

Подготовка. Рассказы очищаются от служебного текста Проекта Гутенберг и делятся на 596 абзацно-выровненных фрагментов. Языковая модель извлекает из каждого фрагмента сущности (персонаж, место, предмет), события, высказывания и отношения в JSON-схеме, каждое с дословной цитатой; цитата, не найденная в тексте фрагмента как подстрока, отбрасывается. Нормализатор добавляет время и структуру высказываний; результат пишется в граф SQLite. Строятся индекс фрагментов (BM25 + векторы bge-m3) и индекс предложений.

Ответ. Маршрутизатор на правилах определяет тип вопроса. Текстовые вопросы идут через гибридный поиск (BM25 и вектор, слияние RRF) и индекс предложений: модель выбирает номера предложений, а ответ – их дословный текст (извлекающий режим, ADR-0009). Вопросы о противоречиях, алиби и хронологии решаются инструментом MCP `timeline-alibi`, который вызывает правила R1–R3; ответ строится по шаблону без вызова модели (ADR-0010). Перед выдачей проверяется, что каждая цитата – дословная подстрока цитируемого фрагмента; иначе выдаётся отказ с причиной. Все шаги отправляются клиенту потоком событий SSE.

Диаграммы потоков данных приведены в ОП (раздел «Описание логической структуры»), правила R1–R3 – в разделе 3.3 настоящей записки.

3.3 Правила символического слоя

Таблица 1 – Правила R1–R3 (`docs/symbolic-layer.md`, раздел 4)

Правило	Условие нарушения	Что не моделируется
R1 – одно место в одно время	Человек участвует в двух событиях, времена которых определённо пересекаются, а места определённо различны	Время в пути; различие «присутствие / передвижение» в схеме извлечения; нет данных – вердикт «неизвестно», а не «согласовано»
R2 – порядок событий	В отношении «раньше» (из относительных меток и абсолютных времён) возникает цикл (компонента сильной связности > 1 узла или петля)	Рассказ «задом наперёд» (позиция в тексте не является доказательством); дубликаты событий могут давать ложные циклы
R3 – высказывание против факта	Структурированное утверждение свидетеля несовместимо с установленным фактом (событие в голосе рассказчика с высокой уверенностью)	Конфликт двух высказываний (нет авторитета выбора); ненадёжный рассказчик

Результат правила – один из трёх вердиктов: `violated`, `consistent`, `unknown` (с кодом причины и перечнем недостающего); отсутствие факта никогда не даёт `consistent` или `violated`. Метка `conditional` ставится, если хотя бы один из извлечённых входов имеет уверенность `low`. Уверенность вычисляется детерминированно по сигналам конвейера (неоднозначный якорь, приблизительное время, неточное сопоставление имён), а не сообщается моделью.

3.4 Структура программы

Модули и их взаимодействие приведены в ОП (рисунки «Контейнеры» и «Потоки»). Кратко: `extract/` – извлечение и нормализация; `index/` и `retrieval/` – индексы и поиск; `graph/` – хранилище графа; `symbolic/` – правила; `mcp/` – клиент и сервер инструментов; `agent/` – маршрутизатор, режимы ответа, проверки; `api/` – сервер Starlette; `web/` – интерфейс без сборки.

3.5 Методы и средства разработки

Python 3.12, SQLite (FTS5, sqlite-vec 0.1.9), Starlette 1.9.0 и uvicorn 0.54.0, pydantic 2, пакет `mcp` 2.x, Ollama; интерфейс – ES-модули и векторная графика без сборочного этапа (ADR-0005). Инструменты: uv, just, ruff 0.17.1, pyright 1.1.414, pytest 9.1.1 (`pyproject.toml`). Сквозное тестирование с Playwright описано в группе зависимостей `e2e` и по умолчанию не ставится.

4 ИЗМЕРЕННЫЕ ХАРАКТЕРИСТИКИ

Ниже собраны числа из отчётов репозитория. «Золотые» наборы вопросов и случаев размечены автоматически и **не проверены человеком** (issue #9), поэтому все показатели качества – показатели относительно автоматических меток.

4.1 Модели на целевом ноутбуке (спайк)

Таблица 2 – Скорость моделей, 300 слов запроса, до 200 токенов ответа, среднее из 3 прогонов (`docs/spike/REPORT.md`, раздел 3)

Модель	ток./с	TTFT, с	ОЗУ пик, МиБ
qwen3:4b-instruct	7,04	19,46	3195
qwen3:4b	7,07	17,19	3526
gemma3:4b	7,73	15,30	4127
qwen3:8b	4,34	29,49	6033

4.2 Поиск

Гибридный поиск (k=30, веса BM25:вектор 0,5:1) дал hit@5 = 0,97 при 35 вопросах, векторный – 0,89; параметры подобраны на тех же 35 вопросах, оценка завышена, доверительных интервалов нет (`docs/spike/REPORT.md`, раздел 5).

4.3 Граф по полному корпусу

Извлечение выполнено на GPU-сервере кафедры (RTX 4070, Ollama 0.40.11, qwen3:4b, промпт extract-2.1, схема v2, temperature 0, seed 42): 596 из 596 фрагментов, 20 из 20 рассказов, около 3,2 с на фрагмент при 4 потоках (на ноутбуке 180–250 с). Сохранено элементов 8663, отброшено 125 (дубликаты 14, цитата не найдена 111). Граф: 2157 высказываний, 1698 событий, 743 персонажа, 631 место, 49 предметов (`docs/spike/results/graph-sanity-20261028.md`).

Доля событий с текстом времени 19,3 %, с нормализованным временем 52,5 %, с днём рассказа 4,5 %; доля высказываний со структурированным утверждением о присутствии 0,7 % (там же). Это главная причина, по которой правила почти ничего не находят на автоматическом графе.

4.4 Оценка качества агента (eval/run_eval.py)

Таблица 3 – Доля «поведение корректно» (ответ на отвечаемый вопрос с покрытием ключевых фактов ≥ 0,5; отказ на внекорпусный вопрос); механический критерий без LLM-судьи

Срез	Голая модель	Только вектор	Агент (hybrid+graph)	Файл
dev (n=34)	4/34	15/34	12/34	`docs/spike/results/eval-2026-10-28-dev-ab945e8-78b3bbb3f2a6-145202-rescored.md`
test (n=30), один прогон на `7b7b197`	3/30	11/30	13/30 (43 %, ДИ 27–61 %)	`docs/spike/results/eval-2026-10-28-test-7b7b197-7857839ed9be-175321.md`

На dev-срезе агент не лучше векторного поиска (12/34 против 15/34); его преимущество – полнота извлечения фрагмента recall@4 (21/27 против 18/27) и отказы. На test-срезе агент лучше голой модели (точный критерий Макнемара p = 0,006) и статистически не отличим от векторного поиска (2 против 0, p = 0,5). Конфигурация vector+rerank не запускалась: локального реранкера нет.

Таблица 4 – Отказы и цитаты на test-срезе (`eval-2026-10-28-test-7b7b197-...-175321.md`)

Показатель	Векторный	Агент
Полнота отказов	6/6	6/6

Показатель	Векторный	Агент
Точность отказов	6/12	6/12
Доля ложных отказов	6/24	6/24
Ответ, все цитаты верны	6/18	7/18
Предложение-цитата попало в золотую цитату	7/18	11/18

4.5 Правила на автоматическом графе

Контрольный набор `eval/golden/contradictions.jsonl`: на test-срезе (20 случаев) найдено 0 из 12 положительных, ложных срабатываний 0 из 8 контрольных; на dev-срезе 0 из 14 и 0 из 9 (файлы `eval-2026-10-28-*`). На всех 20 рассказах правила нашли единственное противоречие – курируемый случай Wisteria Lodge (`docs/spike/results/graph-sanity-20261028.md`). Вывод: правила детерминированы, но подходящих фактов в автоматическом графе практически нет.

4.6 Проход «присутствия» (кто где когда)

Таблица 5 – Воронка прохода на 159 фрагментах демонстрационных рассказов (`docs/spike/results/presence-pass-server-20261029.md`)

Этап	qwen3:8b	qwen3:4b-instruct
Факты от модели	537	587
После проверки цитат и полей	101	122
После голосования (2 из 3)	103	103
После верификатора (оставлено)	16	7
Фрагментов с хотя бы одним фактом	14 из 159	6 из 159

Эталон прохода содержит лишь 4 строгих факта (20 в широком наборе), поэтому оценки точности (4b-instruct: 1,0 по 3 оценённым предсказаниям; 8b: ни один из 16 не совпал с эталоном) не поддерживают никаких выводов о качестве. Извлечение присутствия слабое: оставлено 16 и 7 фактов на 159 фрагментах; ни один оставленный факт не несёт дня рассказа.

4.7 Время и память на целевом ноутбуке

18 различных отвечаемых вопросов dev-среза, три серии по 6: медиана 28,4 с по 16 отвеченным (диапазон 18,6–44,1 с; 90-й процентиль 33,8 с), холодный старт 44,1 с, пик памяти всех процессов llama-server 6289 МБ, температура до 100 °C. Замер выполнен **не в чистом окне** (параллельно

работали VPN, Docker, рабочий стол), оценка – верхняя; профиль 8 ГБ не проверялся (docs/perf/laptop-20261029.md).

4.8 Экспериментальные режимы, не включённые в основной путь

– Угадывание виновного (матрица подозреваемых, экспериментальный код src/detective_board/suspects/, eval/suspects/; отчёты docs/spike/results/suspects-20261030.md и suspects-prereg-heldout-20261030.md). Тестовый срез основного корпуса (8 рассказов, замороженный протокол, один прогон): ни один метод не превзошёл простые базовые приёмы. Dev (8 рассказов) – исследовательский: лучший из примерно 35 вариантов, парный турнир на qwen3:14b, назвал виновного первым в 4 случаях из 8; цифра завышена, так как метод отбирался на этих же рассказах. На 6 новых рассказах (Честертон, «Father Brown», протокол заморожен до прогона, один запуск) тот же метод назвал виновного первым в 2 случаях из 6 – как и базовая «самый упоминаемый» (2 из 6); интервал Уилсона 0,10–0,70; один оправданный назван первым. Метки (виновный, оправданные, место обрезки текста) расставлены автоматически, нужна проверка человеком. Вывод: система не угадывает развязку надёжно; «не обвиняет невиновного» выполняется лишь ценой отказов отвечать.

– Тест «до раскрытия» (eval/pre_reveal.py, 16 вопросов, 8 рассказов): виновник назван 2/16 при полном корпусе, 0/16 при корпусе, обрезанном перед раскрытием, 1/16 у голой модели; различия статистически не значимы (docs/spike/results/pre-reveal-2026-10-28-rescored.md).

– Семантический R3 (модельная проверка пар высказываний, `AgentConfig.semantic_r3`, по умолчанию выключен): на dev строгая полнота 1/14, ложных срабатываний на контролях 8/9

(docs/spike/results/r3-semantic-dev-judge-r3j2.md). В демонстрации не показывается.

– Более ранний вариант `exp/entity-answer` (выбор сущности) признан небезопасным (docs/spike/results/entity-answer-2026-10-29.md); он не слит.

5 ОБОСНОВАНИЕ ПРИНЯТЫХ РЕШЕНИЙ

Решения зафиксированы в ADR (docs/adr/). Таблица приводит статус «как записано в документе»; часть записей предшествует реализации и могла устареть.

Таблица 6 – Архитектурные решения

ADR	Решение	Статус в ADR
0001	Монорепозиторий, Python 3.12, uv, just, ruff, проверка типов	Принято (монорепо, Python, uv, just, ruff); проверка типов – предложено
0002	Хранилище: SQLite FTS5 + sqlite-vec; граф – SQLite, Ladybug отложен	Принято
0003	MCP-серверы и SDK `mcp` 2.x	Предложено (дизайн); реализация есть
0004	Символический слой: обычные функции Python над представлением фактов, без Datalog/ASP	Предложено; реализовано в `symbolic/`
0005	Starlette + uvicorn, поток SSE, статический UI	Принято
0006	Модель эмбеддингов bge-m3	Принято
0007	Модель извлечения	Предложено
0008	Модель ответов qwen3:4b-instruct (n=12, средняя-низкая уверенность)	Принято 23.10.2026
0009	Извлекающие ответы: модель выбирает предложения	Принято 27.10.2026 (пилот n=12, один прогон)
0010	Ответы «правила сначала» и охрана честности	Принято 27.10.2026
0011	Целевой проход присутствия и курируемые факты	Курируемые факты – принято; автоматический проход – предложено (точность не измерена)
0012	Универсальный промпт extract-2.1 + детерминированный ремонт	Принято 26.10.2026

Почему правила написаны на обычном Python (ADR-0004): детерминизм, объяснимость (код правила сам строит объект `Explanation` с цитатами), тестируемость на мини-графах, ноль зависимостей. Почему извлекающие ответы (ADR-0009): генерация на ноутбуке давала 45–140 с на вопрос, а 4B-модель отказывалась отвечать даже при наличии ответа в

запросе; выбор номеров предложений даёт 8–20 с в пилоте и дословный текст ответа.

6 МЕТКИ ПРОИСХОЖДЕНИЯ И ПРЕДЕЛЫ ЧЕСТНОСТИ

Таблица 7 – Метки происхождения

Метка	Кем создана	Свойство
extracted	модель (и детерминированная постобработка)	вероятностная; несёт уверенность high/low и якорь с цитатой
derived	правило R1–R3	детерминированная; несёт объяснение: правило, факты, рёбра, цитаты
conditional	правило	выведено из сомнительного (low) извлечённого факта; в ответе формулируется как «если факт F верен, то…»
source_text	извлекающий ответ	дословные предложения корпуса, выбранные моделью
curated	человек (пометка к факту)	введён вручную для демонстрационных случаев, повторная проверка человеком ещё впереди; в экране, панели «Почему» и ответе назван «curated»

Главное ограничение. Ошибки извлечения проходят в символический слой без изменений: правила точны на графе, который им дан, но не обязательно на рассказе. Неверно извлечённое время, место или говорящий дадут ошибочный, но хорошо объяснённый вывод. Поэтому каждая цитата входа показана, а выводы на сомнительных входах помечены `conditional`. Система утверждает только, что вывод следует из названных фактов.

– Пустой результат правил не означает «противоречий нет»: ответ говорит о покрытии и цитирует текст (охрана честности, ADR-0010).

– Демонстрационные находки (Wisteria Lodge, Abbey Grange R1; контроль Boscombe Valley) построены на восьми **курируемых** фактах (`data/curated/presence_demo.jsonl`), введённых вручную (повторная проверка человеком ещё впереди); для Abbey Grange время относительное, поэтому вывод всегда `conditional`. Показывают, что делают правила на верных фактах, а не что находит модель (`docs/DISCLOSURE.md`).

– Цитата проверяется на дословное вхождение в цитируемый фрагмент, но не на то, что она поддерживает утверждение (docs/security.md, 1.5); добавлена проверка пересечения содержательных слов (порог 0,3, предварительный).
– Золотые наборы (64 вопроса, 43 случая противоречий, 12 фрагментов извлечения) размечены автоматически; проверка человеком не выполнена.
– Вычисления на GPU-сервере: извлечение графа, проход присутствия, часть оценок; на показе их нет. Разрешение организаторов – по сообщению руководителя команды от 26.10.2026; письменный ответ к раскрытию не приложен (docs/DISCLOSURE.md).

7 БЕЗОПАСНОСТЬ

Обзор безопасности выполнен 23.10.2026 (docs/security.md), по коду без запуска моделей. Выводы по группам угроз: внедрение инструкций из корпуса – модель не выбирает маршрут и аргументы инструментов (код), корпус передаётся в ограждённых блоках; найдены проблемы средней важности – неограждённые поля в запросе и проверка цитат только на дословность. Песочница чтения файлов MCP – в порядке; серверы filesystem/fetch не подключены. API: привязка к loopback, проверка Host и Origin, заголовки CSP и X-Frame-Options. SQL-инъекции, pickle/eval – не выявлены. Таблица статусов в отчёте содержит пометки «исправлено, не закоммичено» на момент обзора; актуальное состояние исправлений нужно проверять по коду и тестам (tests/api/test_hardening.py, tests/mcp/test_hardening.py, tests/agent/test_security.py). Открытыми на момент отчёта остались: извлечение-время внедрение (не изучено глубоко), неограниченная привязка к не-loopback адресам (только предупреждение), проверка контрольных сумм корпуса и vendor-файлов.

8 ЧТО НЕ СДЕЛАНО

– Чистая установка из офлайн-архива на двух разных ноутбуках (issue #8): проверена одна машина (`docs/perf/clean-install-20261029.md`).
– Замеры задержки в чистом окне с повторами и профиль 8 ГБ (issue #14).
– Проверка золотых наборов человеком (issue #9).
– Точность автоматического прохода присутствия не доказана; расширение числа курируемых случаев не планировалось в документах.
– Реранкер, фильтрация серверов filesystem/fetch, сервер заметок `evidence-notes`, не реализованы.
– Репетиции показа с финальным кодом (issue #15).

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

Изм.	Номера листов (страниц)			Всего листов	№ докум.	Подп.	Дата
	изменённых	замененных	новых				