_____

(наименование организации – заполнить)

УТВЕРЖДАЮ
Должность
_____
_____ / _____
«____» _____ 2026 г.
(поля подписи оставлены пустыми)

ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Локальный офлайн нейро-символический следователь по рассказам о Шерлоке Холмсе

РУКОВОДСТВО СИСТЕМНОГО ПРОГРАММИСТА

программного комплекса
ГОСТ 19.503-79

Обозначение документа: _____ (присваивается организацией)

Авторы:
Верховых Егор
Стрижевский Андрей
Парамонов Даниил
Приц Артём

Комплект программной документации ЕСПД, документ 5 из 8
Версия комплекса: 0.0.1 (pyproject.toml); состояние репозитория: main, коммит 16122fc
Дата составления: 30.10.2026. Статус: черновик, не согласован

2026

ЛИСТ СОГЛАСОВАНИЯ

Подписи, фамилии и даты не заполнены: документ составлен по состоянию репозитория и не согласован ни с кем.

Роль	Должность	Фамилия И. О.	Подпись	Дата
Разработал				
Проверил				
Нормоконтроль				
Утвердил				

СОДЕРЖАНИЕ

1 ОБЩИЕ СВЕДЕНИЯ О ПРОГРАММЕ....4
2 СТРУКТУРА ПРОГРАММЫ....4
3 НАСТРОЙКА ПРОГРАММЫ....5
3.1 Установка из исходников (с сетью)....5
3.2 Запуск....6
3.3 Конфигурация....6
4 ПРОВЕРКА ПРОГРАММЫ....7
5 ДОПОЛНИТЕЛЬНЫЕ ВОЗМОЖНОСТИ....8
5.1 Офлайн-архив....8
5.2 Использование GPU-сервера....9
5.3 Оценка качества....10
6 СООБЩЕНИЯ СИСТЕМНОМУ ПРОГРАММИСТУ....11
ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ....13

Документ – черновик: составлен по материалам репозитория и измерениям, лежащим в docs/spike/results/ и docs/perf/; человеком не проверен и никем не согласован. Подписи, должности, даты согласования и обозначение документа оставлены пустыми намеренно.

Условные обозначения статуса сведений в комплекте. [Измерено] – число взято из файла отчёта, путь указан рядом. **[Не измерено]** – измерения нет. **[План]** – описано в проектных документах, в коде отсутствует или выключено. **[Заполнить]** – поле оставлено пустым для человека.

1 ОБЩИЕ СВЕДЕНИЯ О ПРОГРАММЕ

Руководство предназначено для системного программиста, который устанавливает, настраивает, проверяет и обслуживает комплекс. Назначение, состав и логическая структура программы описаны в «Описании программы» (ОП); работа оператора – в «Руководстве оператора» (РО); перечень проверок и протоколов – в «Программе и методике испытаний» (ПМИ).

Таблица 1 – Что нужно для работы

Компонент	Версия / требование	Где проверить
ОС	целевая: Linux x86_64; разработка: macOS	docs/team/CLEAN_INSTALL.md
Python	>= 3.12 (в офлайн-архиве 3.12.15)	pyproject.toml
uv и just	uv создаёт окружение по uv.lock; just запускает рецепты justfile	ADR-0001
Ollama	локально, порт 11434 (в архиве – 0.35.0)	scripts/preflight.py
Модели Ollama	bge-m3, qwen3:4b-instruct, qwen3:4b; идентификаторы – в docs/team/models.md	ollama list
Данные	data/index/db.sqlite, data/index/sentences.sqlite, data/graph/graph.sqlite (в git не хранятся)	just run печатает состояние файлов
Node.js	только для just test-web	justfile

2 СТРУКТУРА ПРОГРАММЫ

Каталоги репозитория: src/detective_board/ (пакет), web/ (интерфейс), data/ (корпус, чанки, курируемые факты; бинарные индексы создаются или приходят из архива), eval/ (оценка), scripts/ (корпус, сервер,

упаковка, спайк), `tests/`, `docs/`, `prompts/` (промпты извлечения). Структура пакета и потоки данных – ОП, раздел «Описание логической структуры».

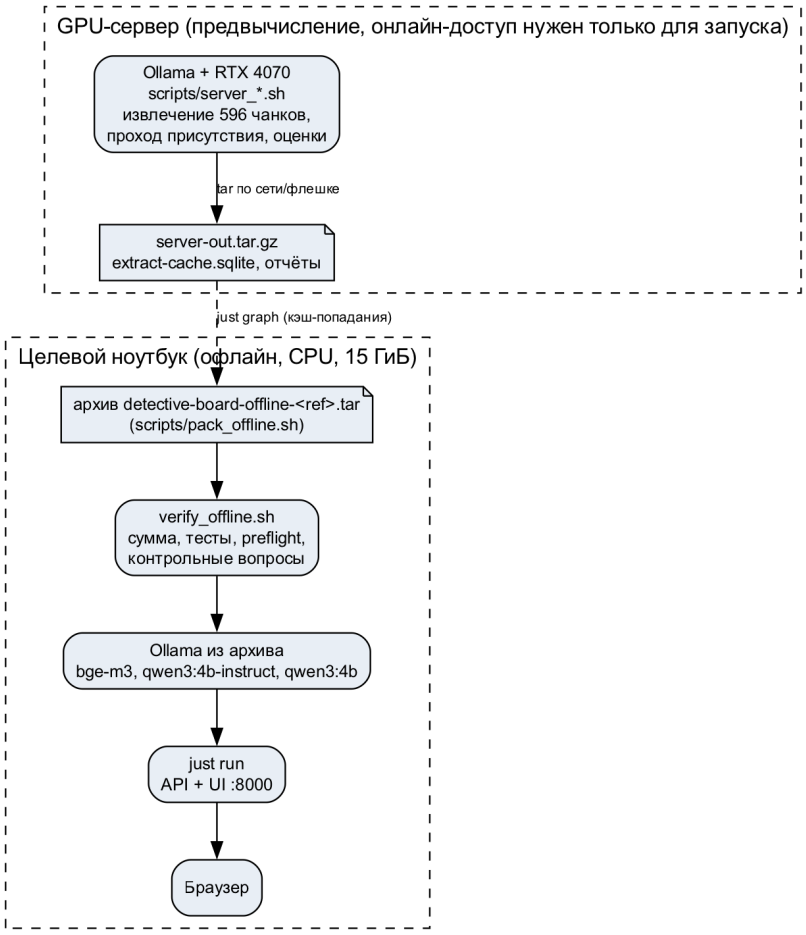


Рисунок 1 – Схема развёртывания: предвычисление на GPU-сервере и работа на ноутбуке

3 НАСТРОЙКА ПРОГРАММЫ

3.1 Установка из исходников (с сетью)

Первая установка требует сети (загрузка пакетов и моделей).

```
git clone https://github.com/AndrewStrizhevskiy/detective-board.git
cd detective-board
# uv sync --group dev
just setup
ollama pull bge-m3 && ollama pull qwen3:4b-instruct && ollama pull qwen3:4b
# сравнить столбец ID с docs/team/models.md
ollama list
```

Корпус и производные данные: `scripts/corpus/fetch.py` скачивает сборники Проекта Гутенберг (список `COLLECTIONS` в скрипте, источники – `data/LICENSES.md`) в `data/raw/`, `scripts/corpus/ingest.py` очищает их и режет на рассказы и 596 чанков (`data/clean/`, `data/chunks.jsonl`);

лицензионные сведения – data/LICENSES.md. Чанки и очищенные рассказы уже лежат в репозитории.

```
# только если нужны исходные тексты
uv run python scripts/corpus/fetch.py
uv run python scripts/corpus/ingest.py
# data/index/db.sqlite: чанки + FTS5 + векторы bge-m3
just index
# data/index/sentences.sqlite (индекс предложений)
just sentences
# data/graph/graph.sqlite из кэша извлечения + нормализация
just graph
```

`just index` без готового кэша эмбеддингов занимает около 22 минут на целевом ноутбуке (0,46 чанка/с, docs/spike/results/embed-20261022-180354.md); индекс предложений – около 20 минут на CPU и 5–10 минут на GPU (justfile, docs/team/SERVER_RUNBOOK.md). Извлечение 596 чанков на ноутбуке заняло бы около 30 часов (оценка docs/PRD.md), поэтому кэш извлечения приходит с GPU-сервера или из архива; `just graph` при полном кэше не вызывает модель (все обращения – попадания в кэш).

Курируемые демонстрационные факты загружаются в граф отдельной командой `python -m detective_board.extract.curated` (параметры – `--help`); без них вопрос о Garcia/Wisteria Lodge не даст находки (docs/team/CLEAN_INSTALL.md, «If something fails»).

3.2 Запуск

```
# проверка Ollama и моделей (scripts/preflight.py), затем API + UI на
http://127.0.0.1:8000
just run
# без Ollama и без файлов данных: фиктивная модель и три фрагмента
just run --fake
uv run python -m detective_board.api --host 127.0.0.1 \
    --port 8000 [--config FILE] [--fake]
```

scripts/preflight.py завершается кодом 2 и печатает, чего нет: недоступна Ollama (`ollama serve`) или не загружена модель (`ollama pull <модель>`). Привязка не к loopback-адресу допускается, но печатается предупреждение: API не аутентифицирует пользователей.

3.3 Конфигурация

Приоритет источников: значения по умолчанию < TOML-файл (`--config` или `DETECTIVE_BOARD_CONFIG`) < переменные окружения

DETECTIVE_BOARD_<ПОЛЕ> < аргументы командной строки. Неизвестные ключи – ошибка.

Таблица 2 – Основные поля (src/detective_board/api/config.py, docs/api.md)

Поле	По умолчанию	Назначение
host, port	127.0.0.1, 8000	адрес и порт API
index_path, graph_path	data/index/ db.sqlite, data/graph/graph.sqlite	файлы данных
facts_path, facts_allow	пусто	JSON FactBase для MCP-инструментов; при пустом значении используется граф
ollama_host	http://localhost:11434	адрес Ollama
llm_model, embed_model, embed_dim	qwen3:4b-instruct, bge-m3, 1024	модели; настройки эмбеддингов должны совпадать с построенным индексом (иначе хранилище откажется работать)
num_ctx, keep_alive	4096, 30m	контекст модели и время удержания в памяти
warmup	true	фоновый прогрев моделей при старте
[agent] (DETECTIVE_BOARD_AGENT_<ИМЯ>)	см. agent/config.py	пороги агента: top_k 4, min_score 0,018, min_support 0,25, answer_mode extractive, rule_first true, translate_questions true, use_llm_router false, tool_timeout_s 5, temperature 0, seed 42 и др.
DETECTIVE_BOARD_TOOL_DEADLINE_S	4	серверный предел времени вызова MCP-инструмента

Значения порогов агента (min_score, min_support, min_claim_overlap) предварительные; промпт выбора предложений заморожен: любое изменение требует повторного измерения (ADR-0009, docs/STATUS.md).

4 ПРОВЕРКА ПРОГРАММЫ

Таблица 3 – Команды проверки

Команда	Что проверяет	Условие
just test	быстрый детерминированный набор pytest (без live и e2e)	без Ollama; **[Измерено]** 986 passed за 9,6 с на коммите 16122fc

Команда	Что проверяет	Условие
`just test-cov`	то же с порогом покрытия 80 % на `src/detective_board`	CI
`just lint`, `just fmt`, `just typecheck`	ruff (проверка/формат) и pyright	—
`just test-web`	логика интерфейса (`tests/web_js/*.test.mjs`, встроенный раннер Node)	нужен Node.js; два живых теста пропускаются без `DB_URL`
`just test-live`	тесты `live`	нужна запущенная Ollama и модели; в CI не запускаются
`just eval --short`	8 вопросов dev, фиктивная модель, образцовый индекс, без сети (задание CI `eval-short`)	—
`./verify_offline.sh --require-offline`	проверка распакованного офлайн-архива (контрольные суммы, окружение, тесты, Ollama, API, контрольные вопросы)	на целевом ноутбуке без сети

Подробный перечень проверок, ожидаемые результаты и протоколы – в ПМИ.

5 ДОПОЛНИТЕЛЬНЫЕ ВОЗМОЖНОСТИ

5.1 Офлайн-архив

Архив содержит всё для работы без сети: репозиторий на теге, записи `web/replay`, индексы и граф, uv, сборку Python, кэш uv, бинарник Ollama и три модели, `MANIFEST` и `SHA256SUMS`. Собирается на Linux x86_64 (платформа цели):

```
scripts/pack_offline.sh --tag rc4 --out ~/dist [--with-8b] [--dry-run]
```

Скрипт отказывается собирать архив, если не хватает модели или файла данных, и сверяет идентификаторы моделей с `docs/team/models.md`. **[Измерено]** архив rc4 (коммит 76f45ad): 6,2 ГБ, sha256 `16854b3d…e2ca3` (полностью – `docs/perf/clean-install-20261029.md`).

Установка на целевой ноутбук (подробно – `docs/team/CLEAN_INSTALL.md`):

```
cp /media/$USER/<носитель>/detective-board-offline-<ref>.tar* ~/
cd ~ && sha256sum -c detective-board-offline-<ref>.tar.sha256
tar -xf detective-board-offline-<ref>.tar && cd detective-board-offline-<ref>
# ожидается RESULT: PASS
./verify_offline.sh --require-offline

# запуск (два терминала)
OLLAMA_MODELS="$PWD/ollama-models" OLLAMA_HOST=127.0.0.1:11434 \
    ollama/bin/ollama serve
export PATH="$PWD/bin:$PATH" UV_OFFLINE=1 UV_PYTHON_DOWNLOADS=never \
    UV_CACHE_DIR="$PWD/uv-cache" UV_LINK_MODE=copy
cd detective-board
uv run --no-sync python scripts/preflight.py
# http://127.0.0.1:8000
uv run --no-sync python -m detective_board.api
```

Перед установкой остановите системную Ollama (`sudo systemctl stop ollama`) и убедитесь, что порты 8765 и 11435 (проверка) и 8000 и 11434 (работа) свободны. Критерий готовности по `CLEAN_INSTALL.md` – успешное прохождение на двух разных ноутбуках с записью в `docs/perf/clean-install-<дата>.md`; **выполнено на одной машине**, на второй **[Не выполнено]** (issue #8).

5.2 Использование GPU-сервера

GPU-сервер используется только для предварительных вычислений: извлечение графа (qwen3:4b, промпт extract-2.1), проход присутствия, сравнения моделей на 12 размеченных фрагментах, индекс предложений, длинные оценки. Это пакетный вывод готовых открытых моделей; обучения и дообучения нет. Во время показа сервер не нужен. Доступ к серверу (SSH, Tailscale, диагностика сети) описан в отдельном репозитории `gpu-server-access`; в настоящий комплект учётные данные и адреса не включены.

Порядок работ (по `docs/team/SERVER_RUNBOOK.md`; на машине общего пользования не хранить учётные данные GitHub, не оставлять ключи и токены, по окончании остановить вручную запущенную Ollama и убрать рабочую копию, если администратор просит):

```
# на ноутбуке: detective-board.tar.gz из HEAD + COMMIT, проверка в чистой копии
scripts/make_server_archive.sh
# или через USB
scp detective-board.tar.gz USER@SERVER:~/
# на сервере, внутри tmux:
# проверки, uv, Ollama, настройки, модели, тесты, подтверждение GPU
scripts/server_bootstrap.sh --with-8b
# детерминизм -> проба параллельности -> gold12 -> полный прогон -> граф ->
отчёт
scripts/server_run_all.sh
# из второго окна: прогресс по шардам, ETA
scripts/server_progress.sh
uv run python -m detective_board.index.sentences
# проход присутствия на демонстрационных рассказах
scripts/server_presence.sh --verify --samples 3
```

Возврат результатов (в git не коммитятся): `data/cache/extract-cache.sqlite`, `data/graph/graph.sqlite`, `data/index/sentences.sqlite`, `data/cache/server/` (отчёт, журналы). Параллельная работа: `OLLAMA_NUM_PARALLEL` (по умолчанию в bootstrap 4) и `OLLAMA_KEEP_ALIVE`. Прогон возобновляем: повторный запуск той же команды продолжает с кэша. Шардирование: `scripts/extract_shards.py plan N`, `scripts/extract_shard.sh k N [модель]`, слияние кэшей `scripts/merge_extract_cache.py merge|verify|count`; `just graph qwen3:4b 20 "data/cache/extract-cache-qwen3_4b-shard*.sqlite"` объединяет шарды и строит граф.

[Измерено] по прогону 27.10.2026 (docs/spike/results/graph-sanity-20261028.md): 596 из 596 чанков, около 3,2 с на чанк при 4 потоках на RTX 4070. Выходы на разном оборудовании и версиях Ollama не побайтно совпадают (сравнено 3 чанка, ни один не идентичен), поэтому кэши ноутбука и сервера не смешивались; демонстрационный граф построен только по серверному прогону.

5.3 Оценка качества

```
# CI-подмножество, без сети
just eval --short
# реальный стек
just eval --split dev
# один раз на замороженную конфигурацию; отказ при незакоммиченных изменениях
just eval --split test
# тест «до раскрытия»; нужна Ollama
just pre-reveal
```

Протокол: результаты dev фиксируются коммитом до запуска test; пороги подбираются только на dev (eval/golden/split.json, проверка

scripts/eval/split_check.py); test-срез запускается один раз на замороженную конфигурацию, повторный запуск для того же коммита и конфигурации отказывает; к каждому числу прикладываются SHA и хэш конфигурации. Тяжёлые прогоны – на GPU-сервере; на целевом ноутбуке осмысленна только задержка.

6 СООБЩЕНИЯ СИСТЕМНОМУ ПРОГРАММИСТУ

Таблица 4 – Диагностика

Сообщение / симптом	Причина	Действие
`preflight: Ollama is not reachable at …`	Ollama не запущена или другой адрес	`ollama serve`; `DETECTIVE_BOARD_OLLAMA_HOST`
`preflight: model missing: <модель>`	модель не загружена	`ollama pull <модель>`
`just run` завершился кодом 2 без запуска сервера	нет файла индекса `data/index/db.sqlite`	`just index` или распаковать архив; состояние файлов печатается при старте
Хранилище отказывается открыть индекс	настройки эмбеддингов не совпадают с построенным индексом	привести `embed_model`, `embed_dim`, префиксы в соответствие
`/api/health`: `degraded`	недоступна Ollama, модель, индекс, граф или MCP-процесс	прочитать поля ответа; при падении подпроцесса MCP метка инструмента `timeline-alibi[in-process]`
`sha256sum -c` FAILED	копия архива повреждена	скопировать заново
`uv sync offline` FAIL (Network connectivity is disabled…)	в кэше нет колеса для платформы	архив собран на другой платформе: пересобрать на Linux x86_64
`ollama` FAIL «address already in use»	работает системная Ollama	`sudo systemctl stop ollama` или `--ollama-port N`
`ollama: model IDs differ`	упакованы другие сборки моделей	пересобрать архив
`api` FAIL на c001	в графе нет курируемых фактов Wisteria Lodge	использовать демонстрационный `graph.sqlite` или загрузить курируемые факты
`network: the internet is reachable`	сеть не отключена	отключить сеть
HTTP 429 `busy`	идёт другой запуск	дождаться или остановить
Коды ошибок API	`invalid_input` 400, `not_found` 404, `unsupported_media_type` 415, `too_large` 413, `busy` 429, `internal` 500	детали в журнале; тело ответа не содержит трассы стека и путей

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

Изм.	**Номера листов (страниц)**			**Всего листов**	**№ докум.**	**Подп.**	**Дата**
	изменённых	замененных	новых				