_____

(наименование организации – заполнить)

УТВЕРЖДАЮ
Должность
_____
_____ / _____
«____» _____ 2026 г.
(поля подписи оставлены пустыми)

ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Локальный офлайн нейро-символический следователь по рассказам о Шерлоке Холмсе

ПРОГРАММА И МЕТОДИКА ИСПЫТАНИЙ

программного комплекса
ГОСТ 19.301-79

Обозначение документа: _____ (присваивается организацией)

Авторы:
Верховых Егор
Стрижевский Андрей
Парамонов Даниил
Приц Артём

Комплект программной документации ЕСПД, документ 6 из 8
Версия комплекса: 0.0.1 (pyproject.toml); состояние репозитория: main, коммит 16122fc
Дата составления: 30.10.2026. Статус: черновик, не согласован

2026

ЛИСТ СОГЛАСОВАНИЯ

Подписи, фамилии и даты не заполнены: документ составлен по состоянию репозитория и не согласован ни с кем.

Роль	Должность	Фамилия И. О.	Подпись	Дата
Разработал				
Проверил				
Нормоконтроль				
Утвердил				

СОДЕРЖАНИЕ

1 ОБЪЕКТ ИСПЫТАНИЙ....4
2 ЦЕЛЬ ИСПЫТАНИЙ....4
3 ТРЕБОВАНИЯ К ПРОГРАММЕ....4
4 ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ....5
5 СРЕДСТВА И ПОРЯДОК ИСПЫТАНИЙ....5
5.1 Средства испытаний....5
5.2 Состав наборов автоматических тестов....5
5.3 Порядок испытаний....6
6 МЕТОДЫ ИСПЫТАНИЙ....7
6.1 Автоматические тесты и статические проверки....7
6.2 Демо-режим без Ollama....7
6.3 Проверка офлайн-архива....7
6.4 Функциональные испытания на реальном стеке....8
6.5 Оценка качества (eval)....8
6.6 Тест «до раскрытия» и исследовательские эксперименты....9
6.7 Замеры времени и памяти....9
ПРИЛОЖЕНИЕ А....11
А.1 Оценка агента, test-срез (однократный прогон)....11
А.2 Тест «до раскрытия» (n = 16)....11
А.3 Офлайн-архив rc4....11
А.4 Время и память на целевом ноутбуке....12
А.5 Другие замеры....12
ПРИЛОЖЕНИЕ Б....14
ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ....15

Документ составлен по материалам репозитория и измерениям, лежащим в `docs/spike/results/` и `docs/perf/`, с помощью ИИ-ассистента; человеком не проверен и никем не согласован. Подписи, должности, даты согласования и обозначение документа оставлены пустыми намеренно.

Условные обозначения статуса сведений в комплекте. [Измерено] – число взято из файла отчёта, путь указан рядом. **[Не измерено]** – измерения нет. **[План]** – описано в проектных документах, в коде отсутствует или выключено. **[Заполнить]** – поле оставлено пустым для человека.

1 ОБЪЕКТ ИСПЫТАНИЙ

Объект – программный комплекс «Детективная доска» (Detective Board) версии 0.0.1 в составе, описанном в «Описании программы» (ОП), на коммите `16122fc` ветки `main` и в виде офлайн-архива (текущий кандидат – тег rc4, коммит 76f45ad; код после rc4 в нём отсутствует, `docs/perf/clean-install-20261029.md`). Испытания проводятся на целевом ноутбуке (ThinkPad X1 Carbon 7 поколения, i7-8665U, 15 ГиБ ОЗУ, Linux x86_64) и, для части проверок, на машине разработки без Ollama.

2 ЦЕЛЬ ИСПЫТАНИЙ

Проверить соответствие комплекса требованиям «Технического задания» (ТЗ), подтвердить воспроизводимость заявленных чисел и честно зафиксировать, что не измерялось. Испытания не доказывают корректность ответов относительно эталона, проверенного человеком: эталонные наборы написаны ИИ-ассистентом и не проверены (issue #9).

3 ТРЕБОВАНИЯ К ПРОГРАММЕ

Проверяются требования ТЗ, раздел 4 (ФТ-1…ФТ-11, надёжность, условия эксплуатации, совместимость). Соответствие требований методам испытаний – в таблице 4 раздела 6.7. Источник сценариев – критерии АС-01…АС-25 (`docs/acceptance/acceptance.md`); их пошаговая проверка при составлении документа не выполнялась **[Не измерено]**. Критериев приёмки по

числовым показателям качества заказчик не задавал: целевые значения в PRD – «TBD» кроме задержки (рабочий бюджет ≤ 40 с) и детерминизма правил (100 %).

4 ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ

Комплект документов (ТЗ, ПЗ, ОП, РО, РСП, ПМИ, ОПр, ФО) проверяется на полноту разделов по соответствующим ГОСТ и на согласованность перекрёстных ссылок; результат проверки – `CHECKLIST.md` комплекта. Оформление – ГОСТ 19.106-78, ГОСТ 2.105-95, ГОСТ 7.32-2017.

5 СРЕДСТВА И ПОРЯДОК ИСПЫТАНИЙ

5.1 Средства испытаний

Таблица 1 – Средства

Средство	Назначение	Где
pytest 9.1.1, pytest-cov 7.1.0	модульные и интеграционные тесты; маркеры `live`, `e2e`, `slow`; строгие маркеры	`tests/`, `pyproject.toml`
Node.js (встроенный раннер)	тесты логики интерфейса	`tests/web_js/*.test.mjs` (7 файлов)
ruff 0.17.1, pyright 1.1.414	стиль и типы	`just lint`, `just typecheck`
`eval/run_eval.py`	A/B-оценка конфигураций и правил по золотым наборам	`eval/`
`eval/pre_reveal.py`	тест «до раскрытия»	`eval/pre_reveal/cases.jsonl`
`scripts/preflight.py`, `verify_offline.sh`	готовность Ollama/моделей и проверка офлайн-архива	`scripts/`
FakeLLM и фиктивное окружение `--fake`	детерминированная замена модели в тестах и демо-режиме	`tests/`, `api/fixture.py`
Измерительные скрипты ноутбука	задержка по API и память процессов	`docs/perf/laptop-*.md`, `scripts/spike/`

5.2 Состав наборов автоматических тестов

Команда `uv run pytest -m "not live and not e2e"` собирает 986 тестов (**[Измерено]** на коммите 16122fc: «986 passed in 9.58s»; в архиве rc4: «976 passed, 2 skipped, 41.5 s», `docs/perf/clean-install-20261029.md`).

Таблица 2 – Тесты по каталогам (сбор тестов на коммите 16122fc)

Каталог	Тестов	Что покрывает
tests/agent/	264	агент: маршрутизатор, извлекающие ответы, правила-сначала, компакция контекста, связывание, таблица присутствия, доска сцены, безопасность, перевод, семантический R3
tests/extract/	158	привязка цитат, разбор, нормализация, ремонт, конвейер
tests/symbolic/	75	правила R1–R3 на мини-графах, детерминизм, готовность
tests/curated/	75	курируемые факты, их проверка и сцены
tests/presence/	79	проход присутствия и верификация
tests/graph/	66	хранилище графа, нормализация времени, якоря, реальные цитаты
tests/api/	64	эндпоинты, SSE, защита (Host, Origin, заголовки), пути, прогрев
tests/mcp/	59	инструменты, stdio-сервер, песочница, защита, паритет с модулем правил
tests/eval/	35	метрики, раннер, тест «до раскрытия»
tests/retrieval/	27	эмбеддер, поиск, хранилище, индекс предложений
tests/index/	11	сборка индексов
tests/*.py (корень)	73	приём корпуса, подсчёт извлечения, шарды, офлайн-скрипты, preflight, хэши vendor, сервер-отчёты

Порог покрытия в CI: 80 % ветвлений на src/detective_board (just test-cov); фактическое покрытие в документах репозитория не зафиксировано **[Не измерено]**.

5.3 Порядок испытаний

1) Автоматические тесты и статические проверки на машине без Ollama (раздел 6.1).
2) Проверка демо-режима just run --fake.
3) Проверка офлайн-архива на целевом ноутбуке без сети: verify_offline.sh --require-offline (раздел 6.3).
4) Функциональная проверка на реальном стеке по трём контрольным вопросам (раздел 6.4).
5) Оценка качества eval/run_eval.py по протоколу раздела 6.5 – на GPU-сервере или на целевом ноутбуке; на ноутбуке осмыслены только значения задержки.

6) Замеры времени и памяти (раздел 6.7) – в чистом окне: закрыть посторонние программы (VPN, Docker, медиа), питание от сети.

7) Заполнение протокола (приложение А) и подписание комиссией – **[Заполнить]**.

6 МЕТОДЫ ИСПЫТАНИЙ

6.1 Автоматические тесты и статические проверки

```
just setup
# ожидается: все тесты проходят (на 16122fc: 986 passed)
just test
# порог 80 %
just test-cov
just lint && just typecheck
# нужен Node.js
just test-web
```

Критерий: 100 % тестов зелёные; тест правил R1–R3 не пропускается и не перезапускается до зелёного. Правила покрыты мини-графами (3–8 узлов) с ручным ответом, повтор запуска даёт идентичный результат; MCP-инструмент и прямой вызов модуля правил дают равный результат (`tests/mcp/`, `tests/symbolic/`).

6.2 Демо-режим без Ollama

```
just run --fake
```

Вопрос «What was the speckled band?» даёт ответ с цитатой фрагмента `speckled-band-0001`; вопрос вне темы – отказ (`docs/api.md`). Критерий – соответствие ожидаемому поведению.

6.3 Проверка офлайн-архива

Шаги и критерии – `docs/team/CLEAN_INSTALL.md`. `verify_offline.sh --require-offline` проверяет: контрольные суммы всех файлов, отсутствие интернета, офлайн-установку окружения, быстрый набор тестов, соответствие идентификаторов моделей `MANIFEST`, `preflight`, контрольные вопросы API (g001 – ответ, c001 – нарушение R1, g047 – отказ, g056 – отказ). Критерий: каждая строка PASS, последняя `RESULT: PASS`. Приёмка заявлена на **двух** разных ноутбуках, один из них не принадлежит автору архива.

6.4 Функциональные испытания на реальном стеке

Таблица 3 – Контрольные вопросы

Идентификатор	Вопрос	Ожидание
g001	What kind of snake killed Dr. Grimesby Roylott?	ответ: «It is a swamp adder!», метка source_text
c001	Is there a conflict about where Aloysius Garcia was at about one o'clock on the night he died?	правило R1 нарушено; conditional; пометка curated; две цитаты
g047	What was the creature that haunted the Baskerville family on the Devonshire moor?	отказ шлюзом, без вызова модели
g056	(второй вопрос вне корпуса, `eval/golden/questions.jsonl`)	отказ

6.5 Оценка качества (eval)

Наборы. `eval/golden/questions.jsonl` – 64 вопроса (категории: факт, многошаговый, связь, хронология, противоречие свидетельств, алиби, межрассказный, вне корпуса, состязательный, русский язык); `eval/golden/contradictions.jsonl` – 43 случая; `eval/extraction_gold/` и 12 размеченных фрагментов; `eval/pre_reveal/cases.jsonl` – 16 вопросов в 8 рассказах. Разбиение dev/test детерминировано (`eval/golden/split.json`, хэш sha256 от seed и идентификатора, расслоено по категориям). Эталоны написаны ИИ-ассистентом.

Конфигурации (генератор везде `qwen3:4b-instruct`, thinking выключен): `bare` – вопрос модели без поиска; `vector` – только поиск bge-m3, топ-4 фрагмента в путь ответа агента (отдельный порог `--vector-min-score`, по умолчанию 0); `vector+rerank` – «не запускалось» (локального реранкера нет); `hybrid+graph` – реальный агент (гибридный поиск, индекс предложений, граф, правила, извлекающий ответ).

Метрики (механические прокси, LLM-судьи нет): «поведение корректно» – отвечаемый вопрос отвечен с покрытием ключевых фактов ≥ 0,5, вопрос вне корпуса отклонён; «цитата верна» – цитата дословна в процитированном фрагменте и фрагмент – из золотых; «предложение-цитата попало» – цитата пересекается с золотой; точность, полнота и доля ложных отказов; recall@1/4/6 фрагментов; recall предложений @1/5/20; обнаружение

противоречий (только правила). У каждой доли – доверительный интервал Уилсона 95 % и n; конфигурации сравниваются парами точным критерием Макнемара.

Протокол. (1) Результаты dev фиксируются коммитом до запуска test (неотслеживаемые файлы считаются изменениями). (2) Пороги, включая `--vector-min-score`, подбираются только на dev. (3) Test-срез запускается один раз на замороженную конфигурацию; запуск с незакоммиченными изменениями отклоняется; повторный запуск для той же пары «коммит, конфигурация» отклоняется. (4) К каждому числу прикладываются SHA коммита и хэш конфигурации. (5) Результат никогда не перезаписывается. Предрегистрация test-прогона: docs/spike/results/test-preregistration-20261028.md.

```
# 8 вопросов dev, FakeLLM, образцовый индекс, без сети
just eval --short
# реальный стек
just eval --split dev
# один раз на замороженную конфигурацию
just eval --split test
```

6.6 Тест «до раскрытия» и исследовательские эксперименты

`just pre-reveal` запускает агента на полном корпусе и на корпусе, обрезанном перед местом, где названа разгадка, плюс «голую» модель; основная метрика – назван ли виновник (имя или псевдоним) в ответе или цитатах. Это лексический прокси, а не чтение человеком. Результаты – раздел A.2. Угадывание виновного (ветка `feat/suspects-matrix`) и семантический R3 – исследовательские, не в `main` или выключены и в приёмочные испытания не входят.

6.7 Замеры времени и памяти

Метод: 18 различных отвечаемых вопросов dev-среза, три серии по 6 с паузой 20 с (как на сцене), разные вопросы, чтобы кэш префикса не превращал повторы в трёхсекундные ответы; модели выгружены перед первым вопросом; регистрируются полное время ответа, пик памяти процессов llama-server и температура корпуса процессора (`docs/perf/laptop-20261029.md`). Правила

измерения (RSS в дочернем процессе, выгрузка других моделей, учёт троттлинга, разделение холодной и тёплой загрузки) – `docs/test-plan.md`, раздел 8.

Таблица 4 – Соответствие требований ТЗ методам испытаний

Требование ТЗ	Метод	Последний результат
ФТ-1 ответ с цитатой	6.2, 6.4, 6.5	A.1: test 13/30 (на метках ИИ)
ФТ-2 правила R1–R3	6.1, 6.4, 6.5	986 passed; A.1: полнота 0/12 на автоматических фактах
ФТ-3 отказ	6.4, 6.5	A.1: полнота отказов 6/6, точность 6/12
ФТ-4 интерфейс	6.1 (`test-web`), осмотр	тесты интерфейса не запускались при составлении (нет Node.js); осмотр – **[Заполнить]**
ФТ-5 MCP	6.1 (`tests/mcp/`)	включено в 986
ФТ-6 метки	6.1, осмотр ответов	включено в 986
ФТ-7 оценка	6.5	A.1
ФТ-8 единый источник	6.1 (тест паритета)	включено в 986
ФТ-9 офлайн-запуск	6.3	A.3: одна машина; вторая – не выполнено
ФТ-10 русский вопрос	осмотр	**[Не измерено]**
Задержка ≤ 40 с	6.7	A.4: медиана 28,4 с; не в чистом окне

ПРИЛОЖЕНИЕ А

(справочное)

Результаты уже выполненных проверок (на дату составления)

Приложение сводит измерения, найденные в репозитории. Это не протокол приёмочных испытаний данной редакции.

А.1 Оценка агента, test-срез (однократный прогон)

Таблица А.1 – `docs/spike/results/eval-2026-10-28-test-7b7b197-7857839ed9be-175321.md`; коммит 7b7b197, хэш конфигурации 7857839ed9be, n=30

Показатель	bare	vector	hybrid+graph
Поведение корректно	3/30 (10 %)	11/30 (37 %)	13/30 (43 %), ДИ 27–61 %
Все цитаты верны (из отвеченных)	н/п	6/18	7/18
Полнота отказов	2/6	6/6	6/6
Точность отказов	2/20	6/12	6/12
recall@4 фрагмента	н/п	16/24	16/24
Медиана полного времени, с	35,1	30,4	29,3
Обнаружение противоречий (правила)	—	—	полнота 0/12; ложных 0/8

Парные сравнения (точный критерий Макнемара): bare–hybrid+graph p = 0,0063; vector–hybrid+graph p = 0,5.

А.2 Тест «до раскрытия» (n = 16)

Файл: `docs/spike/results/pre-reveal-2026-10-28-rescored.md`.

Условие	Виновник назван	Отказ
A. полный корпус	2/16 (12 %)	5/16
B. корпус обрезан перед раскрытием	0/16	5/16
C. голая модель	1/16	13/16

Различия не значимы (A против B p = 0,5; A против C p = 1). Прогон выполнен на «грязном» дереве (коммит 0e00f58), оценка пересчитана без повторного запуска модели.

А.3 Офлайн-архив rc4

Файл: `docs/perf/clean-install-20261029.md`.

Шаг	Результат
Контрольные суммы	PASS, 11 291 файл

Шаг	Результат
Без сети	PASS
Офлайн-установка окружения	PASS, Python 3.12.15
Тесты	PASS, 976 passed, 2 skipped, 41,5 с
Ollama из архива	PASS, 3 модели совпадают с MANIFEST
preflight	PASS
g001 / c001 / g047 / g056	ответ 148,3 с / R1 нарушено 4,6 с / отказ 1,5 с / отказ 95,8 с

Ограничения: одна машина (ноутбук автора архива), модели уже были на диске; медленные ответы (148 с, 96 с) – не измерение скорости (параллельно шёл другой эксперимент и включалась холодная загрузка). Проверка на двух разных ноутбуках не выполнена. Заявление «установка менее 15 минут» не измерено.

A.4 Время и память на целевом ноутбуке

Файл: `docs/perf/laptop-20261029.md`.

Серия	Медиана, с	Диапазон, с	Пик ОЗУ, МБ	Макс. температура, °C
1 (холодный старт первым)	33,3	29,2–44,1	4991	98
2	26,1	18,6–28,4	5659	99
3	28,3	23,9–29,4	6289	98

Все 18 вопросов: медиана 28,4 с по 16 отвеченным, 90-й процентиль 33,8 с, 2 из 18 отказ (модель выбрала NONE). Условия: не чистое окно, один день, одна машина; профиль 8 ГБ не проверялся.

A.5 Другие замеры

Что	Результат	Файл
Граф полного корпуса	596/596 чанков, 5278 узлов до курируемых фактов	`docs/spike/results/graph-sanity-20261028.md`
Проход присутствия	оставлено 16 (qwen3:8b) и 7 (qwen3:4b-instruct) фактов на 159 чанках	`docs/spike/results/presence-pass-server-20261029.md`
Вопросы dev, рескоринг	bare 4/34, vector 15/34, agent 12/34	`docs/spike/results/eval-2026-10-28-dev-ab945e8-78b3bbb3f2a6-145202-rescored.md`
Семантический R3, dev	строгая полнота 1/14, ложных на контролях 8/9	`docs/spike/results/r3-semantic-dev-judge-r3j2.md`

Что	Результат	Файл
Угадывание виновного, 6 новых рассказов (ветка `feat/suspects-matrix`)	виновный первым 2 из 6, как «самый упоминаемый» (2 из 6); интервал Уилсона 0,10–0,70; один оправданный назван первым	`docs/spike/results/suspects-20261030.md` (на ветке, не в `main`)
Скорость доски, PR #30 (headless Chromium, мс до → после)	14 карточек: сдвиг 2400 → 225, масштаб 2100 → 315; 200 узлов: 2060 → 384 и 13 900 → 2780; не на ноутбуке, разброс на масштабе большой	описание PR #30 на GitHub
12 вопросов через API	извлекающий режим 8–20 с против 45–140 с	`docs/spike/results/api12-20261027-extractive.md`, `api12-20261027-generative.md`

ПРИЛОЖЕНИЕ Б

(рекомендуемое)

Форма протокола приёмочных испытаний

Форма не заполнена: подписи, даты, фамилии и результаты вносятся комиссией.

№	Проверка (раздел ПМИ)	Результат	Замечания
1	Автоматические тесты (6.1)		
2	Демо-режим (6.2)		
3	Офлайн-архив на ноутбуке 1 (6.3)		
4	Офлайн-архив на ноутбуке 2 (6.3)		
5	Контрольные вопросы g001, c001, g047, g056 (6.4)		
6	Оценка dev и test (6.5)		
7	Замеры времени и памяти (6.7)		
8	Проверка документации (раздел 4)		

Роль	Фамилия И. О.	Подпись	Дата
Председатель комиссии			
Член комиссии			
Исполнитель			

ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

Изм.	**Номера листов (страниц)**			**Всего листов**	**№ докум.**	**Подп.**	**Дата**
	изменённых	замененных	новых				