_____

(наименование организации – заполнить)

**УТВЕРЖДАЮ**
Должность
_____
_____ / _____
«____» _____ 2026 г.
*(поля подписи оставлены пустыми)*

# ДЕТЕКТИВНАЯ ДОСКА (Detective Board)

Локальный офлайн нейро-символический следователь по рассказам о Шерлоке Холмсе

# ПРОГРАММА И МЕТОДИКА ИСПЫТАНИЙ

программного комплекса
ГОСТ 19.301-79

Обозначение документа: _____ (присваивается организацией)

**Авторы:**
Верховых Егор
Стрижевский Андрей
Парамонов Даниил
Приц Артём

Комплект программной документации ЕСПД, документ 6 из 8
Версия комплекса: 0.0.1 (pyproject.toml); состояние репозитория: main, коммит 16122fc
Дата составления: 30.10.2026. Статус: черновик, не согласован

2026

## ЛИСТ СОГЛАСОВАНИЯ

Подписи, фамилии и даты не заполнены: документ составлен по состоянию репозитория и не согласован ни с кем.

| Роль | Должность | Фамилия И. О. | Подпись | Дата |
|---|---|---|---|---|
| Разработал | | | | |
| Проверил | | | | |
| Нормоконтроль | | | | |
| Утвердил | | | | |

**СОДЕРЖАНИЕ**

1 ОБЪЕКТ ИСПЫТАНИЙ....4
2 ЦЕЛЬ ИСПЫТАНИЙ....4
3 ТРЕБОВАНИЯ К ПРОГРАММЕ....4
4 ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ....5
5 СРЕДСТВА И ПОРЯДОК ИСПЫТАНИЙ....5
5.1 Средства испытаний....5
5.2 Состав наборов автоматических тестов....5
5.3 Порядок испытаний....6
6 МЕТОДЫ ИСПЫТАНИЙ....7
6.1 Автоматические тесты и статические проверки....7
6.2 Демо-режим без Ollama....7
6.3 Проверка офлайн-архива....7
6.4 Функциональные испытания на реальном стеке....8
6.5 Оценка качества (eval)....8
6.6 Тест «до раскрытия» и исследовательские эксперименты....9
6.7 Замеры времени и памяти....9
ПРИЛОЖЕНИЕ А....11
А.1 Оценка агента, test-срез (однократный прогон)....11
А.2 Тест «до раскрытия» (n = 16)....11
А.3 Офлайн-архив rc4....11
А.4 Время и память на целевом ноутбуке....12
А.5 Другие замеры....12
ПРИЛОЖЕНИЕ Б....14
ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ....15

Документ составлен по материалам репозитория и измерениям, лежащим в `docs/spike/results/` и `docs/perf/`, с помощью ИИ-ассистента; человеком не проверен и никем не согласован. Подписи, должности, даты согласования и обозначение документа оставлены пустыми намеренно.

**Условные обозначения статуса сведений в комплекте. [Измерено]** – число взято из файла отчёта, путь указан рядом. **[Не измерено]** – измерения нет. **[План]** – описано в проектных документах, в коде отсутствует или выключено. **[Заполнить]** – поле оставлено пустым для человека.

## 1 ОБЪЕКТ ИСПЫТАНИЙ

Объект – программный комплекс «Детективная доска» (Detective Board) версии 0.0.1 в составе, описанном в «Описании программы» (ОП), на коммите `16122fc` ветки `main` и в виде офлайн-архива (текущий кандидат – тег rc4, коммит 76f45ad; код после rc4 в нём отсутствует, `docs/perf/clean-install-20261029.md`). Испытания проводятся на целевом ноутбуке (ThinkPad X1 Carbon 7 поколения, i7-8665U, 15 ГиБ ОЗУ, Linux x86_64) и, для части проверок, на машине разработки без Ollama.

## 2 ЦЕЛЬ ИСПЫТАНИЙ

Проверить соответствие комплекса требованиям «Технического задания» (ТЗ), подтвердить воспроизводимость заявленных чисел и честно зафиксировать, что не измерялось. Испытания не доказывают корректность ответов относительно эталона, проверенного человеком: эталонные наборы написаны ИИ-ассистентом и не проверены (issue #9).

## 3 ТРЕБОВАНИЯ К ПРОГРАММЕ

Проверяются требования ТЗ, раздел 4 (ФТ-1…ФТ-11, надёжность, условия эксплуатации, совместимость). Соответствие требований методам испытаний – в таблице 4 раздела 6.7. Источник сценариев – критерии АС-01…АС-25 (`docs/acceptance/acceptance.md`); их пошаговая проверка при составлении документа не выполнялась **[Не измерено]**. Критериев приёмки по

числовым показателям качества заказчик не задавал: целевые значения в PRD – «TBD» кроме задержки (рабочий бюджет ≤ 40 с) и детерминизма правил (100 %).

## 4 ТРЕБОВАНИЯ К ПРОГРАММНОЙ ДОКУМЕНТАЦИИ

Комплект документов (ТЗ, ПЗ, ОП, РО, РСП, ПМИ, ОПр, ФО) проверяется на полноту разделов по соответствующим ГОСТ и на согласованность перекрёстных ссылок; результат проверки – `CHECKLIST.md` комплекта. Оформление – ГОСТ 19.106-78, ГОСТ 2.105-95, ГОСТ 7.32-2017.

## 5 СРЕДСТВА И ПОРЯДОК ИСПЫТАНИЙ

### 5.1 Средства испытаний

Таблица 1 – Средства

| Средство | Назначение | Где |
|---|---|---|
| pytest 9.1.1, pytest-cov 7.1.0 | модульные и интеграционные тесты; маркеры `live`, `e2e`, `slow`; строгие маркеры | `tests/`, `pyproject.toml` |
| Node.js (встроенный раннер) | тесты логики интерфейса | `tests/web_js/*.test.mjs` (7 файлов) |
| ruff 0.17.1, pyright 1.1.414 | стиль и типы | `just lint`, `just typecheck` |
| `eval/run_eval.py` | A/B-оценка конфигураций и правил по золотым наборам | `eval/` |
| `eval/pre_reveal.py` | тест «до раскрытия» | `eval/pre_reveal/cases.jsonl` |
| `scripts/preflight.py`, `verify_offline.sh` | готовность Ollama/моделей и проверка офлайн-архива | `scripts/` |
| FakeLLM и фиктивное окружение `--fake` | детерминированная замена модели в тестах и демо-режиме | `tests/`, `api/fixture.py` |
| Измерительные скрипты ноутбука | задержка по API и память процессов | `docs/perf/laptop-*.md`, `scripts/spike/` |

### 5.2 Состав наборов автоматических тестов

Команда `uv run pytest -m "not live and not e2e"` собирает 986 тестов (**[Измерено]** на коммите 16122fc: «986 passed in 9.58s»; в архиве rc4: «976 passed, 2 skipped, 41.5 s», `docs/perf/clean-install-20261029.md`).

Таблица 2 – Тесты по каталогам (сбор тестов на коммите 16122fc)

| Каталог | Тестов | Что покрывает |
|---|---|---|
| tests/agent/ | 264 | агент: маршрутизатор, извлекающие ответы, правила-сначала, компакция контекста, связывание, таблица присутствия, доска сцены, безопасность, перевод, семантический R3 |
| tests/extract/ | 158 | привязка цитат, разбор, нормализация, ремонт, конвейер |
| tests/symbolic/ | 75 | правила R1–R3 на мини-графах, детерминизм, готовность |
| tests/curated/ | 75 | курируемые факты, их проверка и сцены |
| tests/presence/ | 79 | проход присутствия и верификация |
| tests/graph/ | 66 | хранилище графа, нормализация времени, якоря, реальные цитаты |
| tests/api/ | 64 | эндпоинты, SSE, защита (Host, Origin, заголовки), пути, прогрев |
| tests/mcp/ | 59 | инструменты, stdio-сервер, песочница, защита, паритет с модулем правил |
| tests/eval/ | 35 | метрики, раннер, тест «до раскрытия» |
| tests/retrieval/ | 27 | эмбеддер, поиск, хранилище, индекс предложений |
| tests/index/ | 11 | сборка индексов |
| tests/*.py (корень) | 73 | приём корпуса, подсчёт извлечения, шарды, офлайн-скрипты, preflight, хэши vendor, сервер-отчёты |

Порог покрытия в CI: 80 % ветвлений на src/detective_board (just test-cov); фактическое покрытие в документах репозитория не зафиксировано **[Не измерено]**.

### 5.3 Порядок испытаний

1) Автоматические тесты и статические проверки на машине без Ollama (раздел 6.1).
2) Проверка демо-режима just run --fake.
3) Проверка офлайн-архива на целевом ноутбуке без сети: verify_offline.sh --require-offline (раздел 6.3).
4) Функциональная проверка на реальном стеке по трём контрольным вопросам (раздел 6.4).
5) Оценка качества eval/run_eval.py по протоколу раздела 6.5 – на GPU-сервере или на целевом ноутбуке; на ноутбуке осмыслены только значения задержки.

6) Замеры времени и памяти (раздел 6.7) – в чистом окне: закрыть посторонние программы (VPN, Docker, медиа), питание от сети.

7) Заполнение протокола (приложение А) и подписание комиссией – **[Заполнить]**.

# 6 МЕТОДЫ ИСПЫТАНИЙ

## 6.1 Автоматические тесты и статические проверки

```
just setup
# ожидается: все тесты проходят (на 16122fc: 986 passed)
just test
# порог 80 %
just test-cov
just lint && just typecheck
# нужен Node.js
just test-web
```

Критерий: 100 % тестов зелёные; тест правил R1–R3 не пропускается и не перезапускается до зелёного. Правила покрыты мини-графами (3–8 узлов) с ручным ответом, повтор запуска даёт идентичный результат; MCP-инструмент и прямой вызов модуля правил дают равный результат (`tests/mcp/`, `tests/symbolic/`).

## 6.2 Демо-режим без Ollama

```
just run --fake
```

Вопрос «What was the speckled band?» даёт ответ с цитатой фрагмента `speckled-band-0001`; вопрос вне темы – отказ (`docs/api.md`). Критерий – соответствие ожидаемому поведению.

## 6.3 Проверка офлайн-архива

Шаги и критерии – `docs/team/CLEAN_INSTALL.md`. `verify_offline.sh --require-offline` проверяет: контрольные суммы всех файлов, отсутствие интернета, офлайн-установку окружения, быстрый набор тестов, соответствие идентификаторов моделей `MANIFEST`, `preflight`, контрольные вопросы API (g001 – ответ, c001 – нарушение R1, g047 – отказ, g056 – отказ). Критерий: каждая строка PASS, последняя `RESULT: PASS`. Приёмка заявлена на **двух** разных ноутбуках, один из них не принадлежит автору архива.

### 6.4 Функциональные испытания на реальном стеке

Таблица 3 – Контрольные вопросы

| Идентификатор | Вопрос | Ожидание |
|---|---|---|
| g001 | What kind of snake killed Dr. Grimesby Roylott? | ответ: «It is a swamp adder!», метка source_text |
| c001 | Is there a conflict about where Aloysius Garcia was at about one o'clock on the night he died? | правило R1 нарушено; conditional; пометка curated; две цитаты |
| g047 | What was the creature that haunted the Baskerville family on the Devonshire moor? | отказ шлюзом, без вызова модели |
| g056 | (второй вопрос вне корпуса, `eval/golden/questions.jsonl`) | отказ |

### 6.5 Оценка качества (eval)

**Наборы.** `eval/golden/questions.jsonl` – 64 вопроса (категории: факт, многошаговый, связь, хронология, противоречие свидетельств, алиби, межрассказный, вне корпуса, состязательный, русский язык); `eval/golden/contradictions.jsonl` – 43 случая; `eval/extraction_gold/` и 12 размеченных фрагментов; `eval/pre_reveal/cases.jsonl` – 16 вопросов в 8 рассказах. Разбиение dev/test детерминировано (`eval/golden/split.json`, хэш sha256 от seed и идентификатора, расслоено по категориям). Эталоны написаны ИИ-ассистентом.

**Конфигурации** (генератор везде `qwen3:4b-instruct`, thinking выключен): `bare` – вопрос модели без поиска; `vector` – только поиск bge-m3, топ-4 фрагмента в путь ответа агента (отдельный порог `--vector-min-score`, по умолчанию 0); `vector+rerank` – «не запускалось» (локального реранкера нет); `hybrid+graph` – реальный агент (гибридный поиск, индекс предложений, граф, правила, извлекающий ответ).

**Метрики** (механические прокси, LLM-судьи нет): «поведение корректно» – отвечаемый вопрос отвечен с покрытием ключевых фактов ≥ 0,5, вопрос вне корпуса отклонён; «цитата верна» – цитата дословна в процитированном фрагменте и фрагмент – из золотых; «предложение-цитата попало» – цитата пересекается с золотой; точность, полнота и доля ложных отказов; recall@1/4/6 фрагментов; recall предложений @1/5/20; обнаружение

противоречий (только правила). У каждой доли – доверительный интервал Уилсона 95 % и n; конфигурации сравниваются парами точным критерием Макнемара.

**Протокол.** (1) Результаты dev фиксируются коммитом до запуска test (неотслеживаемые файлы считаются изменениями). (2) Пороги, включая `--vector-min-score`, подбираются только на dev. (3) Test-срез запускается один раз на замороженную конфигурацию; запуск с незакоммиченными изменениями отклоняется; повторный запуск для той же пары «коммит, конфигурация» отклоняется. (4) К каждому числу прикладываются SHA коммита и хэш конфигурации. (5) Результат никогда не перезаписывается. Предрегистрация test-прогона: [docs/spike/results/test-preregistration-20261028.md](docs/spike/results/test-preregistration-20261028.md).

```
# 8 вопросов dev, FakeLLM, образцовый индекс, без сети
just eval --short
# реальный стек
just eval --split dev
# один раз на замороженную конфигурацию
just eval --split test
```

### 6.6 Тест «до раскрытия» и исследовательские эксперименты

`just pre-reveal` запускает агента на полном корпусе и на корпусе, обрезанном перед местом, где названа разгадка, плюс «голую» модель; основная метрика – назван ли виновник (имя или псевдоним) в ответе или цитатах. Это лексический прокси, а не чтение человеком. Результаты – раздел A.2. Эксперименты с выбором сущности для вопросов «кто» и семантическим R3 – исследовательские, выключены и в приёмочные испытания не входят.

### 6.7 Замеры времени и памяти

Метод: 18 различных отвечаемых вопросов dev-среза, три серии по 6 с паузой 20 с (как на сцене), разные вопросы, чтобы кэш префикса не превращал повторы в трёхсекундные ответы; модели выгружены перед первым вопросом; регистрируются полное время ответа, пик памяти процессов llama-server и температура корпуса процессора (`docs/perf/laptop-20261029.md`). Правила измерения (RSS в дочернем процессе, выгрузка других моделей, учёт

троттлинга, разделение холодной и тёплой загрузки) – `docs/test-plan.md`, раздел 8.

Таблица 4 – Соответствие требований ТЗ методам испытаний

| Требование ТЗ | Метод | Последний результат |
|---|---|---|
| ФТ-1 ответ с цитатой | 6.2, 6.4, 6.5 | A.1: test 13/30 (на метках ИИ) |
| ФТ-2 правила R1–R3 | 6.1, 6.4, 6.5 | 986 passed; A.1: полнота 0/12 на автоматических фактах |
| ФТ-3 отказ | 6.4, 6.5 | A.1: полнота отказов 6/6, точность 6/12 |
| ФТ-4 интерфейс | 6.1 (`test-web`), осмотр | тесты интерфейса не запускались при составлении (нет Node.js); осмотр – **[Заполнить]** |
| ФТ-5 MCP | 6.1 (`tests/mcp/`) | включено в 986 |
| ФТ-6 метки | 6.1, осмотр ответов | включено в 986 |
| ФТ-7 оценка | 6.5 | A.1 |
| ФТ-8 единый источник | 6.1 (тест паритета) | включено в 986 |
| ФТ-9 офлайн-запуск | 6.3 | A.3: одна машина; вторая – не выполнено |
| ФТ-10 русский вопрос | осмотр | **[Не измерено]** |
| Задержка ≤ 40 с | 6.7 | A.4: медиана 28,4 с; не в чистом окне |

## ПРИЛОЖЕНИЕ А

(справочное)

### Результаты уже выполненных проверок (на дату составления)

Приложение сводит измерения, найденные в репозитории. Это не протокол приёмочных испытаний данной редакции.

### А.1 Оценка агента, test-срез (однократный прогон)

Таблица А.1 – `docs/spike/results/eval-2026-10-28-test-7b7b197-7857839ed9be-175321.md`; коммит 7b7b197, хэш конфигурации 7857839ed9be, n=30

| Показатель | bare | vector | hybrid+graph |
|---|---|---|---|
| Поведение корректно | 3/30 (10 %) | 11/30 (37 %) | 13/30 (43 %), ДИ 27–61 % |
| Все цитаты верны (из отвеченных) | н/п | 6/18 | 7/18 |
| Полнота отказов | 2/6 | 6/6 | 6/6 |
| Точность отказов | 2/20 | 6/12 | 6/12 |
| recall@4 фрагмента | н/п | 16/24 | 16/24 |
| Медиана полного времени, с | 35,1 | 30,4 | 29,3 |
| Обнаружение противоречий (правила) | — | — | полнота 0/12; ложных 0/8 |

Парные сравнения (точный критерий Макнемара): bare–hybrid+graph p = 0,0063; vector–hybrid+graph p = 0,5.

### А.2 Тест «до раскрытия» (n = 16)

Файл: `docs/spike/results/pre-reveal-2026-10-28-rescored.md`.

| Условие | Виновник назван | Отказ |
|---|---|---|
| A. полный корпус | 2/16 (12 %) | 5/16 |
| B. корпус обрезан перед раскрытием | 0/16 | 5/16 |
| C. голая модель | 1/16 | 13/16 |

Различия не значимы (A против B p = 0,5; A против C p = 1). Прогон выполнен на «грязном» дереве (коммит 0e00f58), оценка пересчитана без повторного запуска модели.

### А.3 Офлайн-архив rc4

Файл: `docs/perf/clean-install-20261029.md`.

| Шаг | Результат |
|---|---|
| Контрольные суммы | PASS, 11 291 файл |

| Шаг | Результат |
|---|---|
| Без сети | PASS |
| Офлайн-установка окружения | PASS, Python 3.12.15 |
| Тесты | PASS, 976 passed, 2 skipped, 41,5 с |
| Ollama из архива | PASS, 3 модели совпадают с MANIFEST |
| preflight | PASS |
| g001 / c001 / g047 / g056 | ответ 148,3 с / R1 нарушено 4,6 с / отказ 1,5 с / отказ 95,8 с |

Ограничения: одна машина (ноутбук автора архива), модели уже были на диске; медленные ответы (148 с, 96 с) – не измерение скорости (параллельно шёл другой эксперимент и включалась холодная загрузка). Проверка на двух разных ноутбуках не выполнена. Заявление «установка менее 15 минут» не измерено.

### A.4 Время и память на целевом ноутбуке

Файл: `docs/perf/laptop-20261029.md`.

| Серия | Медиана, с | Диапазон, с | Пик ОЗУ, МБ | Макс. температура, °C |
|---|---|---|---|---|
| 1 (холодный старт первым) | 33,3 | 29,2–44,1 | 4991 | 98 |
| 2 | 26,1 | 18,6–28,4 | 5659 | 99 |
| 3 | 28,3 | 23,9–29,4 | 6289 | 98 |

Все 18 вопросов: медиана 28,4 с по 16 отвеченным, 90-й процентиль 33,8 с, 2 из 18 отказ (модель выбрала NONE). Условия: не чистое окно, один день, одна машина; профиль 8 ГБ не проверялся.

### A.5 Другие замеры

| Что | Результат | Файл |
|---|---|---|
| Граф полного корпуса | 596/596 чанков, 5278 узлов до курируемых фактов | `docs/spike/results/graph-sanity-20261028.md` |
| Проход присутствия | оставлено 16 (qwen3:8b) и 7 (qwen3:4b-instruct) фактов на 159 чанках | `docs/spike/results/presence-pass-server-20261029.md` |
| Вопросы dev, рескоринг | bare 4/34, vector 15/34, agent 12/34 | `docs/spike/results/eval-2026-10-28-dev-ab945e8-78b3bbb3f2a6-145202-rescored.md` |
| Семантический R3, dev | строгая полнота 1/14, ложных на контролях 8/9 | `docs/spike/results/r3-semantic-dev-judge-r3j2.md` |
| Выбор сущности («кто») | верный виновник 1/8 строго; невиновный назван 2/8 | `docs/spike/results/entity-answer-2026-10-29.md` |

| Что | Результат | Файл |
| --- | --- | --- |
| 12 вопросов через API | извлекающий режим 8–20 с против 45–140 с | docs/spike/results/api12-20261027-extractive.md, api12-20261027-generative.md |

## ПРИЛОЖЕНИЕ Б

(рекомендуемое)

### Форма протокола приёмочных испытаний

Форма не заполнена: подписи, даты, фамилии и результаты вносятся комиссией.

| № | Проверка (раздел ПМИ) | Результат | Замечания |
|---|---|---|---|
| 1 | Автоматические тесты (6.1) | | |
| 2 | Демо-режим (6.2) | | |
| 3 | Офлайн-архив на ноутбуке 1 (6.3) | | |
| 4 | Офлайн-архив на ноутбуке 2 (6.3) | | |
| 5 | Контрольные вопросы g001, c001, g047, g056 (6.4) | | |
| 6 | Оценка dev и test (6.5) | | |
| 7 | Замеры времени и памяти (6.7) | | |
| 8 | Проверка документации (раздел 4) | | |

| Роль | Фамилия И. О. | Подпись | Дата |
|---|---|---|---|
| Председатель комиссии | | | |
| Член комиссии | | | |
| Исполнитель | | | |

## ЛИСТ РЕГИСТРАЦИИ ИЗМЕНЕНИЙ

| **Изм.** | **Номера листов (страниц)** | | | **Всего листов** | **№ докум.** | **Подп.** | **Дата** |
|---|---|---|---|---|---|---|---|
| | изменённых | замененных | новых | | | | |
| | | | | | | | |
| | | | | | | | |
| | | | | | | | |
| | | | | | | | |