Проект

Детективная доска

Detective Board

Локальный офлайн-следователь по 20 рассказам о Шерлоке Холмсе

Авторы:

Верховых Егор

Стрижевский Андрей

Парамонов Даниил

Приц Артём

30.10.2026

Цель и задачи

Цель: отвечать по тексту рассказов и показывать, на чём держится ответ.

1. Достать из текста факты вместе с дословными цитатами.
2. Проверить факты правилами, а не мнением модели.
3. Честно отказываться, если в тексте ответа нет.
4. Измерить качество и записать слабые места.

Зачем это нужно

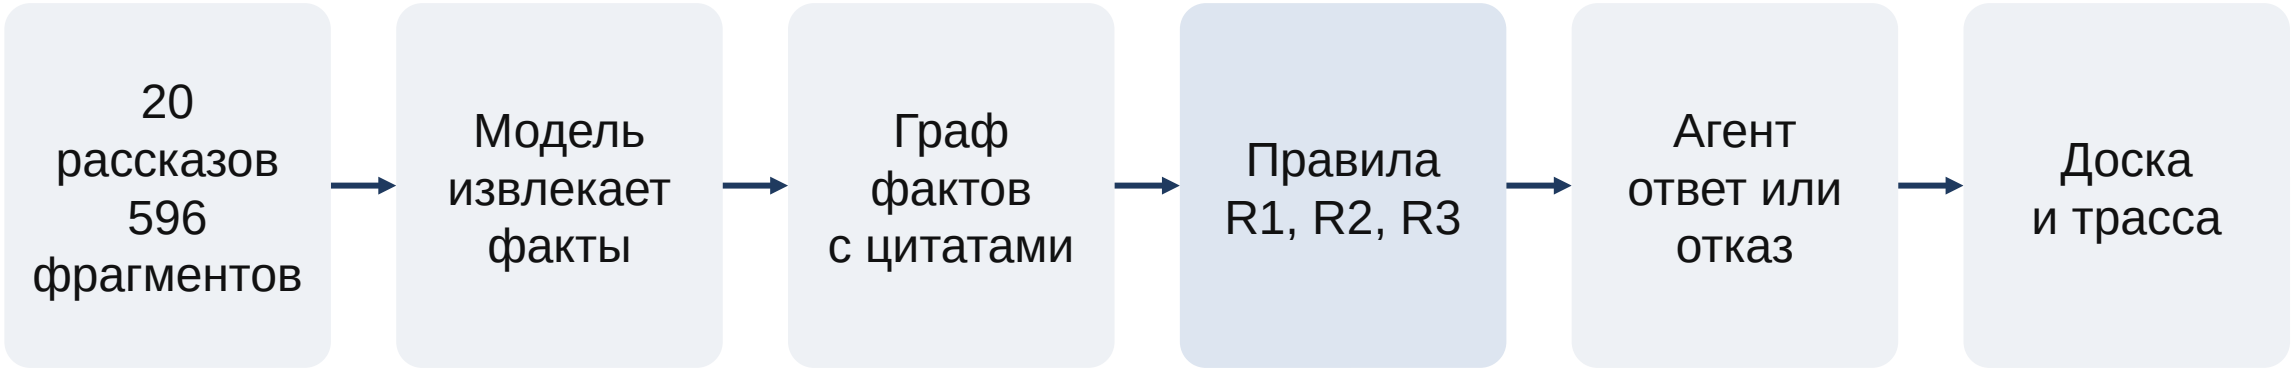
Обычная языковая модель отвечает уверенно, даже когда не знает.

Она выдумывает факты и цитаты.

Без поиска по тексту верный ответ только на 3 из 30 вопросов (test, n=30).

Наш ответ: цитата из текста или отказ

Как устроено



Модель угадывает, правила проверяют.

Всё работает на одном ноутбуке без сети.

Откуда взят каждый факт

extracted
достала модель;
может ошибаться

derived
вывело правило;
есть объяснение

conditional
правило на
сомнительном факте

В демо есть ещё curated: введены вручную, перепроверены человеком 29.10.2026; вывод conditional.

Три правила

R1. Человек не может быть в двух местах сразу.

R2. Порядок событий не замыкается в круг.

R3. Слова свидетеля не спорят с установленным фактом.

Нет данных — ответ «неизвестно», а не «всё согласовано».

Результат: вопросы с ответом или отказом



Тест на 30 вопросах; метки ответов размечены автоматически, человек не проверял.

Что пока не работает

Правила на автоматическом графе: найдено 0 из 12 противоречий.

Извлечение «кто где был»: оставлено 16 и 7 фактов на 159 фрагментах.

Из них ни один не привязан ко дню рассказа.

Эталон для проверки — всего 4 строгих факта.

Источник: отчёт о проходе присутствия (PR #29).

Скорость, интерфейс, тесты

Ответ на ноутбуке без GPU: медиана 28,4 с (замер не в чистом окне).
Доска, 14 карточек: сдвиг 2400 → 225 мс, масштаб 2100 → 315 мс.
Доска, 200 узлов: сдвиг 2060 → 384 мс, масштаб 13 900 → 2 780 мс.
Шум на масштабе большой; на ноутбуке не измерено.
Автотесты: 986 прошли за 9,6 с.

PR #30: время растеризации, headless Chromium, скриптовые сдвиг и масштаб. В покое картинка прежняя (отличие 1,5 из 255).

Угадывание виновного: ненадёжно

Тест (8 рассказов, один прогон): ни один метод не лучше простых.
Dev (8): лучший из ~35 вариантов угадал 4 из 8 – цифра завышена.
6 новых рассказов: верно 2 из 6, как у «самого упоминаемого».
Интервал 0,10–0,70; один оправданный назван первым.
Не обвиняет невиновного – только ценой отказов.

Метки размечены автоматически, нужна проверка человеком. Эксперимент, в основной путь ответов не включён.

Выводы

Система отвечает цитатами и честно отказывается.

Агент немного лучше голой модели; от простого поиска значимо не отличается.

Правила точны, но автоматическому графу не хватает фактов.

Дальше: проверка наборов человеком, установка на двух ноутбуках.

Источники

docs/spike/results/eval-2026-10-28-test-7b7b197-7857839ed9be-175321.md
docs/spike/results/presence-pass-server-20261029.md
docs/perf/laptop-20261029.md
suspects-20261030.md
PR #30 на GitHub: описание измерений