Проект

Детективная доска

Detective Board

Локальный офлайн-следователь по 20 рассказам о Шерлоке Холмсе

Авторы:

Верховых Егор

Стрижевский Андрей

Парамонов Даниил

Приц Артём

30.10.2026

Цель и задачи

Цель: отвечать по тексту рассказов и показывать, на чём держится ответ.

1. Достать из текста факты вместе с дословными цитатами.
2. Проверить факты правилами, а не мнением модели.
3. Честно отказываться, если в тексте ответа нет.
4. Измерить качество и записать слабые места.

Зачем это нужно

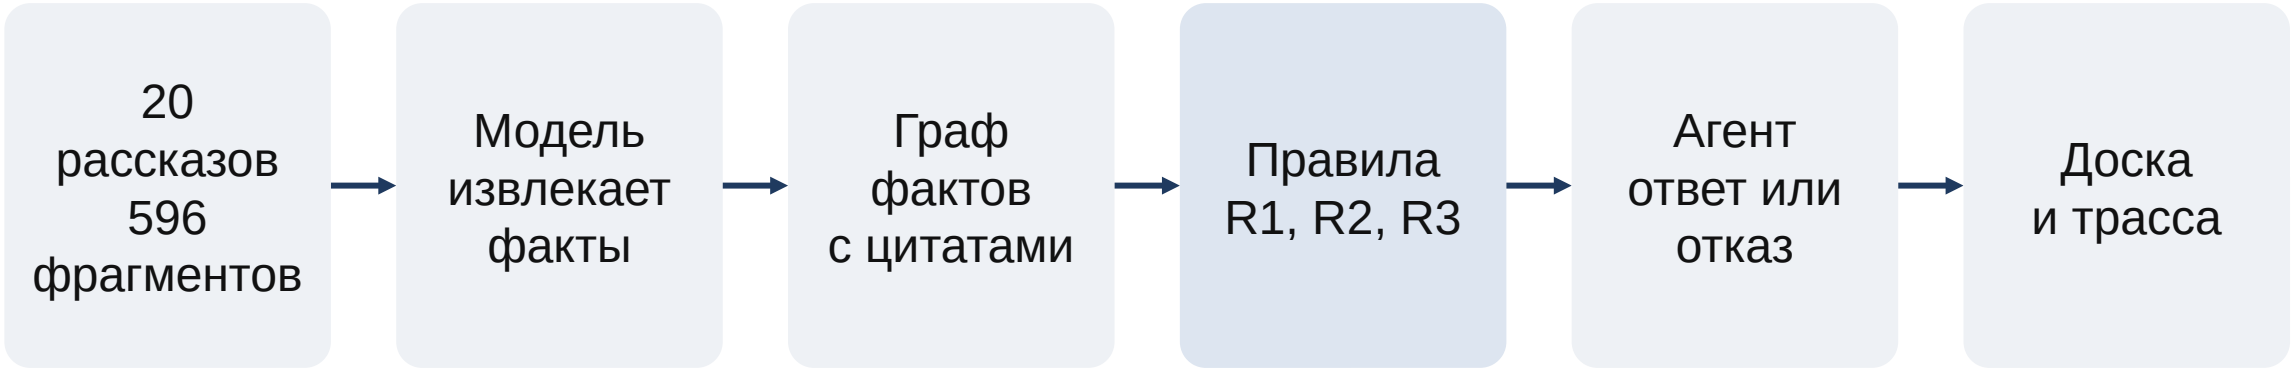
Обычная языковая модель отвечает уверенно, даже когда не знает.

Она выдумывает факты и цитаты.

Без поиска по тексту верный ответ только на 3 из 30 вопросов (test, n=30).

Наш ответ: цитата из текста или отказ

Как устроено



Модель угадывает, правила проверяют.

Всё работает на одном ноутбуке без сети.

Откуда взят каждый факт

extracted
достала модель;
может ошибаться

derived
вывело правило;
есть объяснение

conditional
правило на
сомнительном факте

В демо есть ещё curated: введены вручную, перепроверены человеком 29.10.2026; вывод conditional.

Три правила

R1. Человек не может быть в двух местах сразу.

R2. Порядок событий не замыкается в круг.

R3. Слова свидетеля не спорят с установленным фактом.

Нет данных — ответ «неизвестно», а не «всё согласовано».

Результат: вопросы с ответом или отказом



Агент впереди обоих вариантов. Шкала: 30 вопросов теста; метки ответов размечены автоматически, человек не проверял; разница с поиском в пределах шума.

Над чем работаем дальше

Правила: 0 из 12 противоречий на автоматическом графе – нужно больше фактов «кто где был».

«Кто где был»: 16 и 7 проверенных фактов на 159 фрагментах – основа, которую расширим.

Пока ни один не привязан ко дню рассказа: следующий шаг.

В эталоне 4 строгих факта: расширим набор.

Источник: отчёт о проходе присутствия (PR #29).

Скорость, интерфейс, тесты

Ответ на ноутбуке без GPU: медиана 28,4 с (замер не в чистом окне).
Доска, 14 карточек: сдвиг 2400 → 225 мс, масштаб 2100 → 315 мс.
Доска, 200 узлов: сдвиг 2060 → 384 мс, масштаб 13 900 → 2 780 мс.
Шум на масштабе большой; на ноутбуке не измерено.
Автотесты: 986 прошли за 9,6 с.

PR #30: время растеризации, headless Chromium, скриптовые сдвиг и масштаб. В покое картинка прежняя (отличие 1,5 из 255).

Эксперимент: угадываем виновного

Тест (8 рассказов, один прогон): наши методы на уровне простых.

Dev (8): лучший из ~35 вариантов угадал 4 из 8; на новых рассказах 2 из 6 – значит, на dev цифра оптимистична.

6 новых рассказов: 2 из 6, на уровне «самого упоминаемого».

Интервал 0,10–0,70: выборка мала, нужны новые рассказы; один оправданный назван первым.

Осторожный режим ни разу не назвал невиновного.

Метки размечены автоматически, нужна проверка человеком. Эксперимент, в основной путь ответов не включён.

Выводы

Система отвечает цитатами и отказывается, когда ответа в тексте нет.

Агент даёт лучший результат из трёх вариантов: 13 из 30.

Правила работают на проверенных фактах и объясняют каждый вывод.

Дальше: больше фактов «кто где был», проверка наборов человеком, установка на двух ноутбуках.

Источники

docs/spike/results/eval-2026-10-28-test-7b7b197-7857839ed9be-175321.md
docs/spike/results/presence-pass-server-20261029.md
docs/perf/laptop-20261029.md
suspects-20261030.md
PR #30 на GitHub: описание измерений