ПРОЕКТ · 2026

Детективная доска

Detective Board: локальный офлайн-следователь по 20 рассказам о Шерлоке Холмсе



АВТОРЫ

Верховых Егор · Стрижевский Андрей · Парамонов Даниил · Приц Артём

30.10.2026

Цель и задачи

Отвечать по тексту рассказов и показывать, на чём держится ответ.

01

Достать из текста факты вместе с дословными цитатами.

02

Проверить факты правилами, а не мнением модели.

03

Честно отказываться, если в тексте ответа нет.

04

Измерить качество и записать слабые места.

Зачем это нужно

Обычная языковая модель отвечает уверенно, даже когда не знает.

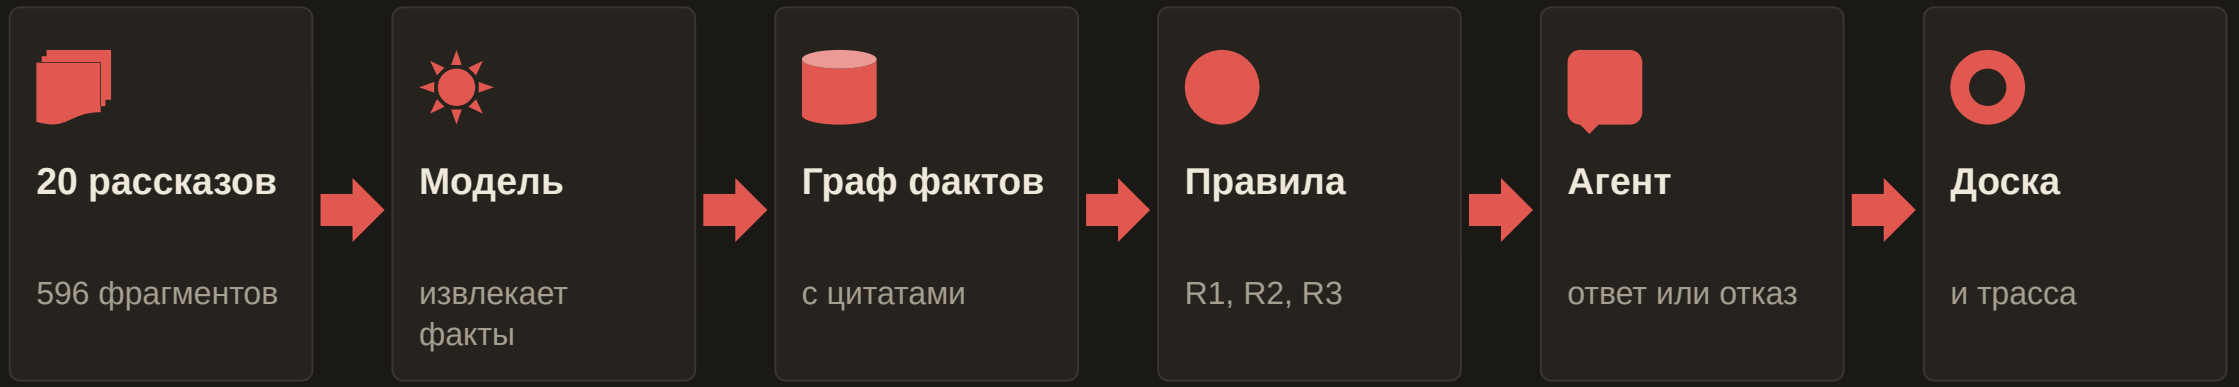
Она выдумывает факты и цитаты.

Наш ответ: цитата из текста или отказ.

3 из 30

верных ответов у модели без поиска по тексту (тест, 30 вопросов)

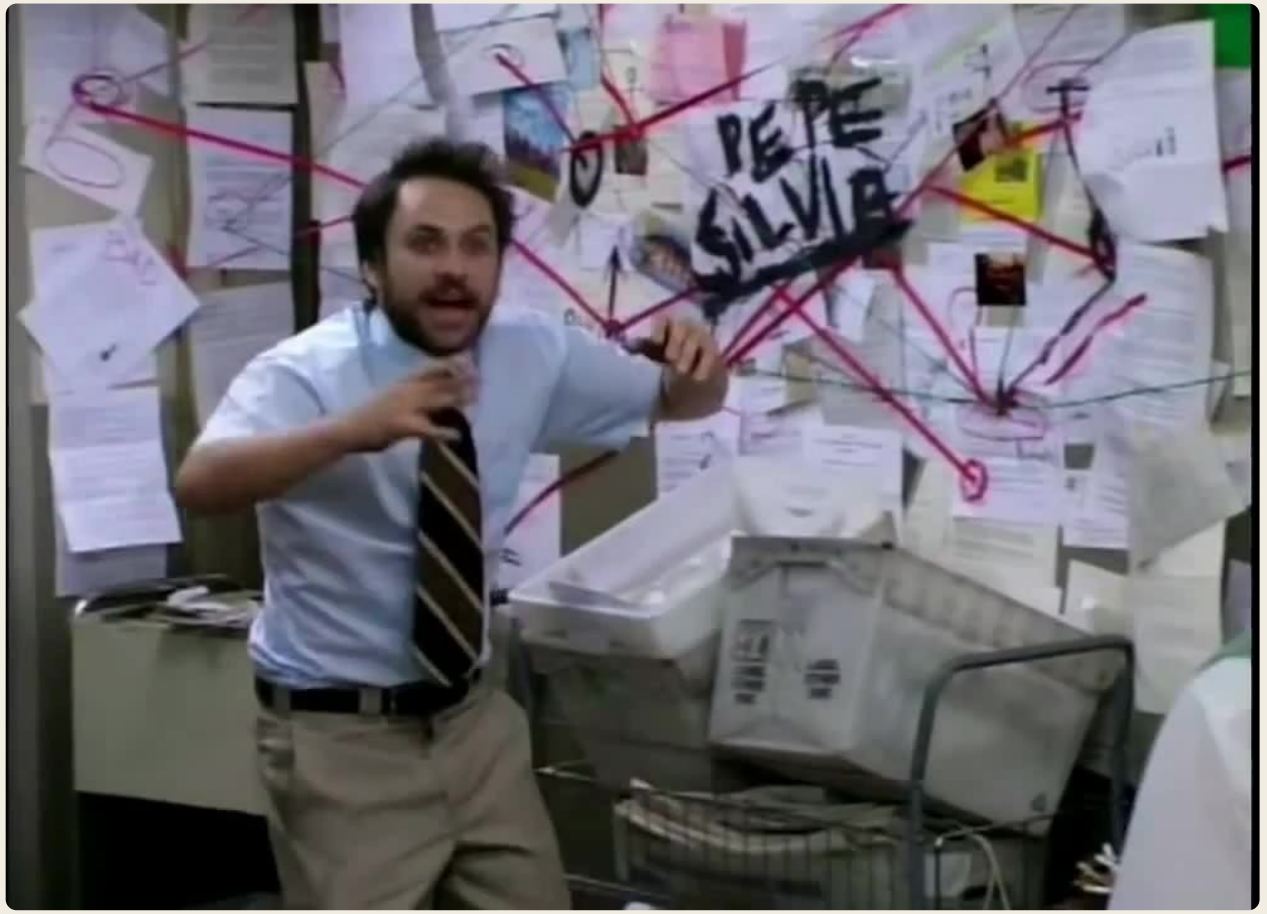
Как устроено



Модель достаёт факты, правила их проверяют.

Всё работает на одном ноутбуке без сети.

Доска без проверки

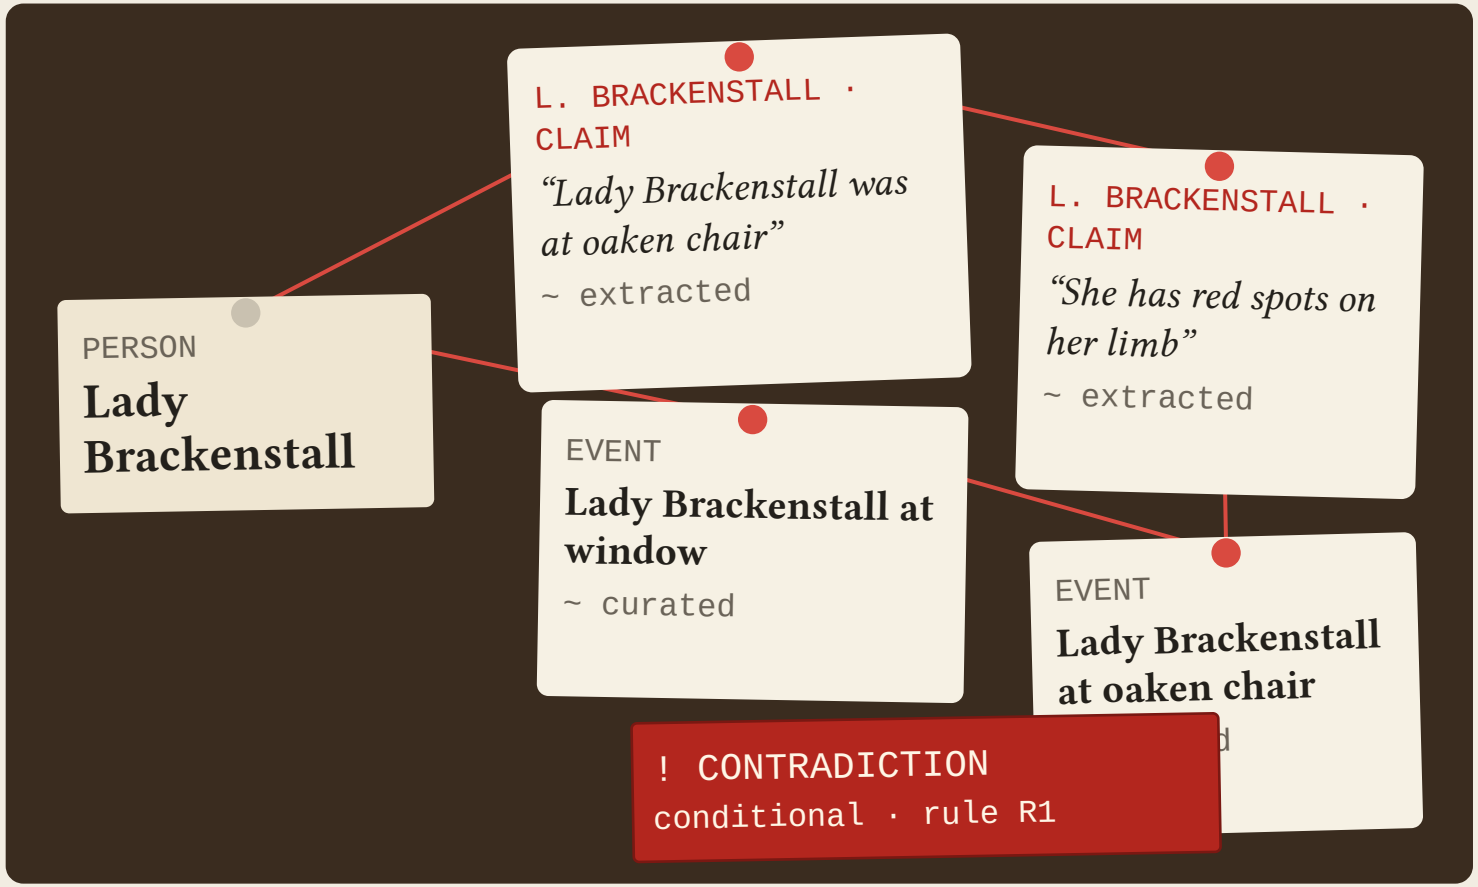


Нитей много, а проверки фактов нет.

У нас каждая нить опирается на цитату, а правила ищут противоречия.

Кадр из сериала «В Филадельфии всегда солнечно», известный мем про доску с нитями.

Так выглядит доска



01

Каждая карточка: факт и цитата из рассказа.

02

Метка внизу показывает происхождение: extracted, derived, curated.

03

Красная нить связывает факты. Красный тег: правило нашло противоречие.

Откуда взят каждый факт

`extracted`

достала модель; может ошибаться

`derived`

вывело правило; есть объяснение

`conditional`

правило на сомнительном факте

`curated`

факт введён вручную и перепроверен человеком (в демо)

У каждого факта есть метка происхождения. По ней видно, чему верить меньше, а чему больше.

Три правила

R1	Человек не может быть в двух местах сразу.
R2	Порядок событий не замыкается в круг.
R3	Слова свидетеля не спорят с установленным фактом.

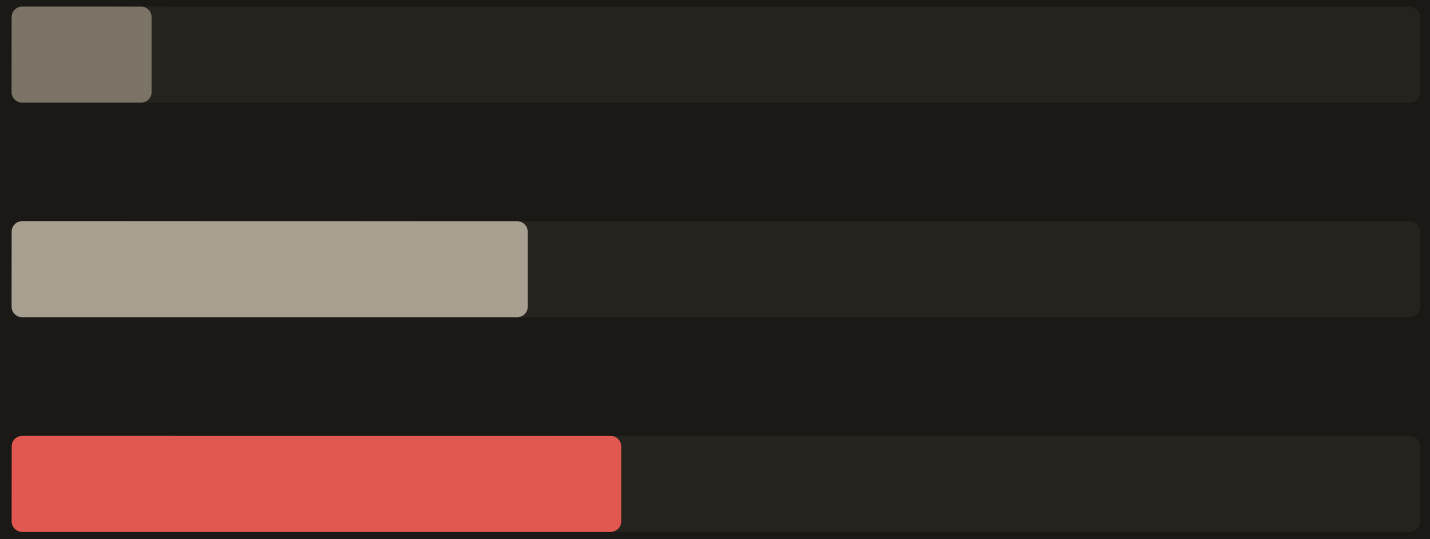
Если данных нет, ответ «неизвестно».

Результат: ответ по тексту или отказ

3 из 30
только модель

11 из 30
только поиск по тексту

13 из 30
агент (поиск + правила + отказ)



Агент впереди обоих вариантов. Шкала: 30 вопросов теста; метки ответов человек не проверял, разница с поиском в пределах шума.

Над чем работаем дальше

0 из 12

противоречий на автоматическом графе: нужно больше фактов «кто где был»

16 и 7

проверенных фактов «кто где был» на 159 фрагментах (две модели): основа, которую расширим

0

из них пока привязаны ко дню рассказа: следующий шаг

4

строгих факта в эталоне: расширим набор

Скорость, интерфейс, тесты

ДОСКА: ВРЕМЯ РАСТЕРИЗАЦИИ, МС

Доска	Действие	Было	Стало
14 карточек	сдвиг	2 400	225
14 карточек	масштаб	2 100	315
200 узлов	сдвиг	2 060	384
200 узлов	масштаб	13 900	2 780

986

автотестов прошли за 9,6 с

28,4 с

медиана ответа на ноутбуке без GPU (замер не в чистом окне)

PR #30 (влит): headless Chromium, скриптовые сдвиг и масштаб. Шум на масштабе большой; на целевом ноутбуке не измерено. В покое картинка прежняя (отличие 1,5 из 255).

Эксперимент: угадываем виновного

2 из 6

виновный назван первым на 6 новых рассказах: на уровне простого метода «самый упоминаемый»

Тест (8 рассказов, один прогон): наши методы на уровне простых.

Dev (8): лучший из ~35 вариантов угадал 4 из 8; на новых рассказах 2 из 6, значит, на dev цифра оптимистична.

Интервал 0,10–0,70: выборка мала, нужны новые рассказы; один оправданный назван первым.

Осторожный режим ни разу не назвал невиновного.

Метки виновного не проверены человеком. Ветка feat/suspects-matrix, в main её нет.

Выводы

01 Система отвечает цитатами и отказывается, когда ответа в тексте нет.

02 Агент даёт лучший результат из трёх вариантов: 13 из 30.

03 Правила работают на проверенных фактах и объясняют каждый вывод.

04 Дальше: больше фактов «кто где был», проверка наборов человеком, установка на двух ноутбуках.

Источники

docs/spike/results/eval-2026-10-28-test-7b7b197-7857839ed9be-175321.md

docs/spike/results/presence-pass-server-20261029.md

docs/perf/laptop-20261029.md

suspects-20261030.md (ветка feat/suspects-matrix)

Pull request #30 на GitHub: описание измерений

Верховых Егор · Стрижевский Андрей · Парамонов Даниил · Приц Артём