Гладко не значит доказано

Небольшая модель, без источников, на вопрос: *What kind of snake killed Dr. Grimesby Roylott?* (какая змея убила доктора Гримсби Ройлотта?)

> *Dr. Grimesby Roylott was not killed by a snake in the story of The Hound of the Baskervilles or any of Arthur Conan Doyle's Sherlock Holmes stories. [...] Wait - correction: Dr. Grimesby Roylott is not a character in The Hound of the Baskervilles.*

По-русски: змея его не убивала ни в «Собаке Баскервилей», ни в других рассказах; «Постойте, поправка»: он вообще не персонаж «Собаки Баскервилей».

RECORDING (запись настоящего прогона) - qwen3:4b-instruct, без поиска по текстам (no retrieval), temperature 0, seed 42, запуск 2026-10-23, 1 вопрос. Ответ в книге: swamp adder, болотная гадюка (*The Speckled Band*, «Пёстрая лента»).[1]

Идея: LLM угадывает, правила доказывают

ЧАСТЬ	ЧТО ДЕЛАЕТ	МЕТКА
LLM	читает рассказы, извлекает факты с дословной цитатой и оценкой уверенности (confidence)	`extracted`
Граф	хранит каждый факт с цитатой и привязкой к источнику	-
Правила R1-R3	выводят находки одинаково при каждом запуске; каждое правило перечисляет цитаты, которые использовало	`derived` / `conditional`
Текст	ответы - это предложения книги, а не проза модели	`source_text`

R1: один человек, одно место, один интервал. R2: в порядке событий нет цикла. R3: показание свидетеля против установленного факта.

Архитектура на одной картинке



Полные диаграммы: `docs/architecture/c4.md` (mermaid, отображается на GitHub).

Демо 1: вопрос и дословная цитата

Q: What kind of snake killed Dr. Grimesby Roylott? *(Какая змея убила доктора Гримсби Ройлотта?)*

> *From the sources: [1: "“It is a swamp adder!” cried Holmes; “the deadliest snake in India."]*

(Из источников: «Это болотная гадюка!» - воскликнул Холмс; «самая смертоносная змея в Индии».)

`selfcheck: verified` - `speckled-band-0030` - модель только выбрала предложение

```
$ rg -F "It is a swamp adder!" data/clean/speckled-band.txt
```

Verified = дословно есть в книге и подтверждает предложение. Это не «истинно».

Демо 2: Wisteria Lodge, правило R1

Q: Is there a conflict about where Aloysius Garcia was at about one o'clock on the night he died? *(Есть ли противоречие в том, где Алоизиус Гарсиа находился около часа ночи в ночь своей смерти?)*

- Eccles: *"...saying that it was nearly one o'clock."* (Garcia в Wisteria Lodge) - `curated`
- Baynes: *"He had been there since one o'clock."* (Garcia мёртв на Oxshott Common) - `curated`
- **R1 violated (нарушено), `= DERIVED`, нарисовано как `conditional`** - вызов инструмента в мс, без модели

Curated (ручные) факты: проверены командой, при участии ИИ, повторная проверка человеком ещё не проведена. Автоматическое извлечение измеряется отдельно.

Демо 3: честный отказ

Q: What was the creature that haunted the Baskerville family on the Devonshire moor? *(Что за существо преследовало семью Баскервилей на девонширских болотах?)*

> *In these materials there is nothing about this.*

(В этих материалах об этом ничего нет.)

- Gate (фильтр релевантности): лучшие фрагменты покрывают **0.17** терминов вопроса, нужно **0.25** - отказ до любого вызова LLM
- Голая модель, тот же вопрос: уверенный ответ по памяти (канон, а не свидетельство корпуса)

Измерено: тестовая выборка, один запуск

Голая модель

10%

3 из 30 · [3, 26]

Только векторный поиск
(наш же конвейер)

37%

11 из 30 · [22, 54]

Агент (hybrid+graph)

43%

13 из 30 · [27, 61]

Агент против голой модели: 11 вопросов против 1, **p = 0,006**. Агент против vector-only: 2 против 0, p = 0,5, **не значимо**.

	РЕЗУЛЬТАТ
Поиск и отказы	нужный фрагмент в топ-4: 16 из 24 у обоих; вне корпуса отклонено **6 из 6** (голая модель 2 из 6); верное предложение: агент 11 из 18, vector-only 7 из 18
Правила на автоматических фактах	найдено **0 из 12** случаев, ложных срабатываний 0 из 8

Критерий механический, эталон написан ИИ, один запуск; допустимые диапазоны записаны до запуска. *Не получилось, и мы это показываем:* судья противоречий (8 из 9 контролей помечены неверно), выбор виновного из списка (невиновный назван в 2 из 8), вопрос «кто виновен» до развязки (0 из 16).

Ограничения выполнены

- **Офлайн**: на время демо сеть выключена; облачной модели нет
- **Только CPU**: на демо-ноутбуке нет GPU; prefill около **21 токена/с**
- **Модели <= 8B**: qwen3:4b-instruct (ответы), qwen3:4b (извлечение), bge-m3 (эмбеддинги); пиковый RSS модели ответов **3195 MiB**
- **Воспроизводимо**: temperature 0, seed 42; `just run` запускает демо; ноутбук, три серии по 6 вопросов, 2026-10-29: медиана **28 с** на ответ (19-44 с), пик **6.3 GB**, **98-100 C** (не чистое окно); установка офлайн одной командой: `verify_offline.sh` прошёл на одном ноутбуке (на втором ещё нет)

Раскрытие и честные ограничения

1. **Предвычислено на другом оборудовании.** Извлечение графа выполнено один раз на кафедральном GPU-сервере теми же открытыми моделями, с тем же промптом и теми же параметрами декодирования; организаторы это разрешили. Ни одна модель не обучалась. Этот ноутбук отвечает на вопросы офлайн.
2. **Curated (ручные) факты.** Восемь фактов (Garcia и Scott Eccles в Wisteria Lodge, Lady Brackenstall в Abbey Grange, контроль Boscombe) введены командой с дословной цитатой, при участии ИИ, и подписаны `curated` на экране и в ответе. Повторная проверка человеком: ожидается.
3. **Эталонные наборы (gold sets) написаны ИИ**, человеком не проверены; метрика механическая. Проверка: **не проведена**. Тестовая выборка запущена один раз, ожидаемые диапазоны записаны заранее.
4. **Правила ничего не находят на автоматических фактах** (0 из 12 тестовых случаев): красные конфликты в демо опираются на curated-факты. Слабое звено - извлечение «кто где и когда».
5. Только измеренные числа. **Verified = дословно и лексически подтверждено, а не истинно.**

Что дальше

- Проверка человеком эталонных наборов и curated-фактов
- Лучшее извлечение «кто где и когда» (дообучить малый экстрактор на сервере, измерять на фактах, проверенных людьми): слабое звено R1 и R3
- Карточки доказательств (evidence cards) по фрагментам и матрица конкурирующих гипотез, чтобы дело можно было аргументировать до развязки (сегодня: 0 из 16)
- Повторить измерения на втором компьютере и с профилем 8 GB

Модель угадывает. Правила доказывают. Каждый шаг показывает свои цитаты.

B7. Более ранние и dev-числа

ЧТО	РЕЗУЛЬТАТ	N	ОГОВОРКА
Реальный API, режим выбора предложения (extractive), 2026-10-27	цитируемое предложение для **6 из 10** вопросов, на которые есть ответ; **2 из 2** вопросов вне корпуса отклонены; **8.1-20.2 с** на вызов модели	12 вопросов, 1 запуск	«отвечено» не значит «правильно»; судей-людей не было
Проверка только поиска (retrieval-only), 2026-10-23	**5 из 10** отвечено и верифицировано; поведение правильное **8 из 12**; голая модель против агента на вопросах, требующих отказа, **1 из 3** против **2 из 3**	12 вопросов, 1 запуск	эталон написан ИИ; граф и правила выключены
Эталонный фрагмент в топ-4	**70 из 86 = 81%**	86 вопросов	только поиск, без LLM
Полный граф с кафедрального сервера, 2026-10-27	**596 из 596** фрагментов, 20 из 20 рассказов, 2157 утверждений, 1698 событий; правила: **0 находок в 19 из 20 рассказов** (только curated Garcia R1)	596 фрагментов, 1 запуск	качество извлечения не оценено, кроме 12 эталонных фрагментов; проход по присутствию (presence pass) не запускался
Реальный стек на полном графе, ноутбук, 2026-10-28	**5 из 6** dev-вопросов отвечены цитируемым предложением за **30-43 с**; 1 отклонён (g009, многошаговый, multi-hop)	6 вопросов, 1 запуск	не чистое окно; «отвечено» не значит «правильно»
Dev-выборка, три конфигурации, 2026-10-28 (eval runner, механический критерий, пересчитано)	правильное поведение: голая модель **4/34 = 12%** [5, 27], vector-only **15/34 = 44%** [29, 61], hybrid+graph (агент) **12/34 = 35%** [21, 52]; поиск лучше голой модели (McNemar p 0.001 и 0.02); **vector-only против агента: 3 против 0, p 0.25, не значимо, агент не лучше**	34 вопроса, 1 запуск	критерий (proxy) = покрытие ключевых фактов >= 0.5 ожидаемого ответа; эталон написан ИИ; тестовая выборка не запускалась
Агент после настройки списка кандидатов (12 предложений из индекса + по 3 из каждого из 4 лучших фрагментов; выбрано на dev	правильное поведение **14/34 = 41%** [26, 58]; эталонное предложение процитировано **13/22 = 59%**; вопросы вне корпуса отклонены **7/7**; ложные отказы **5/27**; все цитаты верны 9/22	34 вопроса, 1 запуск, только hybrid+graph	настроено на тех же 34 dev-вопросах: оптимистично; vector-only 15/34 = 44% в исходном запуске, поэтому разрыв с ним теперь один

B1. Почему ручные факты: что нашёл автоматический конвейер

Первый настоящий запуск, один рассказ (wisteria-lodge), после детерминированной починки:

- **107** событий, **137** утверждений
- **0** точных моментов времени, **0** дней рассказа, **1** пригодное предложение о присутствии
- R1 рассмотрело **19** пар и не смогло решить **16**

Проход по присутствию (presence pass) на 3 фрагментах случая c001 (по 1 запуску): qwen3:4b-instruct **7** фактов, оставлен **1** (и оставленный неверен); qwen3:8b **15** фактов, оставлено **11**, ключевой факт верен, несколько неверных персон или мест. Точность не измерена.

Поэтому демо-случаи используют curated-факты (сегодня их восемь). Они показывают, что делают правила, когда факты верны, а не то, что модель находит сама.

B2. Пилот извлечения (12 фрагментов)

QWEN3:4B	ПРОМПТ V2.1 (ИСПОЛЬЗУЕТСЯ)	ПРОМПТ V2.2 (НЕ ПРИНЯТ)
strict F1, сущности (entities)	0.557	0.000
strict F1, утверждения (claims)	0.200	0.283
strict F1, связи (relations)	0.136	0.026
утверждения с polarity=deny	91%	12%
события с участниками	0%	33%

Оговорки: 12 фрагментов, эталон размечен ИИ, различия на уровне шума. После v2.1 используется детерминированный шаг починки (ADR-0012). Источник: `docs/spike/results/prompt-v2-2-20261026.md`.

B3. Пилот поиска

ВАРИАНТ (BGE-M3, 35 ВОПРОСОВ)	HIT@1	HIT@5
Hybrid RRF k=30, bm25:vec 0.5:1	0.63	0.97
Hybrid k=10, 1:1	0.60	0.91

Эталонный фрагмент в топ-k, 86 вопросов с ответом: топ-3 **63/86 = 73%**, топ-4 **70/86 = 81%**, топ-5 **72/86 = 84%**.

Оговорка: k и веса подбирались на тех же 35 вопросах, поэтому 0.97 оптимистично. Реранкер при hit@5 не нужен.

B4. Скорость на этом CPU

- Prefill: около **21-22 токенов/с**; потоки, размер батча, длина контекста ничего не меняют за пределами шума (1 запуск на вариант)
- Помог только кэш префикса системного промпта: **42.7 с** против **52.7 с** для промпта в 1080 токенов
- Генеративные ответы: **45.7-140.8 с** на вызов модели (реальный API, 12 вопросов); проверка только поиска: первый токен **42.0 с**, **59.5 с** на вопрос
- Ответы в режиме выбора предложения (модель только выбирает предложения): **8.1-20.2 с**

Поэтому модель выбирает предложение, а не пишет его (ADR-0009).

B5. Контрольный случай, который правила не должны помечать

Boscombe Valley, случай c042: оба свидетеля согласны в том, что делал James; расходятся только в том, следовал ли он намеренно. Это намерение, а не наблюдаемый факт.

- Правила правильно **не** помечают его (регрессионный тест на трёх curated-фактах, а не на настоящем извлечённом графе)
- Контроль слабее своего названия: метку в эталоне должен решать человек
- Запись: `?replay=replay/real-boscombe-control.json` (25.3 с при исходном темпе)

B6. Где режим выбора предложения всё ещё ошибается

Те же 12 вопросов, один запуск:

- g007 и g016 - на них есть ответ, но они отклонены (модель выбирает NONE)
- g057 (состязательный вопрос, ожидается поправка верной предпосылки) отклонён
- g062 (на русском) отклонён фильтром релевантности; русский язык необязателен
- Модель на 4B чувствительна к формулировке: одна переписанная клауза перевела g001 в NONE, поэтому промпт выбора заморожен

«Отвечено» не значит «правильно»: ответы никто не оценивал.